这次作业的资源账单

原作业要的 · 四张 GPU

- L40S 裁判模型
- L4 最弱的 agent
- L40S 中间的 agent
- H100 最强的 agent

课程给选课学生发算力额度

我们实际用的

1 × L40S 约 2 小时 10 分钟	≈ $6
裁判 token	≈ 529 万
三个 agent Bedrock	34 万
做作业 + 做视频的会话	见开头



开发日志

作业 2：给 agent 打分

作业 1：搭一个 agent

作业 2：给 agent 打分

就是常说的"让大模型当裁判"，只不过裁判是指定的，而且偏弱



不给标准答案

不给参考图

看不到别的运行



作业说明开头

四类错误

没出图 `execution_failure`

中途报错放弃

数据错 `wrong_data`

漏了一步变换

设计不符 `wrong_chart`

该用对数轴用了线性轴

可读性差 `hard_to_read`

文字互相压住

示意



可读性差

被边缘切掉一半



设计不符

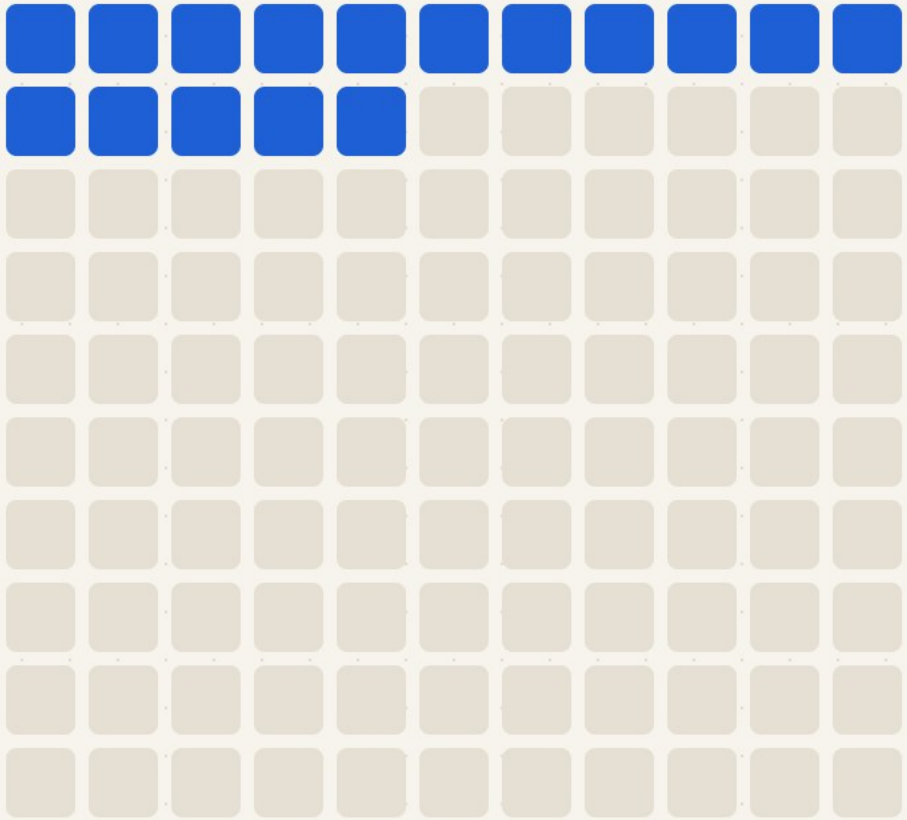
销售额

整个掉到图外 = 缺了必需元素



作业说明 Scoring

种子集 110 个运行 · 用 MCC 打分



永远说"有错"

65%
准确率

0
MCC

MCC：全对 1 · 和瞎猜一样 0 · 比瞎猜还反 负数

四类各算一个 MCC，取平均 = macro-MCC

$$MCC = (TP \cdot TN - FP \cdot FN) / \sqrt{((TP+FP)(TP+FN)(TN+FP)(TN+FN))}$$

完全没错 16 | 设计不符 71 | 可读性差 39 | 数据错 25 | 没出图 12



作业说明 Scoring

四部分 · 评分 · 我的顺序

1. 跑 baseline · 找误判
2. 两项改进
3. 自己出 5 道题 · 打包成 Harbor
4. 再迭代 · 写报告

40	30	20	10
报告	私有集 MCC	测验	代码

私有集我们拿不到 · 只报种子集和自建题

改过的 validator　五道题 + Harbor 包　15 个运行的人工标注　LaTeX 报告

我的顺序

① 先跑 baseline 算账

② 能用代码判的不交给模型

③ 一次只改一两处

④ 差异当场记进表



作业说明 Grading

部署
baseline
改进
出题
Harbor
迭代
踩坑

裁判模型被写死了

ASSIGNMENT.md

"you may not replace it or call another model from your validator"

你不能替换它，也不能在 validator 里调用别的模型

"We'll grade your assignment by calling your validator using a deployment of this same model."

评分时，我们也用同一个模型来跑你的 validator

裁判
Qwen3-VL 30B

300 亿参数 · 每次激活 30 亿

固定 · 不能换

不能请外援

弱裁判
看图能力有限 · 故意选的

→

用工程手段补
validator 要能泛化



作业说明

● 部署
baseline
改进
出题
Harbor
迭代
踩坑

为什么要自己部署

1 锁死变量

- 权重 · Qwen3-VL-30B-A3B
- 量化 · FP8
- vLLM 0.13.0
- 上下文 32768
- 温度 0

第三方接口随时可能换版本

2 专有接口

/tokenize /detokenize



只有自己部署的 vLLM 才有

3 成本可控

- 开源权重
- 课程发的算力额度
- 全班几百人反复跑

另外三个 agent

3B | 14B | GLM Flash

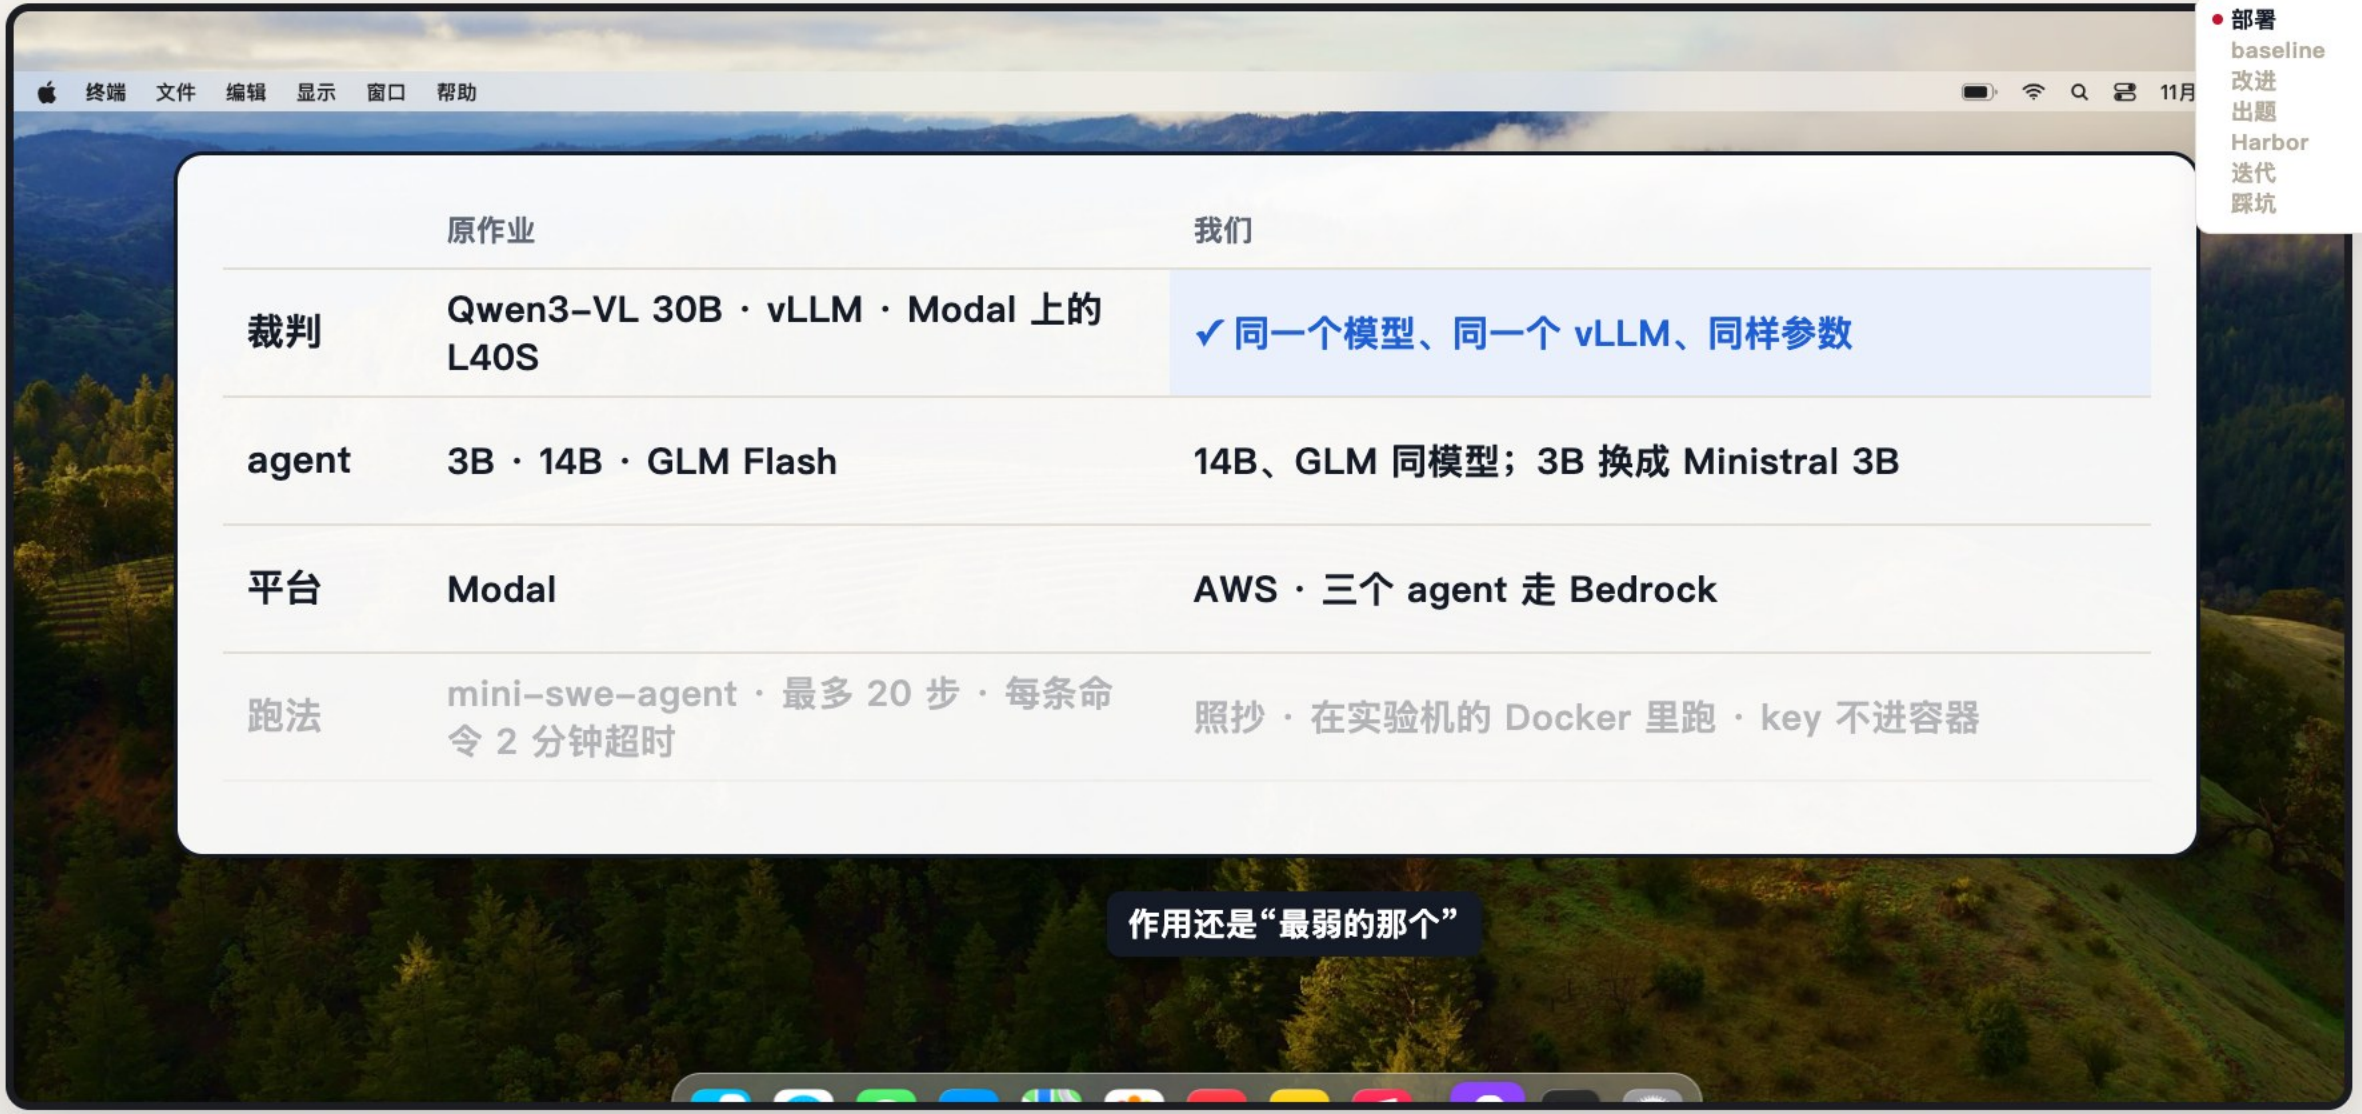
弱 → 强

给自己出的题交卷子

强弱不一 → 有对有错



作业 infrastructure/



	原作业	我们
裁判	Qwen3-VL 30B · vLLM · Modal 上的 L40S	✓ 同一个模型、同一个 vLLM、同样参数
agent	3B · 14B · GLM Flash	14B、GLM 同模型；3B 换成 Ministral 3B
平台	Modal	AWS · 三个 agent 走 Bedrock
跑法	mini-swe-agent · 最多 20 步 · 每条命令 2 分钟超时	照抄 · 在实验机的 Docker 里跑 · key 不进容器

作用还是“最弱的那个”



开发日志 · 环境


终端 文件 编辑 显示 窗口 帮助
11月
GPU 机器 — 第一次开机
冷启动（开发日志）
[1/4] 安装 vLLM 0.13.0
约 2 分钟
[2/4] 下载权重 Qwen3-VL-30B-A3B-Instruct-FP8 · 30 GB
216 秒
[3/4] 从云硬盘读进显存
约 6 分钟
[4/4] GET /health → 200
共约 20 分钟
第一次开机
约 20 分钟
第二次开机
5 分半
停机 · 不删盘
一轮全量 12–15 分钟
先写完一版
离线自测
再开 GPU 去跑



开发日志 · 冷启动

部署
baseline
改进
出题
Harbor
迭代
踩坑

baseline：macro-MCC 只有 0.027

110 个运行　用了约 15 分钟



0 ≈ 瞎猜

68 判“没问题”
其中真没问题的只有 3 个

37 判“没出图”

5 判“设计不符”

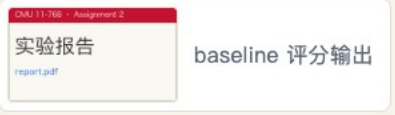
一次都没判过

数据错　可读性差

平均每个运行 8 秒

一次都没触发上下文截断

vLLM 专有接口 `/tokenize` `/detokenize` 没派上用场



baseline 评分输出

部署
baseline
改进
出题
Harbor
迭代
踩坑

误判类型一：答反了

⦸ 没出图　误报 33 个

问题（原文）

Did the agent crash, exhaust its turns, or give up without producing a valid figure?

agent 是不是崩了、用完了轮数、或者没画出有效的图就放弃了?

裁判回答 · run 022

YES **裁判的意思：是的，它画出来了**

`"The agent successfully completed the task..."`

baseline：只看开头是不是 YES → 判成没出图



33 / 33
误报的运行都存了图

32
裁判理由在说 agent 成功了



误判分析 类型 1

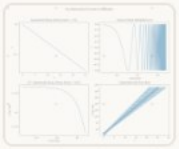
部署
baseline
改进
出题
Harbor
迭代
踩坑

连带损失：后面三类不查了

没出图 | 提前返回 | 数据错 | 设计不符 | 可读性差

20 / 33
误报里其实带着别的错

25
个标签被盖住



例：004
第三个子图该用对数轴，却是线性轴

真没出图的 8 个：裁判答 NO，一个都没认出来

010	053	065	089	096	168	181	208
没有图	没有图	没有图	没有图	没有图	没有图	没有图	没有图
判成出了图	判成出了图	判成出了图	判成出了图	判成出了图	判成出了图	判成出了图	判成出了图

<> 用代码判：没有 figure.png ⇔ 没出图 · MCC 1.000



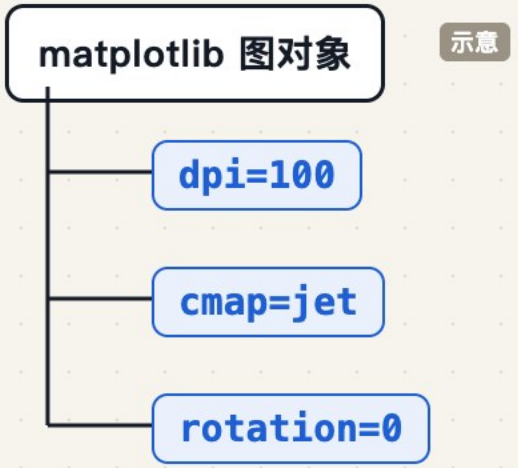
误判分析 类型 1

部署
baseline
改进
出题
Harbor
迭代
踩坑

误判类型二：写死的参数被放过

run	任务要求	实际
009、038	x 轴刻度旋转 30 度	水平
060、130	120 dpi	100 dpi
051、106、130	禁止 jet	用了 jet
016、028	要有图例	没有
112、126	y 轴从 0 开始	从 1 或约 −110 开始
142	横向柱状图	竖向

👁 看图：dpi 看不出来



示意

它就是一个确定的值



误判分析 类型 2

部署
baseline
改进
出题
Harbor
迭代
踩坑

改进一：有没有出图，用代码判



改进二：重放代码，量出实际画了什么

代码轨迹
每条 bash 命令

每条命令单开一个 shell

Docker 沙箱
--network none

断网 · 2 GB · 非 root

劫持 savefig
sitecustomize.py

图对象 JSON
测量结果

规则检查
dpi · 尺寸 · 配色 · 旋转
图例 · y 从 0 · 横竖柱

不给图

裁判逐条核对
任务说明 + 测量 JSON

met · violated · unknown

只收 violated

solution.py

```python
if not _docker_ok():
    # Agent code is untrusted: never run it on the host. Without the
    # sandbox the validator falls back to judging the image.
    return None
```

没有 Docker：放弃重放，退回看图判断

× 绝不在宿主机上执行

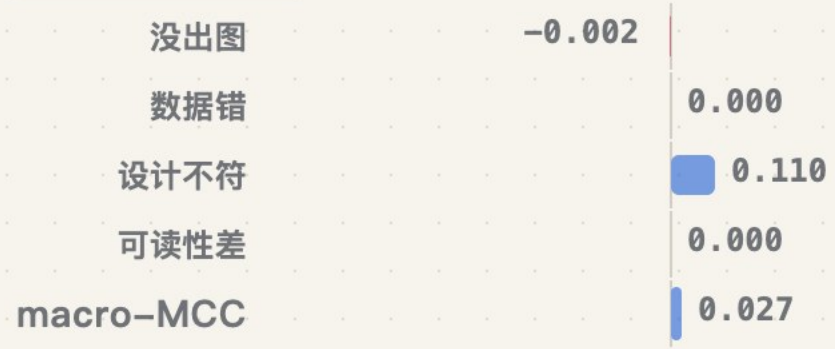


开发日志 Part 2

部署
baseline
改进
出题
Harbor
迭代
踩坑

两项改进一起上：macro-MCC 0.027 → 0.332

baseline（Part 1）



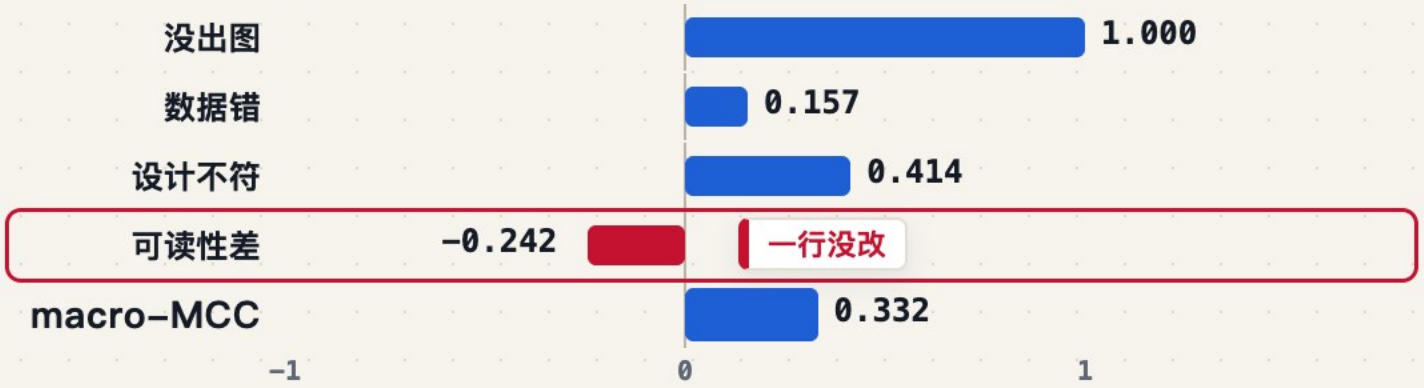
以前被误判成没出图的 33 个运行



可读性检查

baseline 的问法 · 一行没改

Part 2 · 两项改进

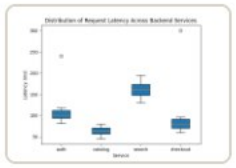


8 误报 · 0 命中

实验报告 report.pdf Part 2 结果

一个误报，一个漏报

误报 · 082 数据错



箱线图 · auth 组的 8 个数

82	91	95	99	104	110	118	240

中位数 = (99 + 104) / 2 = 101.5 · 图画对了

裁判
Qwen3-VL 30B

“中位数是 97”
拿了第 3、4 个数 → 判 agent 画错

弱裁判在提示词里做算术 → 算错 → 记成 agent 的错
数据错的 15 个误报，大多是这样来的

漏报 · 016 设计不符



要求有图例
图里没有
我们没报

我自己的 bug：图例规则的分支写反了
Part 2 时：只在任务说“不要图例”时才检查

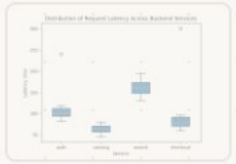
下一轮修 · 下面是修好后的代码

solution.py · 图例规则（已修）

```
mentions = list(re.finditer(r"\blegend\b", low))
if mentions and not any(_negated(low, m.start()) for m in mentions):
    has_legend = extra.get("has_fig_legend") or ...
    if not has_legend:
        errors.append(_err(ErrorFamily.WRONG_CHART, ...))
```

一个误报，一个漏报

误报 · 082 数据错



箱线图 · auth 组的 8 个数

82	91	95	99	104	110	118	240

中位数 = (99 + 104) / 2 = 101.5 · 图画对了

裁判
Qwen3-VL 30B

“中位数是 97”
拿了第 3、4 个数 → 判 agent 画错

弱裁判在提示词里做算术 → 算错 → 记成 agent 的错
数据错的 15 个误报，大多是这样来的

漏报 · 016 设计不符



要求有图例 | 图里没有 | 我们没报

我自己的 bug：图例规则的分支写反了
Part 2 时：只在任务说“不要图例”时才检查

下一轮修 · 下面是修好后的代码

solution.py · 图例规则（已修）

```
mentions = list(re.finditer(r"\blegend\b", low))
if mentions and not any(_negated(low, m.start()) for m in mentions):
    has_legend = extra.get("has_fig_legend") or ...
    if not has_legend:
        errors.append(_err(ErrorFamily.WRONG_CHART, ...))
```

Part 2 时这里分支写反



Part 2 结果

部署
baseline
改进
出题
Harbor
迭代
踩坑

先猜它会在哪两处翻车

读一遍自己 Part 2 的代码

派生计算 derived-aggregation

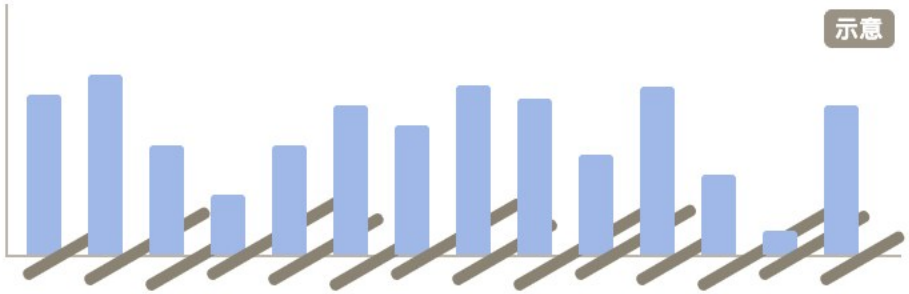
筛选 | 排序 | 累计 | 滚动窗口

裁判只看到汇总后的数

数据错 一条规则都没写

密集文字 dense-text-layout

长标签 | 扎堆的标注



可读性差 还是 baseline 的问法

五道题：考它的两处弱点

数据：固定随机种子合成

派生计算 · 3 道

1

营收占比 ·
最大的在最上面

regional-revenue-share

3B 14B GLM

2

里昂 7 日均温 ·
前 6 天不画

lyon-rolling-temperature

3B 14B GLM

3

三渠道累计注册 ·
固定堆叠顺序

cumulative-signups-by-channel

3B 14B GLM

密集文字 · 2 道

4

14 个长名字部门 ·
7×4 英寸

department-headcount-…

3B 14B GLM

5

25 座非洲城市 ·
对数轴散点

african-cities-…

3B 14B GLM

15 个运行
全部出了图

130 次
模型调用

34 万
agent token（三个合计）

不到 1 毛
美元

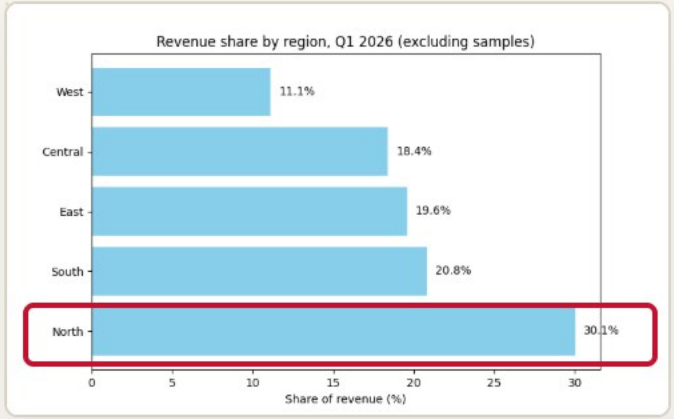


实验报告 Part 3

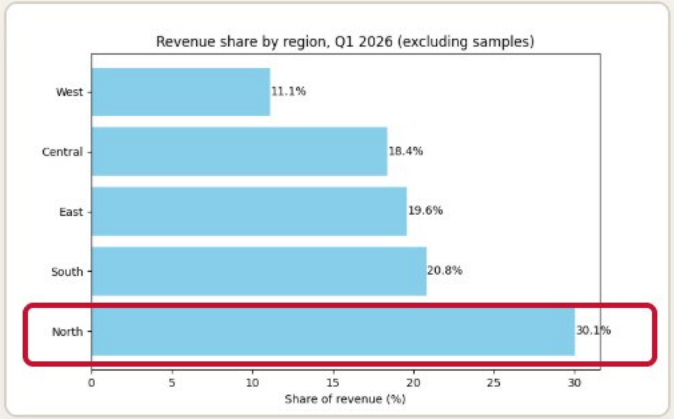
标注时看到的

1 三个 agent，犯了同一个错

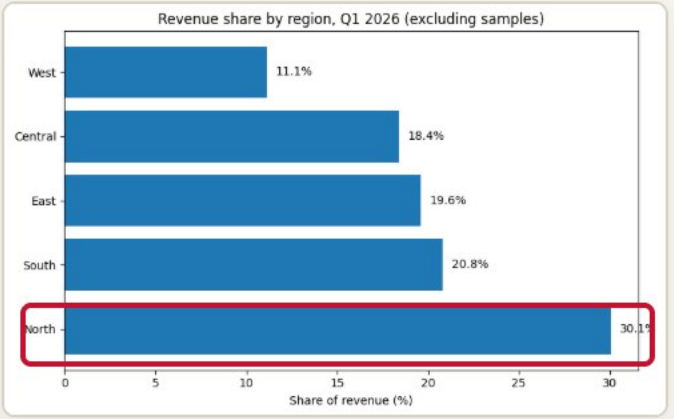
3B



14B



GLM



✓ 占比都算对了　✓ 都按从大到小排了　× 最大的那根在最下面

barh 横向柱状图：第一根柱子画在最下面



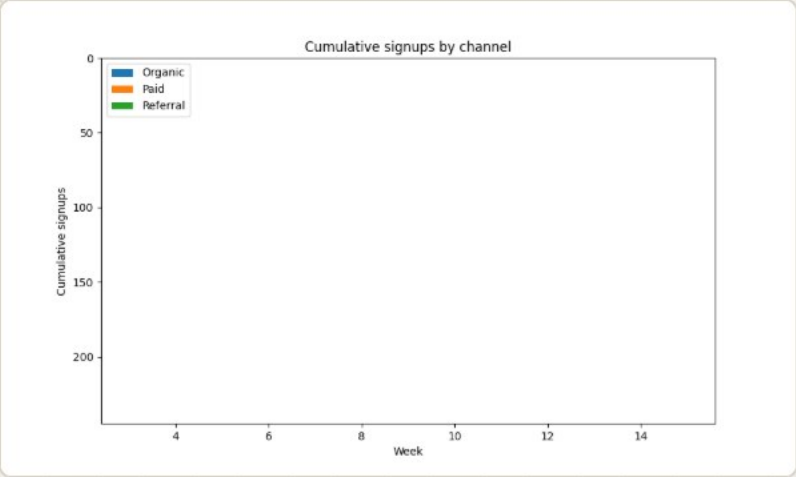
实验报告 Part 3

部署
baseline
改进
出题
Harbor
迭代
踩坑

标注时看到的

3 最弱的模型画出了一张空图

3B



累计值对错了行 → 全变成空值

图上只剩图例

还顺手把纵轴倒了过来

cumulative_signups_by_channel.py

```
    cumulative_totals[channel] = weekly_signups_channel['signups'].cumsum()
...
plt.gca().invert_yaxis()  # Stacking is inverted in matplotlib
```

它自己编的



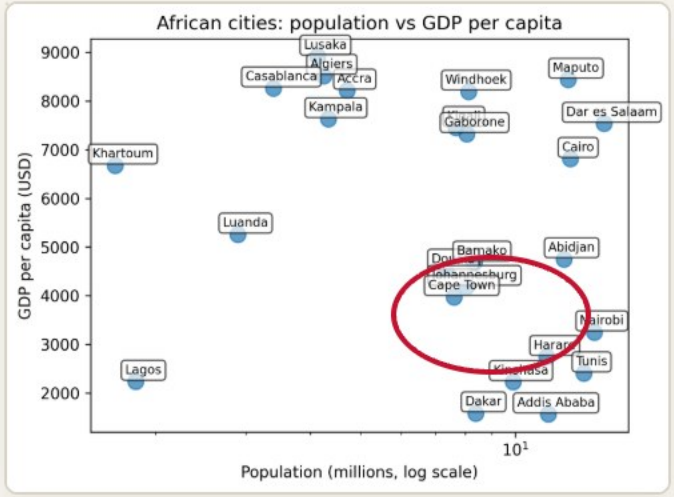
实验报告 Part 3

部署
baseline
改进
• 出题
Harbor
迭代
踩坑

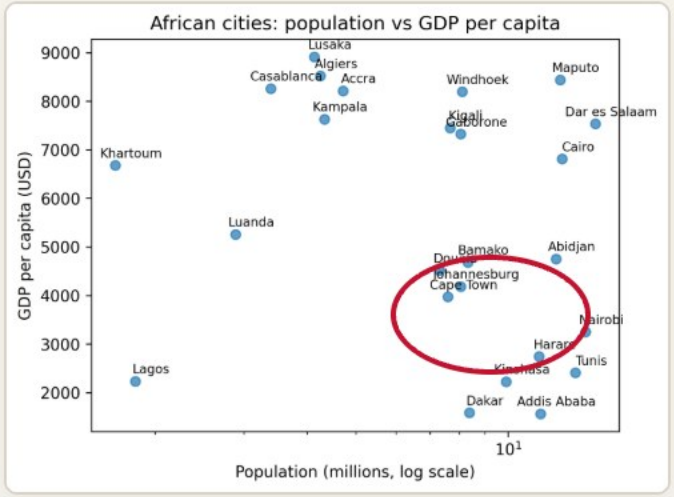
标注时看到的

4 城市名全都叠在一起

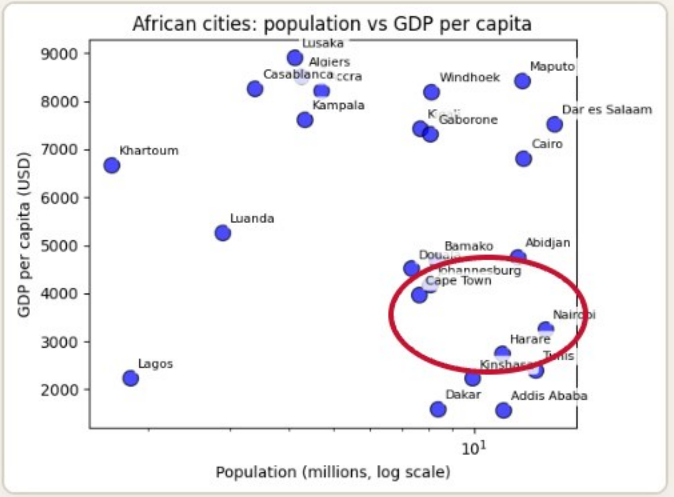
3B



14B



GLM



可读性差 三张都是

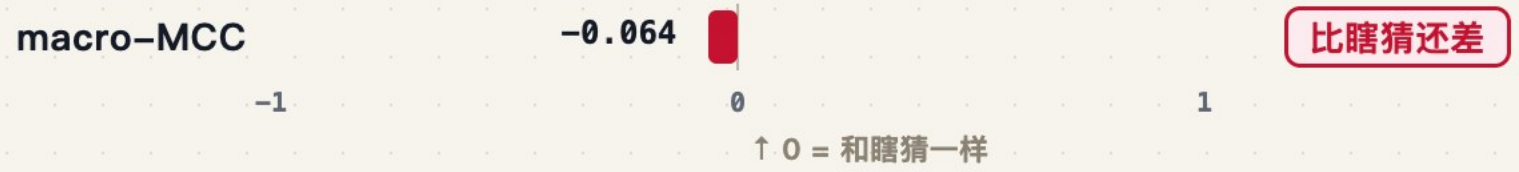


实验报告 Part 3

部署
baseline
改进
出题
Harbor
迭代
踩坑

迭代前：macro-MCC −0.064

Part 2 版本 · 自建 15 个运行





15 个里 13 个被误判成设计不符

测量结果里的标注
只截了前 10 条
→ 裁判："25 个标注只画了 10 个"

灰点的配色字段是默认值 viridis
→ 裁判："点不是灰色的"

agent 真犯的那几个错，
它反倒大多漏了



实验报告 Part 3 结果

部署
baseline
改进
出题
Harbor
迭代
踩坑

Harbor：每道题是一个目录

```
harbor/tasks/
├─ regional-revenue-share/
│  ├─ instruction.md
│  ├─ task.toml
│  ├─ environment/  沙箱：Dockerfile · orders.csv
│  ├─ tests/test_state.py  评分标准
│  ├─ solution/solve.sh
│  └─ mutants/largest_at_bottom/
├─ african-cities-annotated-scatter/
│  ├─ …
│  └─ mutants/label_pileup/
├─ cumulative-signups-by-channel/
├─ lyon-rolling-temperature/
└─ department-headcount-long-labels/
```

tests/test_state.py

确定性检查

重跑画图脚本 · 和手算的值逐个比

solution/solve.sh

参考答案

必须 1.0

mutants/

两个错误答案

一个 0 分 · 一个骗到 1.0



Harbor 题目目录

部署
baseline
改进
出题
Harbor
迭代
踩坑

Harbor：每道题是一个目录

```
harbor/tasks/
├─ regional-revenue-share/
│  ├─ instruction.md
│  ├─ task.toml
│  ├─ environment/  沙箱：Dockerfile · orders.csv
│  ├─ tests/test_state.py  评分标准
│  ├─ solution/solve.sh
│  └─ mutants/largest_at_bottom/
├─ african-cities-annotated-scatter/
│  ├─ …
│  └─ mutants/label_pileup/
├─ cumulative-signups-by-channel/
├─ lyon-rolling-temperature/
└─ department-headcount-long-labels/
```

Harbor 版：agent 还要多存两样

`plot.py` 画图脚本　`plotted_values.json` 画出来的数值

tests/test_state.py

```python
EXPECTED = {"North": 30.0656, ...}
...
def test_s3_sidecar():
    data = sidecar()
    ...
    for key, value in data.items():
        ...
        assert abs(value - EXPECTED[key]) < 0.01, ...
```

EXPECTED：我手算好的字面值



Harbor 题目目录

部署
baseline
改进
出题
Harbor
迭代
踩坑

两个错误答案：一个 0 分，一个骗到 1.0

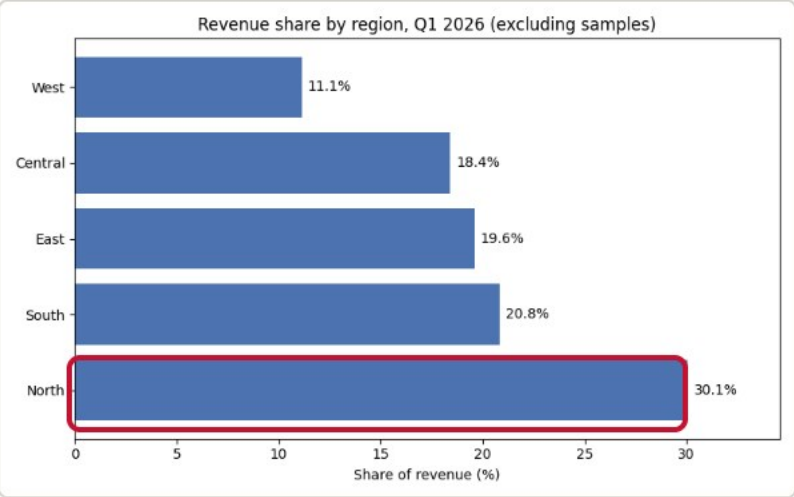
✓ 五道题参考答案全部 1.0 · 空答案 0

⚠ 错误答案：都取自 agent 真犯过的错

最大的在底部

0 分

`mutants/largest_at_bottom`

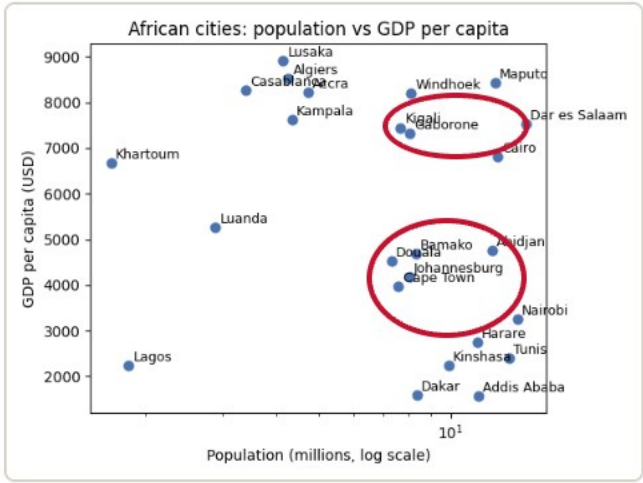


× `test_s2_largest_share_at_the_top`

城市名重叠

1.0

`mutants/label_pileup`



- 数值 ✓
- 25 个标签 ✓
- 对数轴 ✓
- 尺寸 ✓

没有一条检查看文字有没有压在一起



实验报告 Harbor

部署
baseline
改进
出题
Harbor
迭代
踩坑

确定性检查管得到什么

错误类别	确定性检查能不能判
没出图	能
数据错	已知题能
设计不符	大部分能
可读性差	只能部分 量得出重叠、裁切 · 人能不能读是感知判断

每道题的检查只管这一道

→ 私有集需要一个不看题目的裁判

确定性检查

+

VLM 裁判

作业要同时做这两样



实验报告 Harbor

Part 4：四处改动

来自：自建题 · 5 个漏 5 个

① 可读性：不问模型，直接测量

全从重放出的图对象里算

- 文字重叠
- 被画布裁掉
- 对比度太低
- 画成背景色
- 坐标区被挤扁

数字刻度轻微贴边：不算 不排除的话，种子集多 20 个误报

来自：营收占比题

② 排序方向

柱子的排序方向
改用代码查

来自：run 016

③ 图例规则

写反的图例规则
修掉

来自：082 · 自建题误报

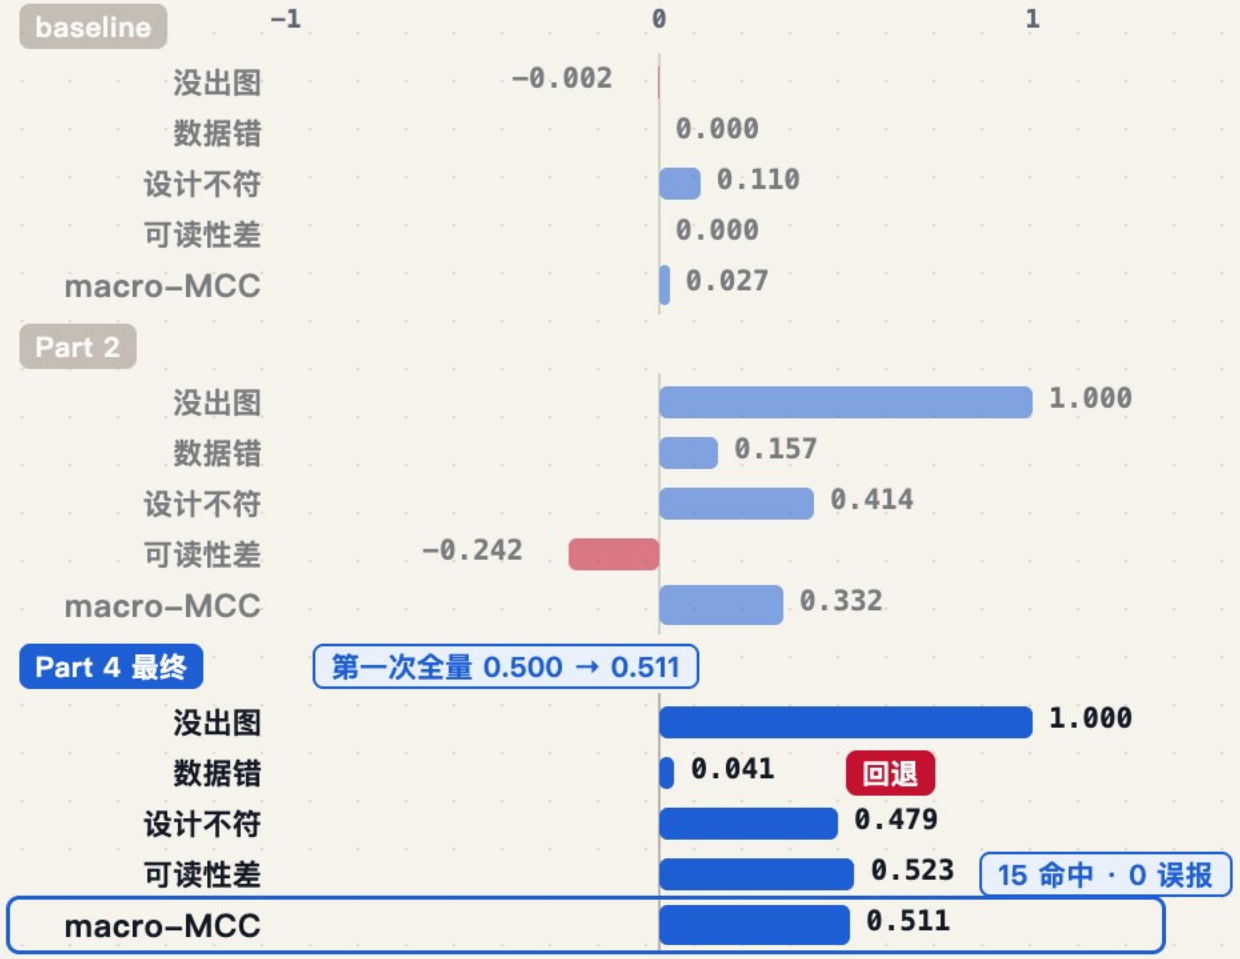
④ 给裁判的材料

测量结果不截断
报实际画出来的颜色
不要自己算数 · 排序交给规则



实验报告 Part 4

种子集 macro-MCC：0.027 → 0.332 → 0.511



自建题 macro-MCC



数据错：回退

0.157 → 0.041

误报 15 → 12 · 命中 9 → 5

自建题 · 可读性差

1.000

15 个 · 我自己标的 · 只能说没找到反例



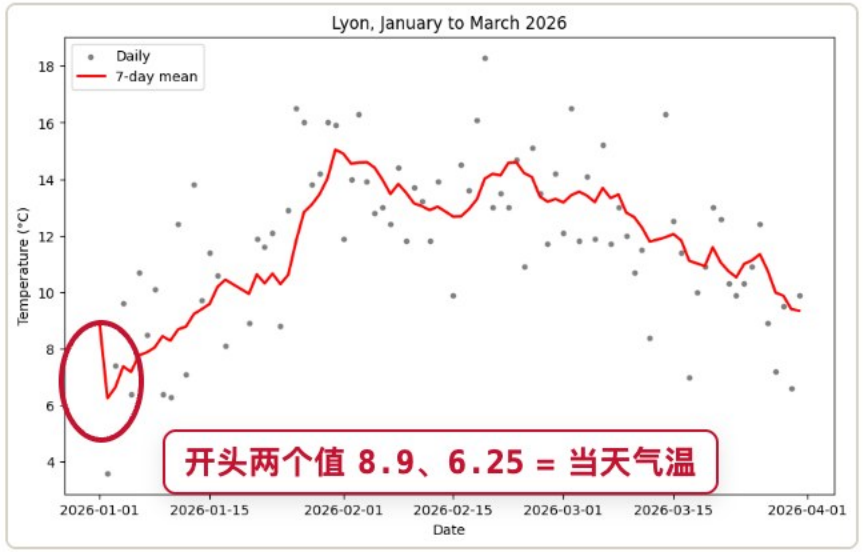
开发日志 分数总表

部署
baseline
改进
出题
Harbor
迭代
踩坑

剩下的错：一个漏报，一个误报

漏报 · 数据错

里昂气温 · GLM `lyon-rolling-temperature`

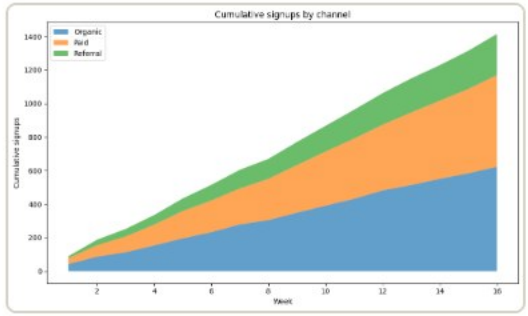


要算一下才看得出 · 可裁判被告知别算数

补一条规则：前六个值必须为空 这次没做

误报 · 设计不符

累计注册 · GLM `cumulative-signups`



裁判
Qwen3-VL 30B

判这条要求被违反

裁判 JSON · 它说违反的要求

```
Stack channels from bottom to top in the order
Organic, Paid, Referral
```

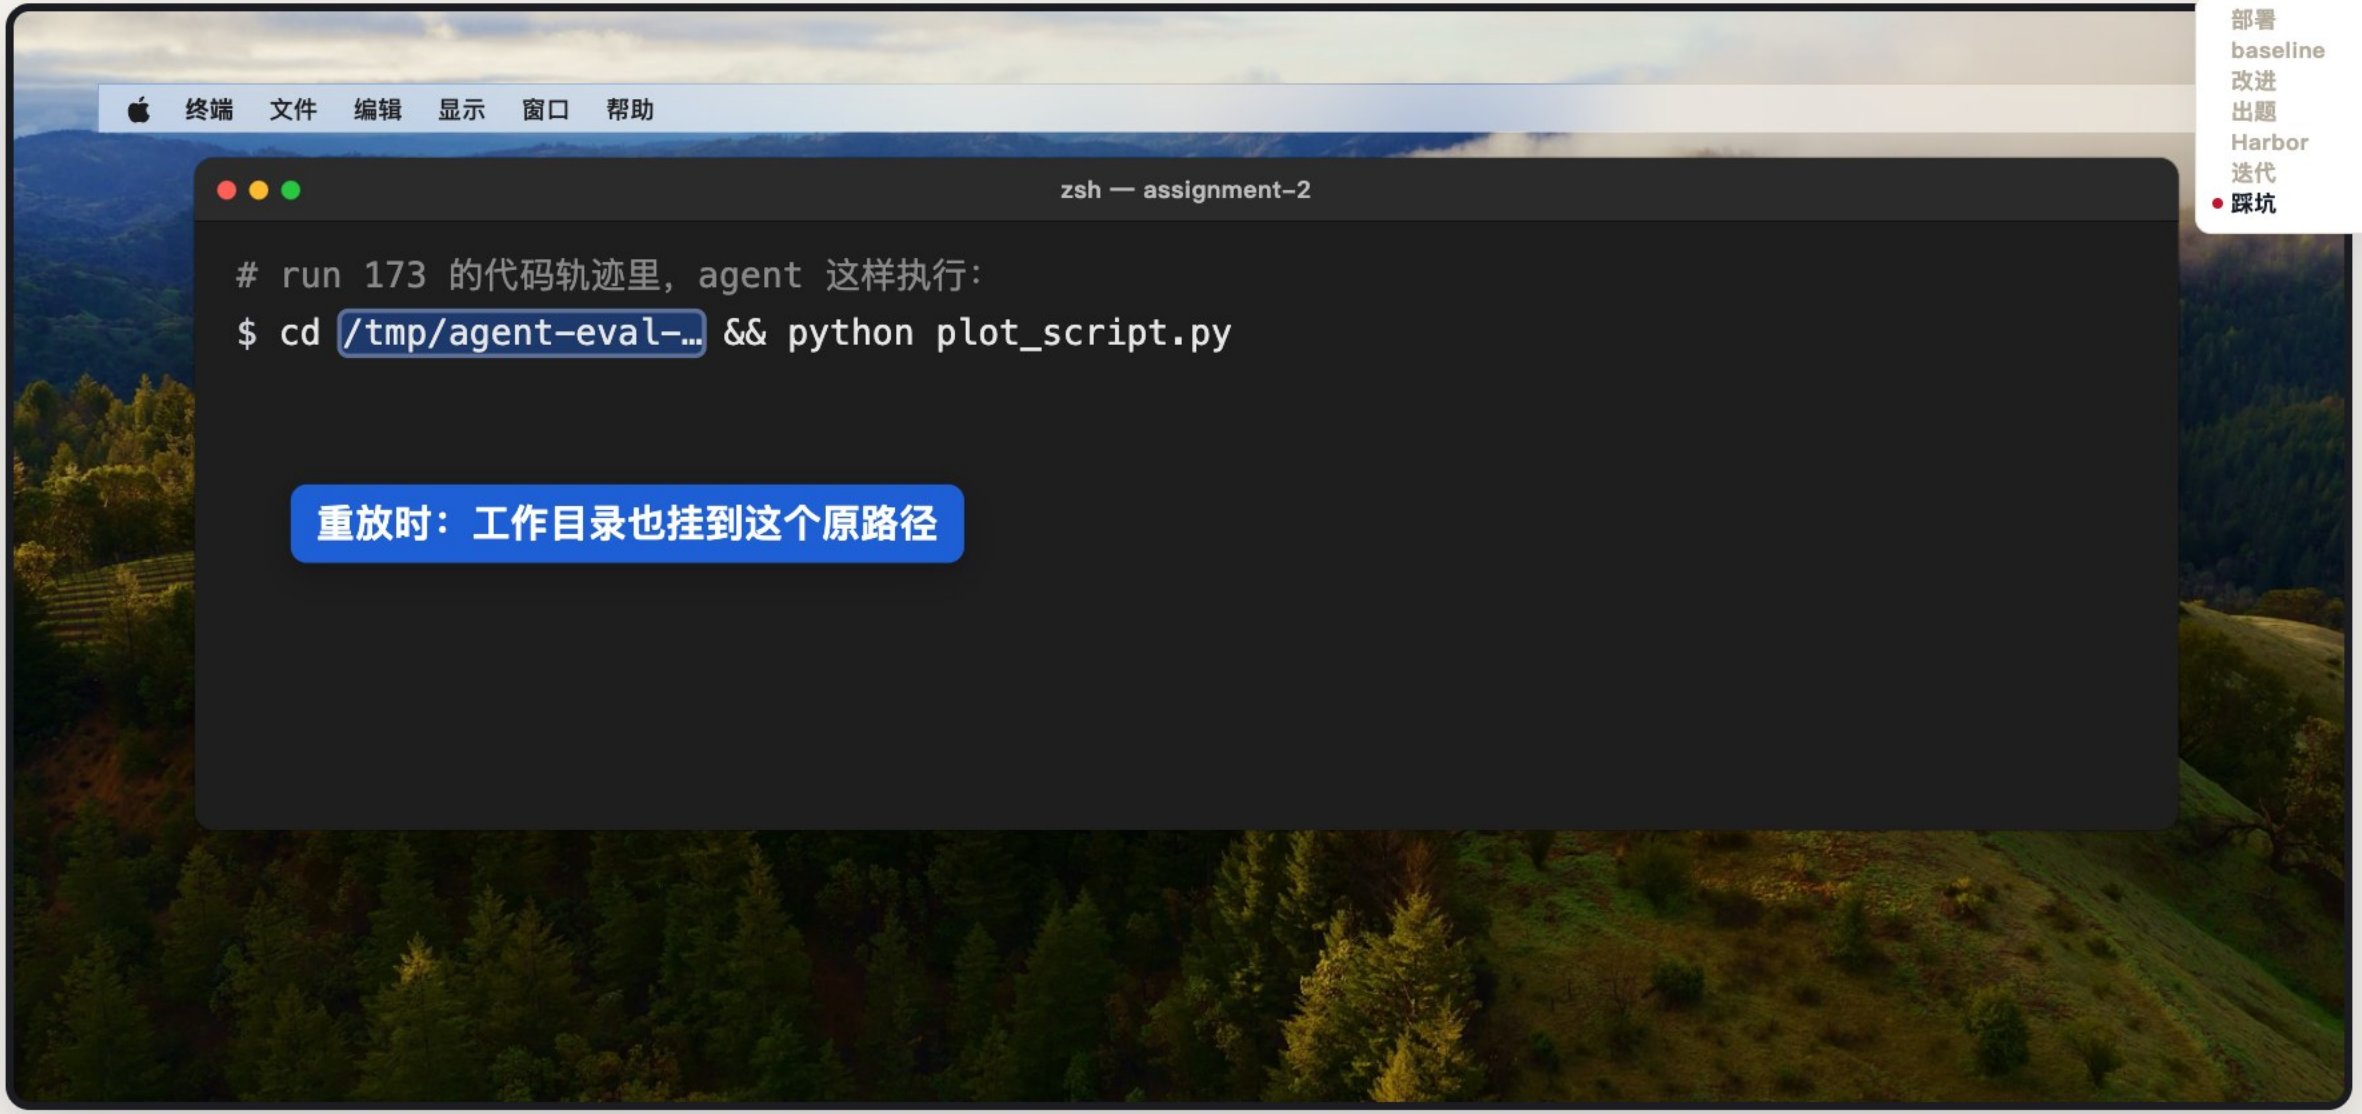
✕ 矛盾

它自己引用的测量值

```
"legend": ["Organic", "Paid", "Referral"]
```



实验报告 Part 4



部署
baseline
改进
出题
Harbor
迭代
踩坑



开发日志 · 坑

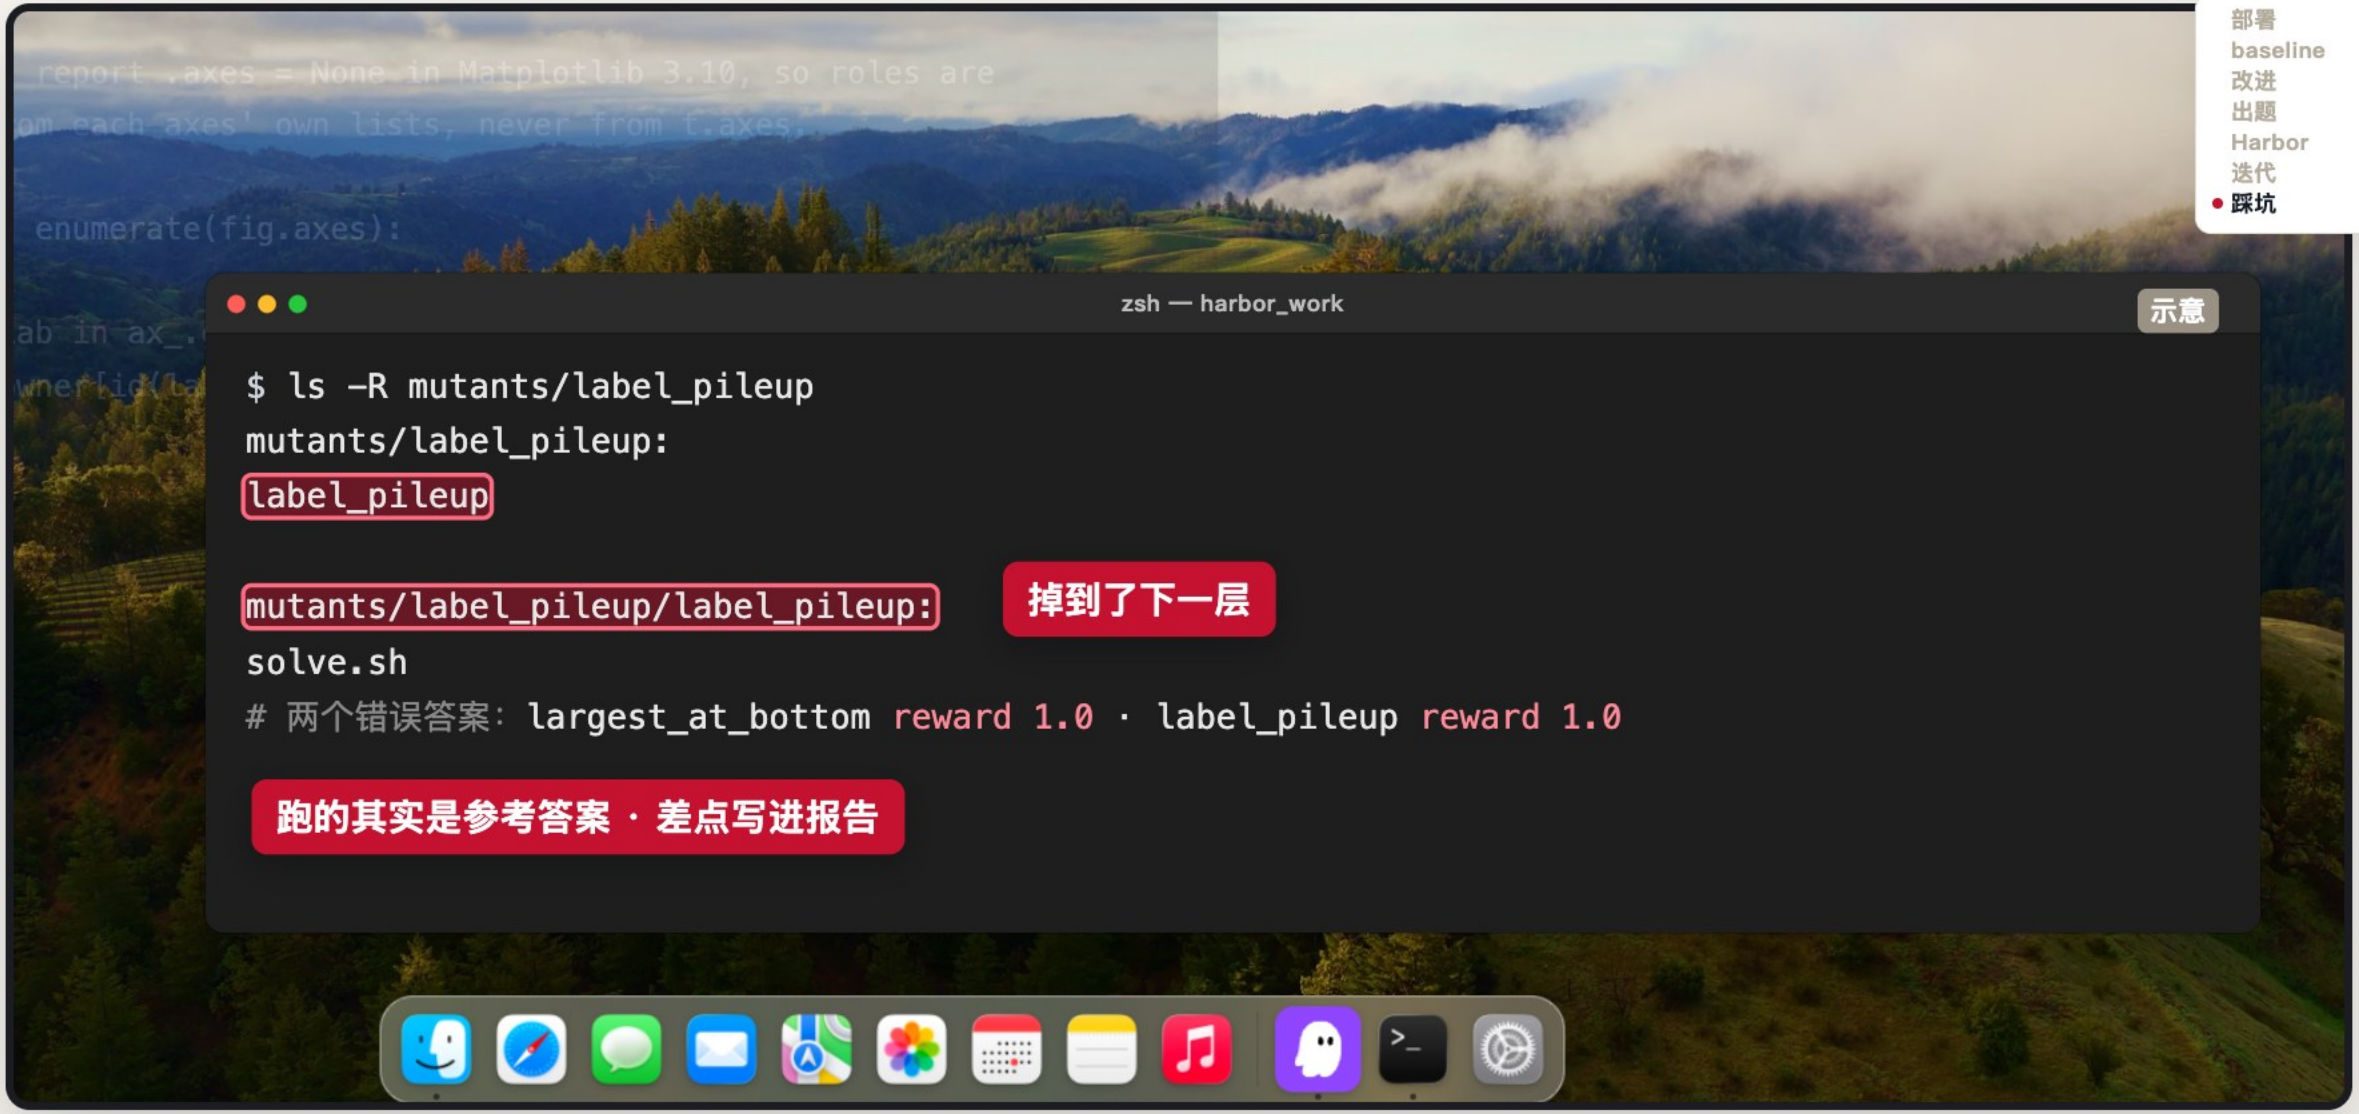
部署
baseline
改进
出题
Harbor
迭代
踩坑





开发日志 · 坑

部署
baseline
改进
出题
Harbor
迭代
踩坑





开发日志 · 坑

弱裁判下做评测：六条原则

1. 能算的，不交给模型
2. 给它看测量结果
3. 别让弱裁判做算术
4. 问题要具体、要结构化
5. 分数变化要说清来源
6. 确定性检查有盲区

第 6 条

确定性检查有盲区

能骗过检查拿满分的错误答案



实验报告