彻底搞懂

从监督微调到策略梯度

全长 31 分钟 | 建议先收藏

这一讲：强化学习基础

上一讲片尾

下一讲：强化学习基础

从自己的试跑里学 · 专家迭代 · 重新加权

监督微调 → 冷启动检查点 → 强化学习

模型自己跑 · 只留通过的 = 专家迭代

奖励越高 → 梯度权重越高

强化学习三讲

- 第 9 讲 这一讲 **策略梯度**
- 第 11 讲 进阶算法
- 第 12 讲 强化学习系统

② 猜数字

③ 监督微调的三个局限

④ 生成打分和更新

⑤ 把交互写成轨迹

⑥ 专家迭代和 ReST

⑦ 策略梯度

⑧ 基线和优势

⑨ GRPO 和 DrGRPO



课件 p.1

贯穿全讲的例子：猜数字

环境

11

藏着的数

agent

四次机会

1 2 3 4 5 6 7 **8** 9 10 11 12 13 14 15 16

每次切一半

二十个问题 · Wordle 最佳首猜：道理相似

第一条	猜 8	往上	猜 12	往下	猜 10	往上	猜 11	猜中 · 奖励 1
第二条	猜 4	往上	猜 8	往上	猜 12	往下	猜 11	猜中 · 奖励 1
第三条	猜 16	往下	猜 8	往上	猜 9	往上	猜 10	超时 · 奖励 0
第四条	猜 1	往上	猜 2	往上	猜 3	往上	猜 4	超时 · 奖励 0

前两条动作不同，结果一样成功



课件 p.2（中文重绘）

奖励：就是一个数

								奖励
第一条	猜 8	往上	猜 12	往下	猜 10	往上	猜 11	猜中 · 奖励 1	1
第二条	猜 4	往上	猜 8	往上	猜 12	往下	猜 11	猜中 · 奖励 1	1
第三条	猜 16	往下	猜 8	往上	猜 9	往上	猜 10	超时 · 奖励 0	0
第四条	猜 1	往上	猜 2	往上	猜 3	往上	猜 4	超时 · 奖励 0	0

SWE-bench · 全部单元测试

全过 → 1

没全过 → 0

也可以记：通过测试的比例



示意

RLVR · 可验证奖励

奖励要么 0 要么 1



这一讲的方法：奖励是任意实数也适用



课件 p.2（中文重绘）

回顾：在示范上做监督微调

历史	→	目标	→	历史	→	目标	→	历史	→	目标	→	历史	→	目标
提示		猜 8		往上		猜 12		往下		猜 10		往上		猜 11

$$\mathcal{L}_{\mathrm{SFT}} = -\Sigma_t \log \pi_\theta(a_t^* \mid h_{1:t})$$

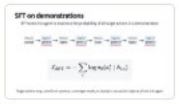
每一步给示范动作打高分 · 对数概率加起来、取负号就是损失

人

更强的模型

agent 自己的成功轨迹

这一讲后面就会用到



课件 p.3（中文重绘）

① 任务错位
示范的概率，不等于做成的概率

② 数据错位
也想从不够好的数据里学

③ 曝光偏差
训练时没见过自己犯的错

示范 第一条	猜 8	往上	猜 12	往下	猜 10	往上	猜 11	猜中 · 奖励 1
另一条成功 第二条	猜 4	往上	猜 8	往上	猜 12	往下	猜 11	猜中 · 奖励 1

猜 12 → 往下 → 猜 13 ✕

猜 8 → 往上 → 比 8 小的数 ✕

猜 8、往上之后，示范是猜 12；没被示范的数： 示意

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16

更小的数

更大、没被示范的数

损失 = 损失

一样

监督微调眼里，一样糟



课件 p.4（中文重绘）

① **任务错位**
示范的概率，不等于做成的概率

② **数据错位**
也想从不够好的数据里学

③ **曝光偏差**
训练时没见过自己犯的错

示范 第一条	猜 8	往上	猜 12	往下	猜 10	往上	猜 11	猜中 · 奖励 1
其他候选 第二条	猜 4	往上	猜 8	往上	猜 12	往下	猜 11	猜中 · 奖励 1
第三条	猜 16	往下	猜 8	往上	猜 9	往上	猜 10	超时 · 奖励 0
第四条	猜 1	往上	猜 2	往上	猜 3	往上	猜 4	超时 · 奖励 0

提高这些动作的概率 ✕

以后别这么走 强化学习

监督微调做不到，强化学习可以



课件 p.5（中文重绘）

① 任务错位
示范的概率，不等于做成的概率

② 数据错位
也想从不够好的数据里学

③ 曝光偏差
训练时没见过自己犯的错

训练用的示范 第一条

猜 8 | 往上 | 猜 12 | 往下 | 猜 10 | 往上 | 猜 11 | 猜中 · 奖励 1

固定的、别处来的历史

生成时

猜 8 | 往上 | 猜 2 | ?

自己一个个生成
接下来的历史，它从没见过

自己生成 → 自己学

在自己的错误里学会恢复

在线策略

⚖ 它一般是好事

好处

- 面对自己的错误
- 监督对得上

代价

- 效率

离策略：强化学习下一讲



课件 p.6（中文重绘）

强化学习：生成、打分、更新



任务错位	训练目标直接就是期望奖励	✓
数据错位	从所有轨迹学：往高奖励靠、躲开低奖励	✓
曝光偏差	轨迹自己生成（在线策略），学会从错误里恢复	✓

大约三四年前

重复 · 陷进循环

↓ 后训练最后加一步强化学习



课件 p.7（中文重绘）

agent 和环境的循环



场景	观察	动作	奖励
文本生成	到目前为止的 token	下一个 token	评判模型给的分
网页 agent	渲染出来的页面	点击、输入、滚动	完成了几个子任务
猜数字	往上、往下或猜中	下一次猜的数	猜中记 1，否则记 0

后台数据库

agent 看不到

只看得到当前页面

只在任务结束时给一次



中间每一步都给 · 也适用



课件 p.9（中文重绘）

agent 只靠历史做决定



历史 h_2

策略看到的全部

环境状态 · 藏着的数 11

策略看不到

$$h_t = (o_0, a_0, o_1, \ldots, o_t) \qquad \pi_\theta(a_t \mid h_t)$$

历史 → agent 框架 → 下一个 token 的分布 → 环境里的动作



课件 p.10（中文重绘）

把每一步的奖励也放进去

提示	→	猜 8	→	往上	→	猜 12	→	往下	→	猜 10	→	往上	→	猜 11	→	猜中
o_0		a_0		o_1		a_1		o_2		a_2		o_3		a_3		o_4
				$r_1 = 0$				$r_2 = 0$				$r_3 = 0$				$r_4 = 1$

轨迹 τ_1 · 整条轨迹奖励 = 0 + 0 + 0 + 1 = 1

$$\tau = (o_0, a_0, r_1, o_1, \ldots, a_{T-1}, r_T, o_T) \qquad R(\tau) = \sum_{t=1}^{T} r_t$$

每一步都可能有奖励



⇄

只在末尾 猜数字 · 二值 0 / 1





课件 p.11（中文重绘）

轨迹的概率：策略 × 环境



蓝格：策略给的　灰格：环境给的

$$p_\theta(\tau \mid x) = \prod_t \pi_\theta(a_t \mid h_t)\, P(o_{t+1}, r_{t+1} \mid h_t, a_t, x)$$

环境：不知道，但能采样

环境 ? → 往上　猜中

亚马逊网站上点一下 → 会看到什么？

只能去试、看会发生什么

试一下 → 看结果 → 间接反馈

很耗算力



课件 p.12（中文重绘）

目标：期望奖励最大

$$J(\theta) = \mathrm{E}_{\tau \sim p_\theta(\cdot|x)}[R(\tau)]$$

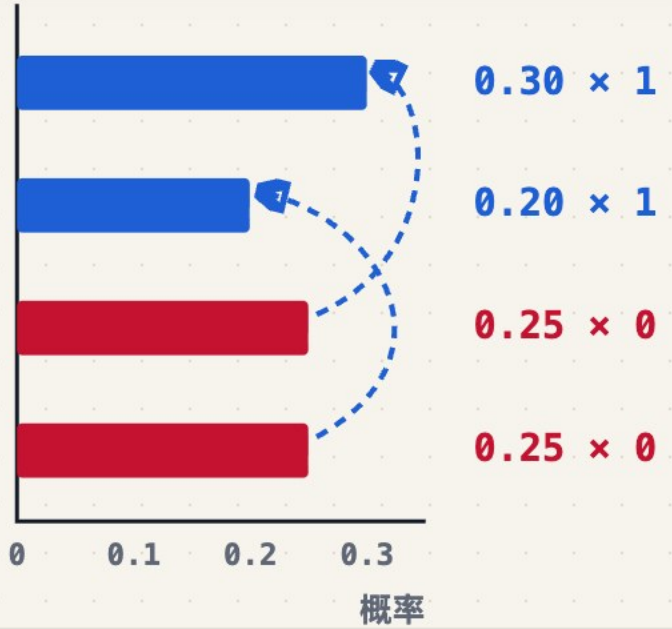
反复跑这道题 · **奖励取平均** · 训练就是调参数，让它变大

0.30 × 1 + 0.20 × 1 + 0.25 × 0 + 0.25 × 0

期望奖励 = 0.50

第一条	猜 8	→ 往上	→ 猜 12	→ 往下	→ 猜 10	→ 往上	→ 猜 11	猜中 · 奖励 1
第二条	猜 4	→ 往上	→ 猜 8	→ 往上	→ 猜 12	→ 往下	→ 猜 11	猜中 · 奖励 1
第三条	猜 16	→ 往下	→ 猜 8	→ 往上	→ 猜 9	→ 往上	→ 猜 10	超时 · 奖励 0
第四条	猜 1	→ 往上	→ 猜 2	→ 往上	→ 猜 3	→ 往上	→ 猜 4	超时 · 奖励 0

一半的概率拿零奖励

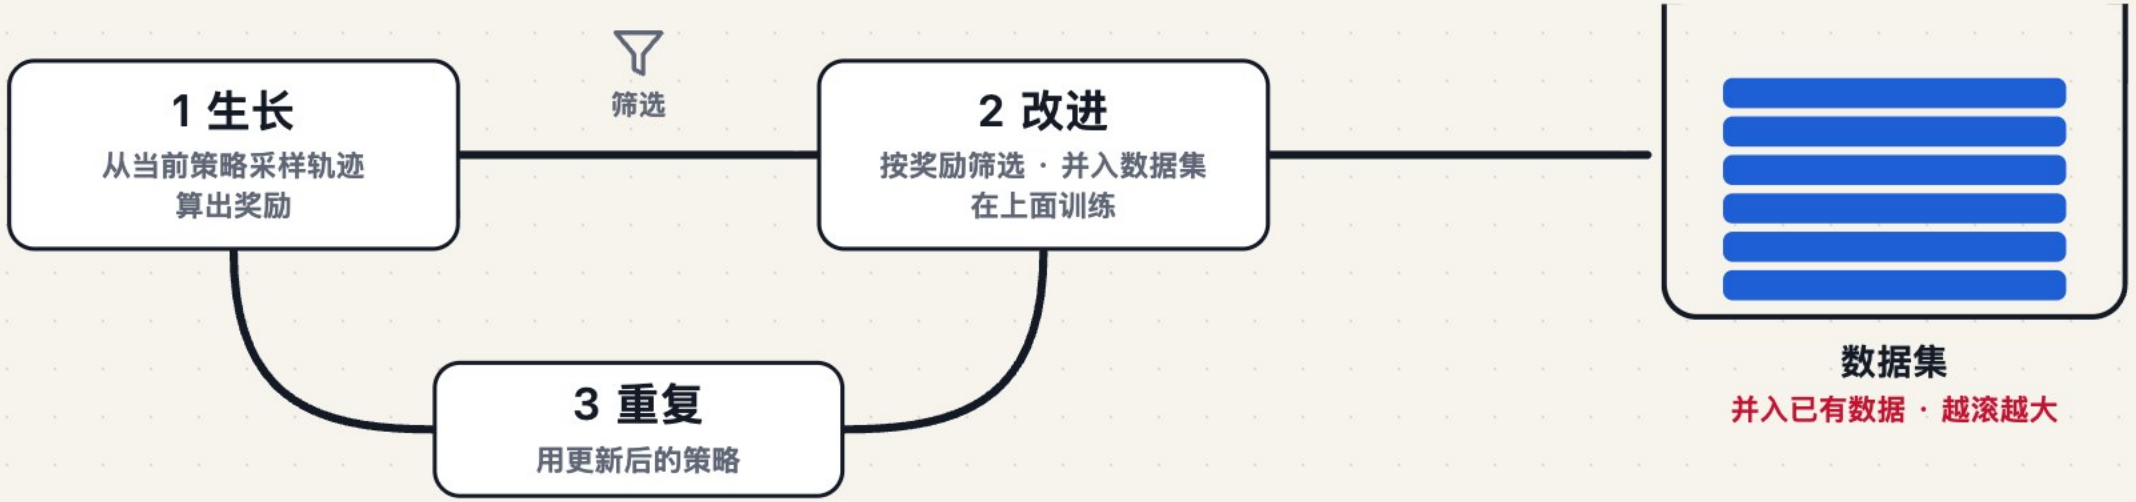


低奖励轨迹 ● ● 概率 → ● ● ● 高奖励轨迹



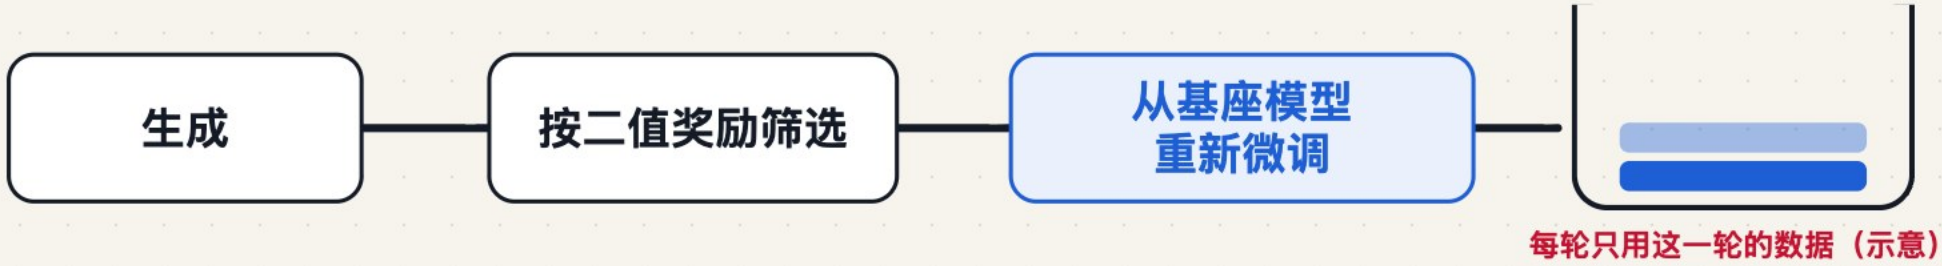
课件 p.13（中文重绘）

ReST：生长 → 改进 → 重复



ReST-EM

EM = 期望最大化





课件 p.15（中文重绘）

损失 = 成功轨迹上的监督微调损失

采样轨迹 → 算奖励 → 筛选 → 监督微调



下一轮的训练集

前面的监督微调损失（课件 p.3）

$$L_{SFT} = -\sum_t log\ \pi_\theta(a^*_t \mid h_{1:t})$$

ReST 的损失（课件 p.16）

$$L_{ReST} = -\sum_{\tau:\ R(\tau)=1} \sum_t log\ \pi_\theta(a_t \mid h_t)$$

严格说不叫强化学习，但很像

数据是模型生成的 · 怎么更新由奖励决定

简单又挺有效的基线

设施全能复用 · 奖励二值时尤其合适



课件 p.16、p.3（中文重绘）

期望奖励：为什么不能直接反向传播

参数 θ → 策略 $\pi_\theta(a \mid h)$ × 采样 动作 a × 环境 观察 o、奖励 r

× 第一：动作是采样出来的

改的是概率，采到哪个动作不变

导数几乎处处为零

× 第二：世界通常不可微

一个单元测试，对代码求导？

$$J(\theta) = \sum_{\tau} p_\theta(\tau \mid x) R(\tau)$$

随参数变的只有概率

奖励要等跑完才看得到

经典的解法：策略梯度

REINFORCE
Williams, 1992



课件 p.18（中文重绘）

推导策略梯度：五步

1 $J(\theta) = \mathbb{E}_{\tau \sim p_\theta(\cdot|x)}[\, R(\tau) \,] = \sum_\tau p_\theta(\tau \mid x)\, R(\tau)$

目标：概率 × 奖励的总和

2 $\nabla_\theta J = \sum_\tau \nabla_\theta p_\theta(\tau \mid x)\, R(\tau)$

导数只落在概率上

3 $= \sum_\tau p_\theta(\tau \mid x)\, R(\tau)\, \dfrac{\nabla_\theta p_\theta(\tau \mid x)}{p_\theta(\tau \mid x)}$

乘一个、再除一个

4 $= \sum_\tau p_\theta(\tau \mid x)\, R(\tau)\, \nabla_\theta \log p_\theta(\tau \mid x)$

概率的导数 ÷ 概率
= 对数概率的导数

5 $= \mathbb{E}_{\tau \sim p_\theta(\cdot|x)}[\, R(\tau)\, \nabla_\theta \log p_\theta(\tau \mid x) \,]$

一个能用样本估计的期望



课件 p.19（中文重绘）

和监督微调算的是同一种东西

策略梯度（第五步）

$$\nabla_\theta J = \mathbb{E}_{\tau \sim p_\theta(\cdot|x)}[\, R(\tau) \, \boxed{\nabla_\theta \log p_\theta(\tau \mid x)} \,]$$

监督微调的损失（第三部分）

$$\mathcal{L}_{SFT} = -\sum_t \boxed{\log \pi_\theta(a_t^* \mid h_{1:t})}$$

都是一串 token 的对数概率，对模型参数求导

整个推导，对语言模型和环境没做任何假设



课件 p.19（中文重绘）

用采样代替期望

$$\nabla_\theta J = \mathbb{E}_{\tau \sim p_\theta(\cdot|x)}[\, R(\tau)\ \nabla_\theta \log p_\theta(\tau \mid x)\,]$$

把期望换成采样到的轨迹

↓

$$\tau \sim p_\theta(\cdot \mid x), \qquad \widehat{\nabla_\theta J} = R(\tau)\ \nabla_\theta \log p_\theta(\tau \mid x) = R(\tau) \sum_t \nabla_\theta \log \pi_\theta(a_t \mid h_t)$$

严格说，要对几条轨迹取平均

动作是 agent 自己采的，不是示范

$\tau \sim p_\theta(\cdot \mid x)$

当前策略跑出来的轨迹

采样：策略加环境

$R(\tau)$

任务层面的评估

由环境给

$\nabla_\theta \log \pi_\theta(a_t \mid h_t)$

改变采到的动作的概率

和监督微调一样算



课件 p.20（中文重绘）

第一笔：轨迹里环境那部分怎么办

$p(o_0|x)$ 第一个观察 + $\pi_\theta(a_0|h_0)$ 策略选 8 + $P(o_1,r_1|h_0,a_0,x)$ 环境回往上 + $\pi_\theta(a_1|h_1)$ 策略选 12 + $P(o_2,r_2|h_1,a_1,x)$ 环境回往下 …

常数

$$\log p_\theta(\tau \mid x) = \sum_t \log P(o_t, r_t \mid h_t, a_t, x) + \sum_t \log \pi_\theta(a_t \mid h_t)$$

$$= const + \sum_t \log \pi_\theta(a_t \mid h_t)$$

$$\nabla_\theta \log p_\theta(\tau \mid x) = \sum_t \nabla_\theta \log \pi_\theta(a_t \mid h_t)$$

剩下的只是每个动作对数概率的梯度之和



课件 p.21（中文重绘）

第二笔：一个动作是好几个 token

课上有人问： 动作本身是一串 token，怎么和轨迹对上？

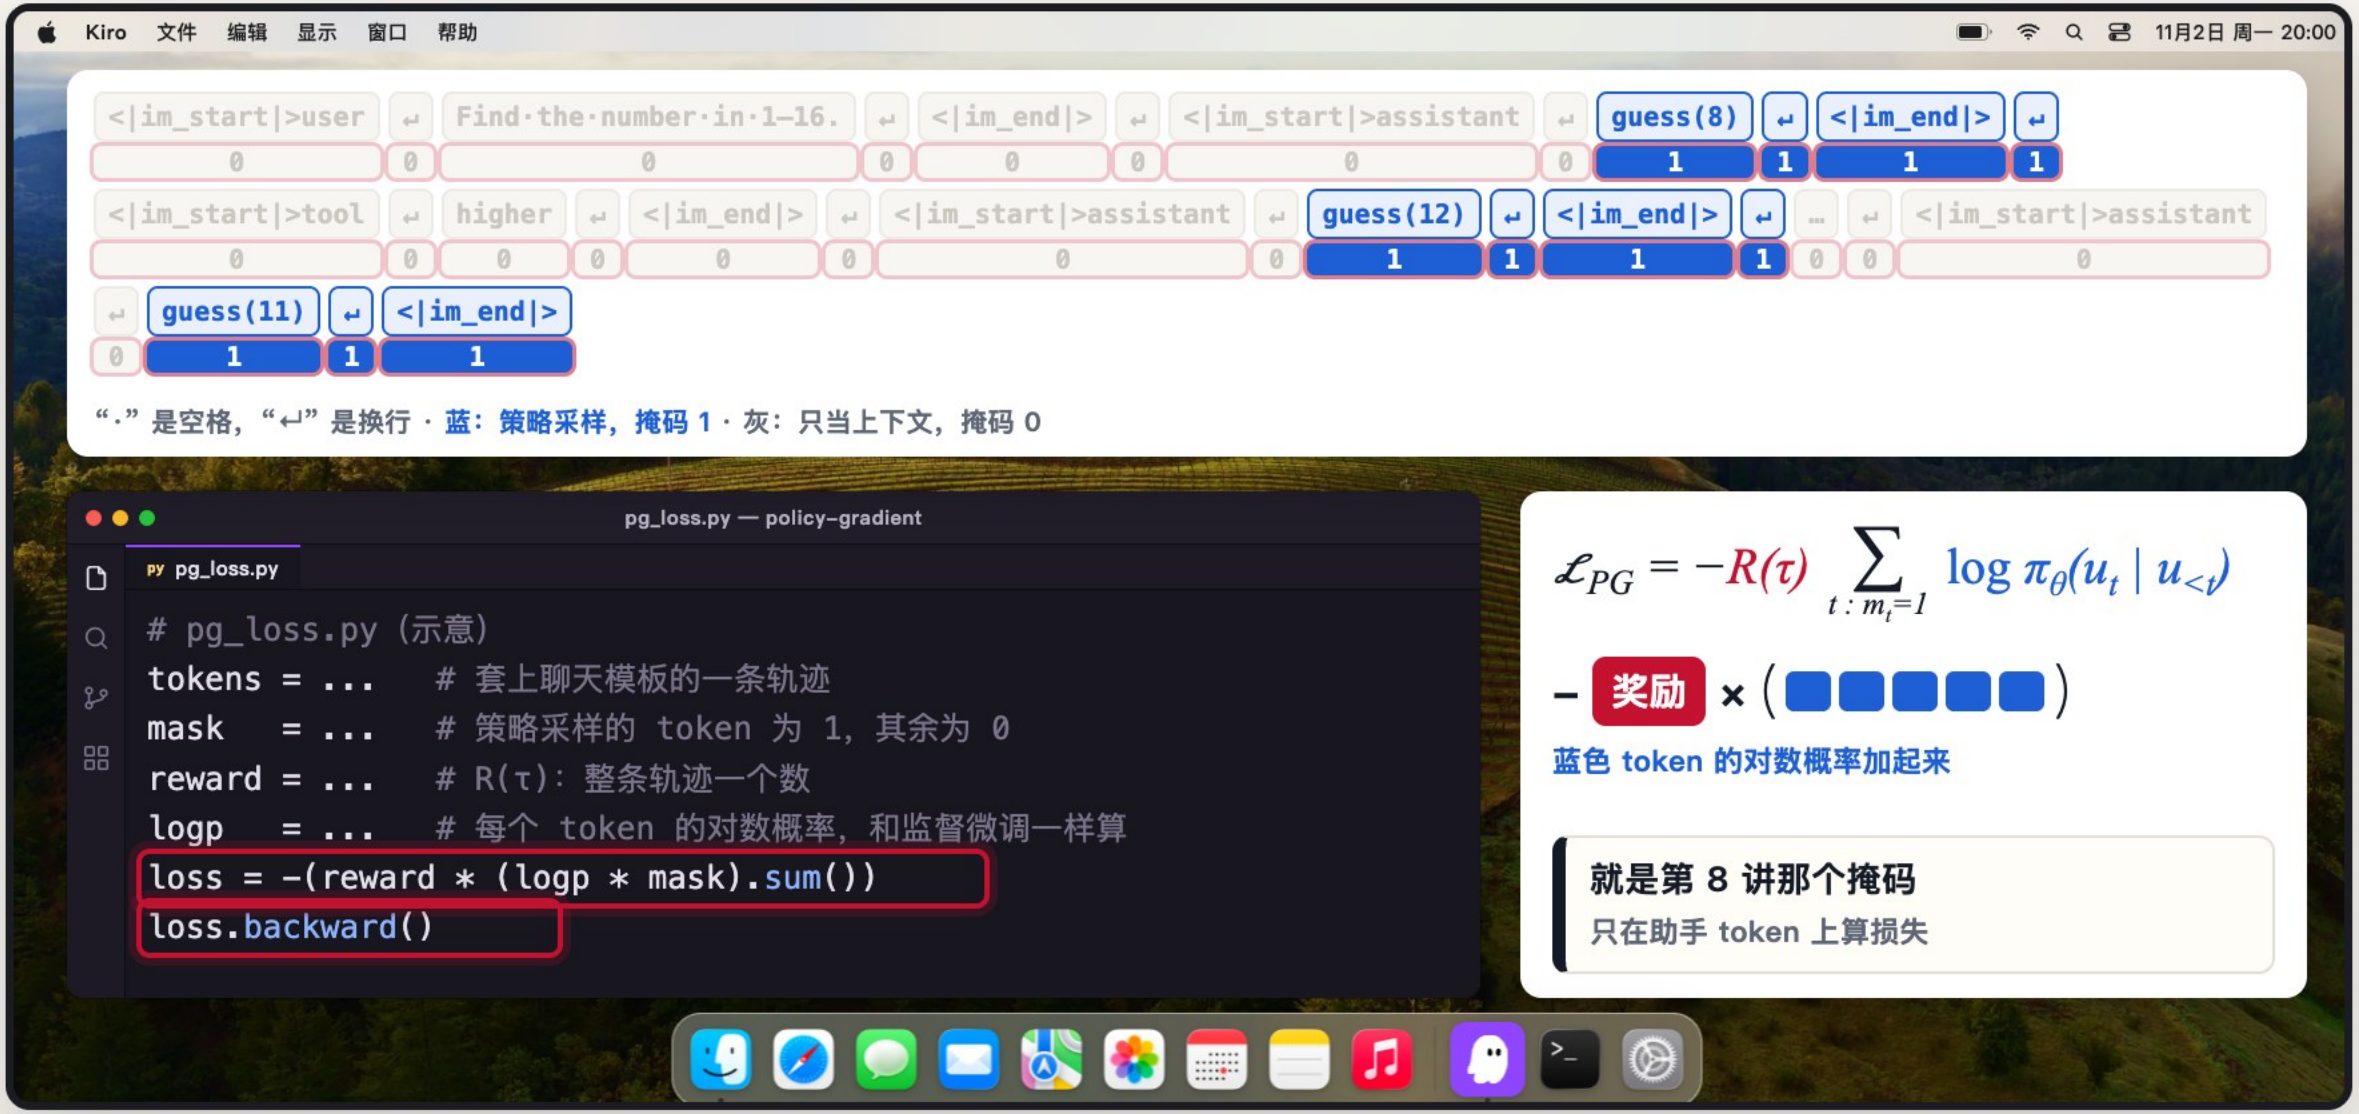


token 切分和条长：示意

$$a_t = (u_{t,1}, \ldots, u_{t,m_t}), \qquad \nabla_\theta \log \pi_\theta(a_t \mid h_t) = \sum_{k=1}^{m_t} \nabla_\theta \log \pi_\theta(u_{t,k} \mid h_t, u_{t,<k})$$



课件 p.21（中文重绘）


Kiro 文件 编辑 显示 窗口 帮助
11月2日 周一 20:00
<|im_start|>user ↵ Find·the·number·in·1–16. ↵ <|im_end|> ↵ <|im_start|>assistant ↵ guess(8) ↵ <|im_end|> ↵
0 0 0 0 0 0 0 1 1 1 1
<|im_start|>tool ↵ higher ↵ <|im_end|> ↵ <|im_start|>assistant ↵ guess(12) ↵ <|im_end|> ↵ … ↵ <|im_start|>assistant
0 0 0 0 0 0 0 0 1 1 1 1 0 0 0
↵ guess(11) ↵ <|im_end|>
0 1 1 1
“·” 是空格，“↵” 是换行 · 蓝：策略采样，掩码 1 · 灰：只当上下文，掩码 0
pg_loss.py — policy-gradient
py pg_loss.py
pg_loss.py（示意）
tokens = ... # 套上聊天模板的一条轨迹
mask   = ... # 策略采样的 token 为 1，其余为 0
reward = ... # R(τ)：整条轨迹一个数
logp   = ... # 每个 token 的对数概率，和监督微调一样算
loss = -(reward * (logp * mask).sum())
loss.backward()
$\mathcal{L}_{PG} = -R(\tau) \sum_{t\,:\,m_t=1} \log \pi_\theta(u_t \mid u_{<t})$
– 奖励 × ( )
蓝色 token 的对数概率加起来
就是第 8 讲那个掩码
只在助手 token 上算损失



课件 p.22（中文重绘）

训练循环：一圈圈转

① 收集
采一批题，让 agent 跑

② 评估
给每条轨迹算奖励

③ 构造损失
用奖励给对数概率加权

④ 更新
反向传播，改参数

策略
新的策略

收集：每道题一条

- 题 1 — 一条轨迹
- 题 2 — 一条轨迹
- 题 3 — 一条轨迹

批大小 = 题的个数

$$\mathcal{L}_{PG} = -\sum_i R(\tau_i) \sum_t \log \pi_\theta(a_{i,t} \mid h_{i,t})$$

题 1 ------ 轨迹 轨迹 轨迹 轨迹

后面：同一道题好几条 → GRPO



课件 p.23（中文重绘）

二值奖励下，REINFORCE 就是 ReST

第一条 猜 8 → 往上 → 猜 12 → 往下 → 猜 10 → 往上 → 猜 11 → 猜中 · 奖励 1 × 1

第二条 猜 4 → 往上 → 猜 8 → 往上 → 猜 12 → 往下 → 猜 11 → 猜中 · 奖励 1 × 1

第三条 猜 16 → 往下 → 猜 8 → 往上 → 猜 9 → 往上 → 猜 10 → 超时 · 奖励 0 × 0

第四条 猜 1 → 往上 → 猜 2 → 往上 → 猜 3 → 往上 → 猜 4 → 超时 · 奖励 0 × 0

REINFORCE

$$-\sum_i R(\tau_i) \sum_t \log \pi_\theta(a_{i,t} \mid h_{i,t})$$

=

只在成功轨迹上做监督微调

$$-\sum_{i\,:\,R(\tau_i)=1} \sum_t \log \pi_\theta(a_{i,t} \mid h_{i,t})$$

REINFORCE 采一批 → 更新 · 采一批 → 更新 · 采一批 → 更新 · 采一批 → 更新　　完全在线

ReST 攒一大批 → 累积数据集 → 训一轮或几轮　　批量更新



课件 p.24（中文重绘）

奖励应该是相对的

奖励 1　奖励 1　奖励 1　奖励 1

第一条：猜 8 → 往上 → 猜 12 → 往下 → 猜 10 → 往上 → 猜 11 → 猜中 · 奖励 1

每个动作都被加权提高

奖励 0　奖励 0　奖励 0　奖励 0

第三条：猜 16 → 往下 → 猜 8 → 往上 → 猜 9 → 往上 → 猜 10 → 超时 · 奖励 0

基本的 REINFORCE 里：完全不产生梯度

想学会：以后别这么做 （虚线：没有梯度）



九成五的时候拿到 1

剩下那一点：一个很蠢的错

狠狠往反方向推



更新的大小，要看这个策略平时在这道题上做得怎么样



课件 p.26（中文重绘）

优势：这个动作比平时好多少

$$A^{\pi}(h, a) = Q^{\pi}(h, a) - V^{\pi}(h)$$

$Q^{\pi}(h, a)$：选了这个动作之后，平均能拿多少

$V^{\pi}(h)$：照平时的策略走，平均能拿多少

正的：比平时好

负的：比平时差

历史 猜 8 往上 猜 12 往下

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16

还剩两次 ● ●

猜 11

猜错 → 两个候选、一次机会

优势 < 0

$V^{\pi}(h)$

平时能拿多少

0 1

约 2/3 到 1 粗估

猜 10

猜错 → 一个候选、一次机会

优势 > 0

每次都选最好的 → 总能赢 · 在合理的数里随机挑 → 大概三分之二



课件 p.27（中文重绘）

把基线放进策略梯度：改动很小

REINFORCE

每个动作都乘这条轨迹拿了多少

$$\widehat{\nabla_\theta J} = R(\tau)\,\Sigma_t\,\nabla_\theta \log \pi_\theta(a_t \mid h_t)$$

减掉基线

改成乘：比预期多拿了多少

$$\widehat{\nabla_\theta J} = \Sigma_t \underbrace{\boxed{(R(\tau) - b(h_t))}}_{\hat{A}_t}\,\nabla_\theta \log \pi_\theta(a_t \mid h_t)$$

两种写法数值上不相等，但**都是合法的估计**

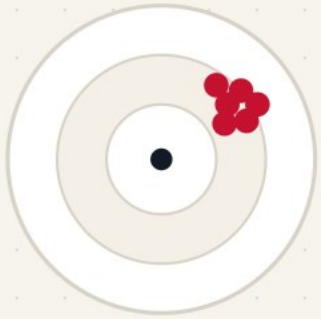
b 怎么选，就得到**不同的算法**

一个常数	后面的老虎机就是	
奖励的滑动平均	随策略变好而调整	
训练一个价值模型 $V_\varphi(h_t)$	actor-critic、PPO · 多一个模型	成本高
同一道题的组内平均	不需要额外的模型 · GRPO	第 ⑨ 部分



课件 p.28（中文重绘）

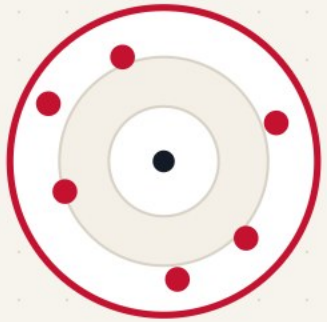
减掉基线，梯度会不会偏?



偏差

平均值离真实值有多远

靶子是示意



方差

每次抽出来的值散得多开

真正要紧的

$$\widehat{\nabla_\theta J} = \Sigma_t \left(R(\tau) - b(h_t)\right) \nabla_\theta \log \pi_\theta(a_t \mid h_t)$$

$$\mathrm{E}[\widehat{\nabla_\theta J}] = \nabla_\theta J - \mathrm{E}[\Sigma_t\, b(h_t)\, \nabla_\theta \log \pi_\theta]$$

$$\mathrm{E}_{a\sim\pi_\theta(\cdot|h)}[b(h)\, \nabla_\theta \log \pi_\theta(a \mid h)]$$

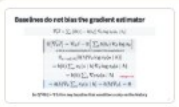
$$= b(h)\, \Sigma_a\, \pi_\theta(a \mid h)\, \nabla_\theta \log \pi_\theta(a \mid h)$$

$$= b(h)\, \Sigma_a\, \nabla_\theta \pi_\theta(a \mid h) \quad \pi\nabla\log\pi = \nabla\pi$$

$$= b(h)\, \nabla_\theta\, \Sigma_a\, \pi_\theta(a \mid h) = b(h)\, \nabla_\theta\, 1 = 0$$

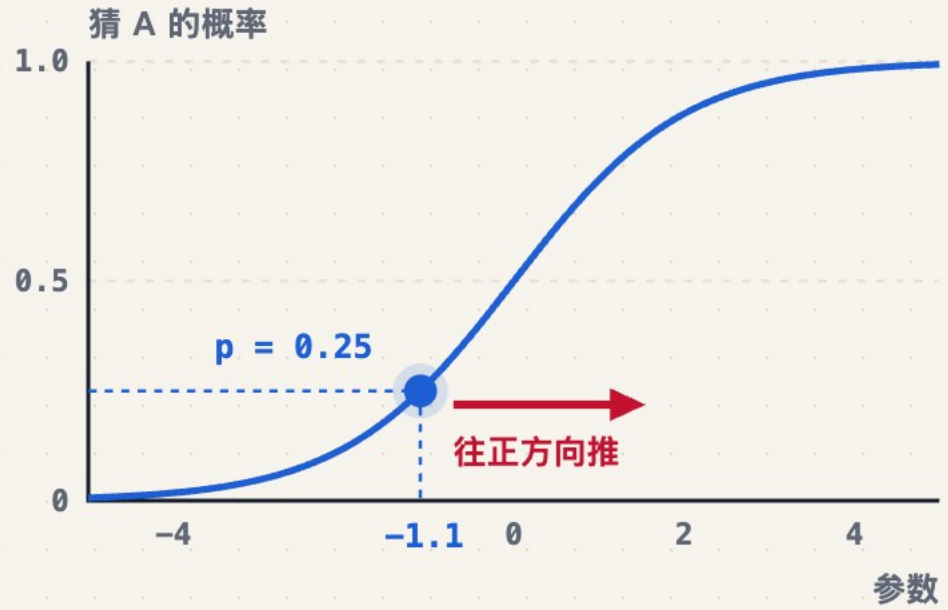
只依赖历史的基线：期望梯度一点不变

- ✓ 一个常数
- ✓ 奖励的滑动平均
- ✓ 价值模型
- ✓ 组内平均



课件 p.29（中文重绘）

双臂老虎机：一个参数、两个动作



猜 A	概率 0.25	奖励 1
猜 B	概率 0.75	奖励 0

真实梯度 = 0.25 × 0.75 + 0.75 × 0 = 0.1875



采到 A · 奖励 1

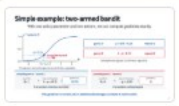
奖励 1 × 斜率 +0.75 = **+0.75**

A 变得更可能

采到 B · 奖励 0

奖励 0 × 斜率 −0.25 = **0**

什么都不发生，和奖励为 0 的轨迹一样



课件 p.30（中文重绘）

加一个基线 0.5

奖励 0 — 基线 0.5 — 奖励 1

比预期差 · 优势 < 0

比预期好 · 优势 > 0

采到 A · 奖励 1

优势 1 − 0.5 = +0.5 × 斜率 +0.75 = **+0.375**

不加基线：+0.75

采到 B · 奖励 0

优势 0 − 0.5 = −0.5 × 斜率 −0.25 = **+0.125**

不加基线：0

失败也学到：该多猜 A

期望 = 0.25 × 0.375 + 0.75 × 0.125

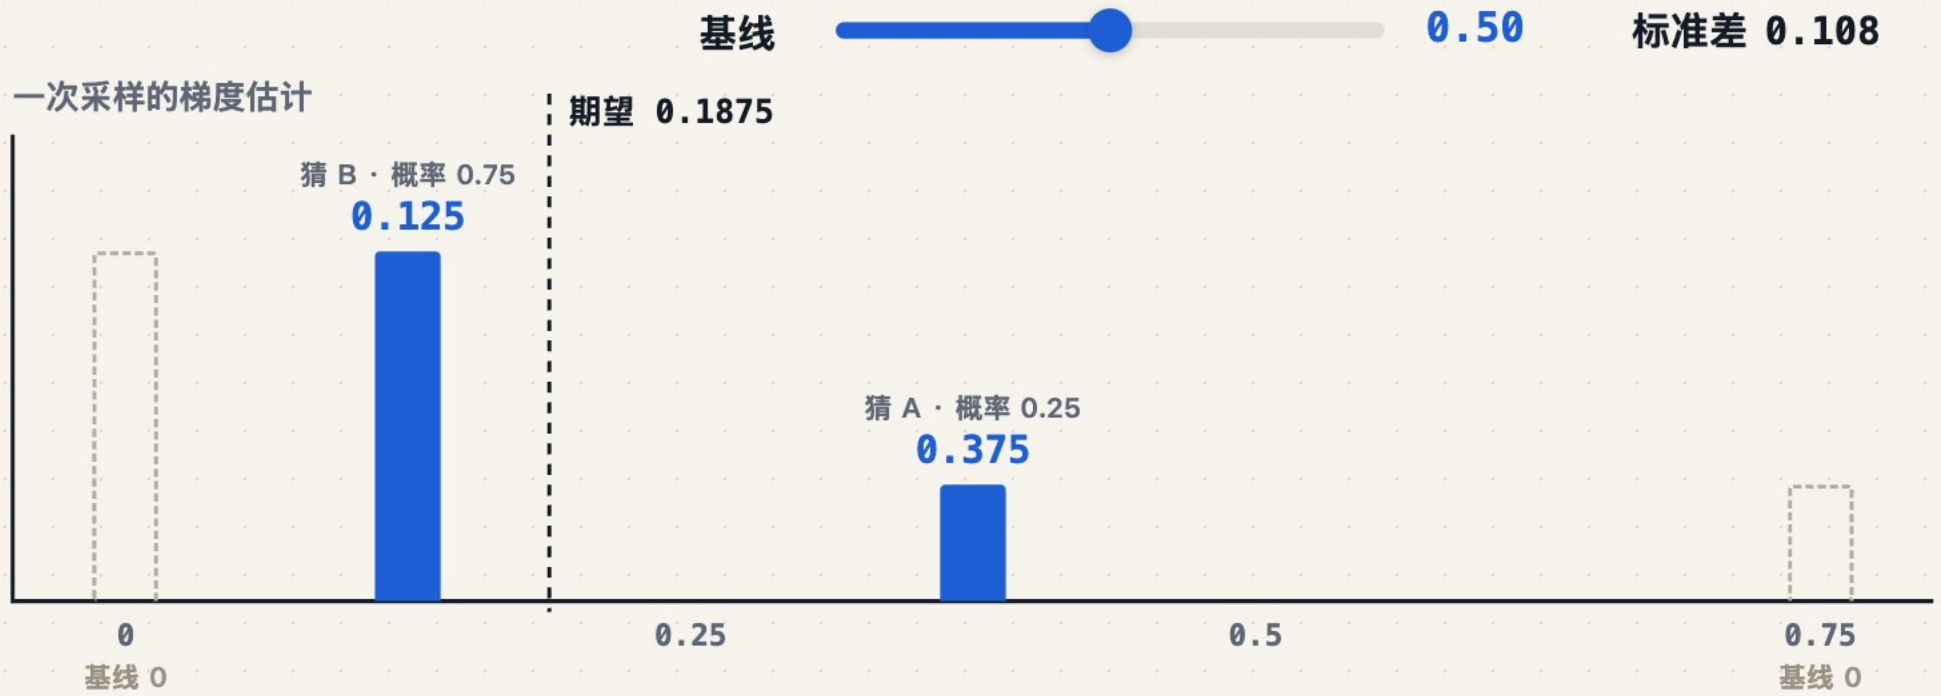
= 0.1875，一点没变



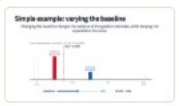


课件 p.31（中文重绘）

改变基线：方差变，期望不变

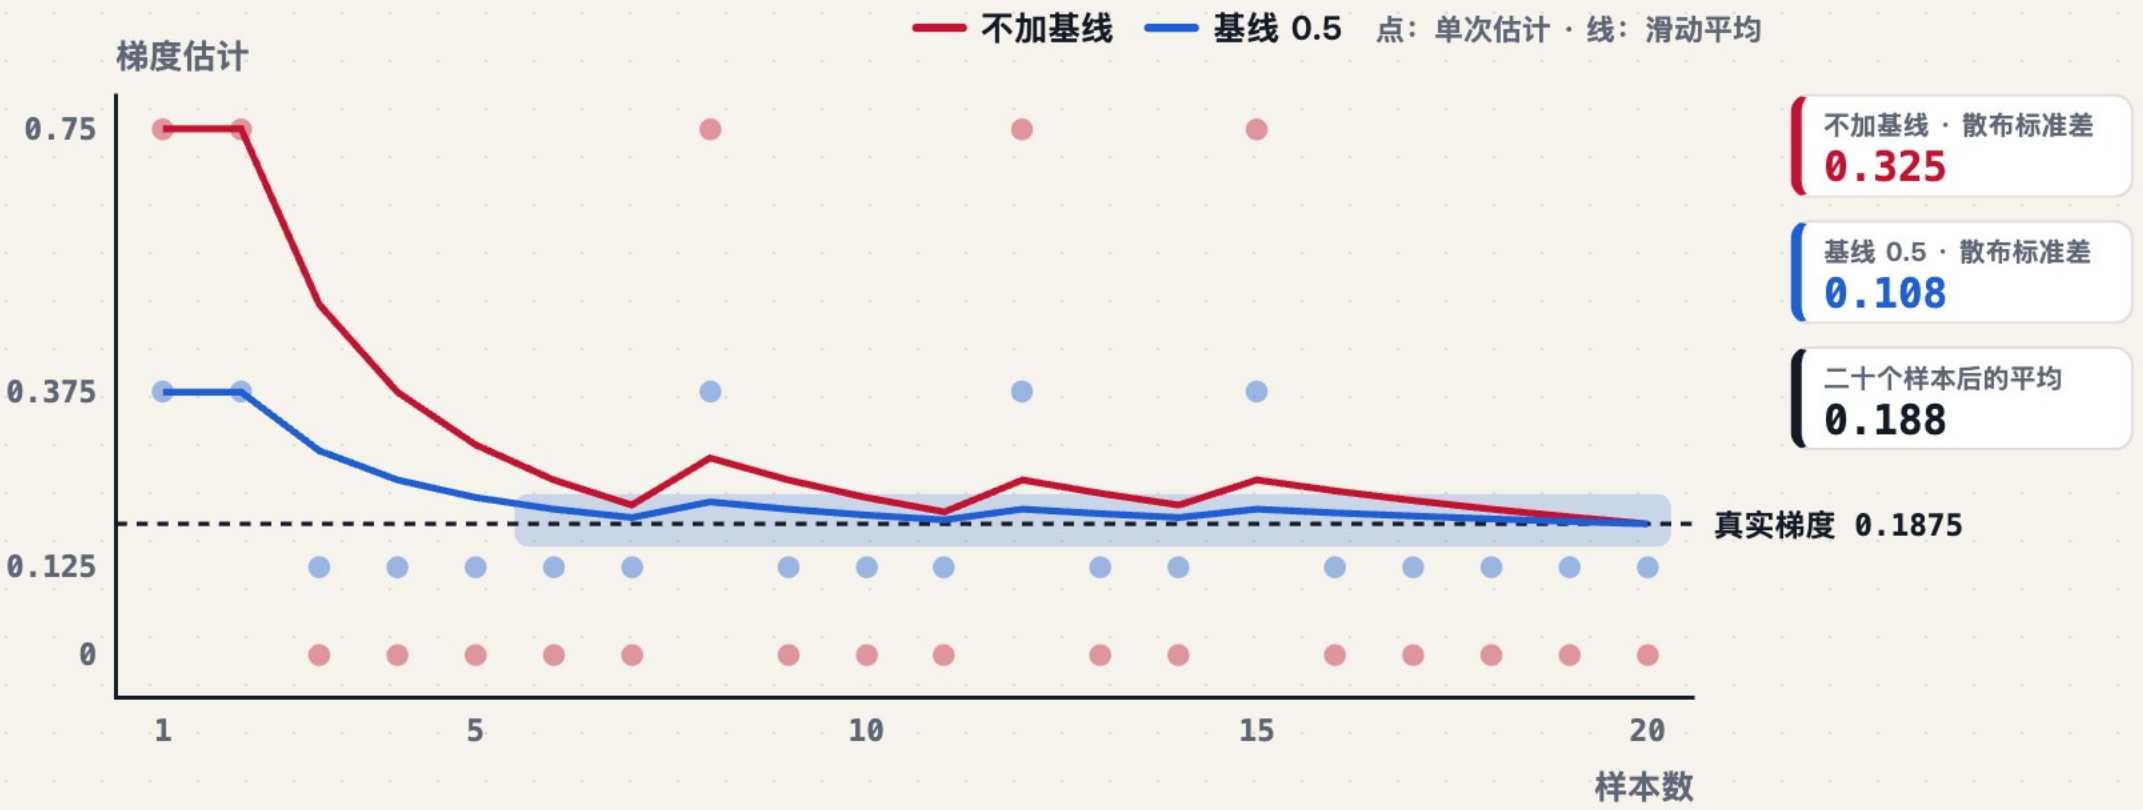


不管拉到哪，都在把参数往正方向推；方差越低，走得越快

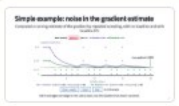


课件 p.32（中文重绘）

反复采样：平均一样，散布不一样



这个直觉，在更复杂的多步决策里同样成立



课件 p.33（按原图读数）

基线帮了什么，还缺什么

帮上了

- ✓ 能把一条轨迹标成比预期好或者差
- ✓ 好的基线还能降低方差

没解决

- ✗ 同一条轨迹里，所有动作拿到的优势一样
- ✗ 要估好平时能拿多少，可能还得另训一个价值模型



? 是哪一步做对了？

信用分配 只看最终奖励，分不出来



课件 p.34（中文重绘）

有中间奖励：用往后的奖励之和

$$R_t = \sum_{t'=t+1}^{T} r_{t'}$$



一个动作只按它之后拿到的奖励来加权

之前的奖励和它无关：扔掉能降低方差，又不引入偏差

猜数字只在最后给一次奖励：每个动作的这个数 = 整条轨迹的奖励



课件 p.35（中文重绘）

一组四条轨迹：和组内平均比

GRPO · DeepSeekMath §4.1.2

$$b(h_t) = \bar{R} = \frac{1}{G}\sum_{j=1}^{G} R(\tau_j)$$

$$\hat{A}_j = \frac{R(\tau_j) - \bar{R}}{\sigma_R}$$

									奖励 R_j	减去平均 $R_j - \bar{R}$	除以标准差 σ_R	优势 $\hat{A}_j$
第一条	猜 8	往上	猜 12	往下	猜 10	往上	猜 11	猜中 · 奖励 1	1	+0.5	÷ 0.5	+1
第二条	猜 4	往上	猜 8	往上	猜 12	往下	猜 11	猜中 · 奖励 1	1	+0.5	÷ 0.5	+1
第三条	猜 16	往下	猜 8	往上	猜 9	往上	猜 10	超时 · 奖励 0	0	−0.5	÷ 0.5	−1
第四条	猜 1	往上	猜 2	往上	猜 3	往上	猜 4	超时 · 奖励 0	0	−0.5	÷ 0.5	−1

$\bar{R} = 0.5$ 组内平均

$\sigma_R = 0.5$ 组内标准差（按总体算）



课件 p.37（中文重绘）

一批里好几道题，每道题自己一组

任务实例	四次试跑的奖励				组内平均	优势 $\hat{A}_{ij}$			
第一道 藏着 11	1	1	0	0	$\bar{R}_1 = 0.50$	+1	+1	−1	−1
第二道 藏着 3	1	0	0	0	$\bar{R}_2 = 0.25$	+1.73	−0.58	−0.58	−0.58
第三道 藏着 7	1	1	1	0	$\bar{R}_3 = 0.75$	+0.58	+0.58	+0.58	−1.73

平均只在每道题内部算：每道题自己的 R_i，自己的 σ_i

策略梯度损失 · i 是批里第几条

$$-\sum_i R(\tau_i) \sum_t \log \pi_\theta(a_{i,t} \mid h_{i,t})$$

↓ 只换了这一项：$R(\tau_i) \to \hat{A}_{ij}$，它在同一组里比平均好多少

GRPO 损失 · i 是第几道题，j 是组里第几条

$$-\sum_i \frac{1}{G} \sum_{j=1}^{G} \hat{A}_{ij} \sum_t \log \pi_\theta(a_{ij,t} \mid h_{ij,t})$$

组大小：一般 8 左右

DeepSeekMath 原文：64 条

比值　截断　KL

今天先去掉 · 强化学习下一讲

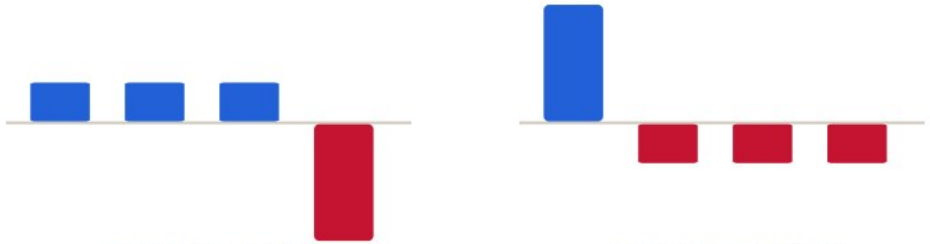


课件 p.38（中文重绘）

DrGRPO：去掉两处除法

	GRPO	DrGRPO	为什么改
优势	$\frac{R_j - \bar{R}}{\sigma_R}$	$R_j - \bar{R}$ 只减平均	标准差在每组内部算，每道题都不一样；几乎总做对、几乎总做不对的题，标准差很小，分量被放大
回答汇总	$\frac{1}{\lvert y_j \rvert}\sum_t(\cdot)$	$\frac{1}{C}\sum_t(\cdot)$ C：生成长度上限	回答长度 $\lvert y_j \rvert$ 每个都不同；又长又错的回答，每个 token 挨的罚更轻 → 偏向更长的错误回答

÷ 标准差：标准差很小的题被放大 示意



各种难度，被压到同一个范围 示意



不再知道这道题有多难

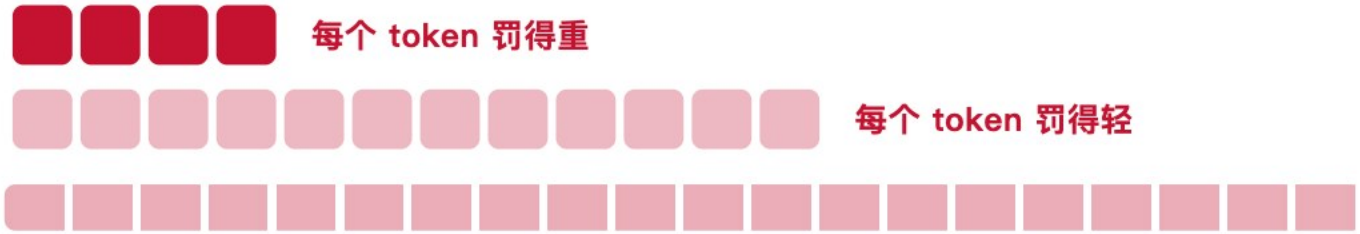


课件 p.39（中文重绘）

DrGRPO：去掉两处除法

	GRPO	DrGRPO	为什么改
优势	$\frac{R_j - \bar{R}}{\sigma_R}$	$R_j - \bar{R}$ 只减平均	标准差在每组内部算，每道题都不一样；几乎总做对、几乎总做不对的题，标准差很小，分量被放大
回答汇总	$\frac{1}{\lvert y_j \rvert}\sum_t(\cdot)$	$\frac{1}{C}\sum_t(\cdot)$ C：生成长度上限	回答长度 $\lvert y_j \rvert$ 每个都不同；又长又错的回答，每个 token 挨的罚更轻 → 偏向更长的错误回答

÷ 回答长度：长短两个错误回答 示意





课件 p.39（中文重绘）

DrGRPO：每个 token 一个系数

第一条

$\hat{A}_1 = +0.5$

+0.5 ÷ 常数

<|im_start|>assistant ↵ guess(8) ↵ <|im_end|> ↵ <|im_start|>tool ↵ higher

+0.5 ÷ 常数

↵ <|im_end|> ↵ … ↵ <|im_start|>assistant ↵ guess(11) ↵ <|im_end|>

每个 token **+0.5 ÷ 常数**

第三条

$\hat{A}_3 = -0.5$

−0.5 ÷ 常数

<|im_start|>assistant ↵ guess(16) ↵ <|im_end|> ↵ <|im_start|>tool ↵ lower

−0.5 ÷ 常数

↵ <|im_end|> ↵ … ↵ <|im_start|>assistant ↵ guess(10) ↵ <|im_end|>

每个 token **−0.5 ÷ 常数**

一组的结果平均起来

$$\mathcal{L}_{DrGRPO} = -\frac{1}{G}\sum_{j=1}^{G}\frac{1}{C}\sum_{t\,:\,m_{j,t}=1}\hat{A}_j \log \pi_\theta(u_{j,t} \mid u_{j,<t})$$

$\hat{A}_j = R(\tau_j) - \bar{R}$，不再除以 σ_R

简化过：论文的目标里还有比值和截断



课件 p.40（中文重绘）

奖励全相同：没有梯度

全部失败

[0, 0, 0, 0] → [0, 0, 0, 0]

可能太难

全部成功

[1, 1, 1, 1] → [0, 0, 0, 0]

可能太简单

组里没有差别 → 优势全为 0 → 没有梯度

全失败时能做什么？

- **换一批题**
- **提示里注入知识**
  引导模型更可能做对
- **加示范**
  放进组里 · 先微调
- **信息量更大的奖励**
  奖励做对的中间决定

奖励塑形





课件 p.41（中文重绘）

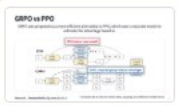
GRPO 对 PPO：不要价值模型

PPO



GRPO





课件 p.42（中文重绘）

Q1 经典强化学习的马尔可夫假设呢?

课上提问

经典写法：马尔可夫假设

下一个状态只看上一个

状态 → 状态 → 状态

这一讲的写法

部分可观测 · POMDP

观察 · 动作 · 观察 … 历史

底下的状态：看不到

在 POMDP 里，两种写法等价



课堂提问

Q2 ReST 和自蒸馏有什么区别?

课上提问

ReST：区别就在这一步

用奖励来筛选

全部轨迹 → 按奖励筛选 → 训练

在全部轨迹上训练

就是自训练

全部轨迹 → 训练



课堂提问

Q3 一条成功的轨迹都跑不出来呢?

课上提问

办法一

先在示范上训

强化学习之前的冷启动，就是上一讲的监督微调

办法二

课程学习

先挑能拿到奖励的题，再上难题



办法三

给中间奖励

比如先探索代码仓库，就为这一步给奖励

强化学习必须面对的一个大问题



课堂提问

Q4 GRPO 有偏差吗?

课上提问 + DrGRPO 原文

减去组内平均

基线只来自模型自己的试跑

课上的回答：无偏

÷ 组内标准差

给每道题乘上不同的系数

DrGRPO：偏差来源

÷ 回答长度

和除以标准差一样

DrGRPO：偏差来源

去掉这两处除法 → 带无偏基线的写法



课堂提问

每种方法都在给动作加权，只差在权重

$$\nabla_\theta J = \Sigma_t \, w_t \, \nabla_\theta \log \pi_\theta(a_t \mid h_t)$$

ReST-EM	权重 = 成功的轨迹记 1，其余记 0
REINFORCE	权重 = 整条轨迹的奖励
GRPO / DrGRPO	权重 = 比同一道题上其他试跑好多少



课件 p.44–46

四条轨迹，四种权重

			ReST-EM	REINFORCE	GRPO	DrGRPO
第一条	8 往上 12 往下 10 往上 11	猜中 · 1	1	1	+1	+0.5
第二条	4 往上 8 往上 12 往下 11	猜中 · 1	1	1	+1	+0.5
第三条	16 往下 8 往上 9 往上 10	超时 · 0	0	0	−1	−0.5
第四条	1 往上 2 往上 3 往上 4	超时 · 0	0	0	−1	−0.5

四列按本讲前面的算法逐条算出（示意）



课件 p.44–46

开头那三个问题，都解决了

问题 1

任务错位

目标是期望奖励，任何成功的轨迹都会被强化

问题 2

数据错位

有了合适的基线，也能从不够好的轨迹里学

问题 3

曝光偏差

轨迹来自当前策略，学会从自己的错误里恢复

代价 必须真的在环境里去试 · 成本可能很高 · 给梯度带来噪声



课件 p.44–46

CMU 11-768 · AI AGENTS

第 9 讲 · 强化学习基础

下一讲：深度研究 agent

强化学习的下一讲：进阶算法

每晚 20:00 更新



课件 p.44–46