25,840,000 token

彻底搞懂

深度研究 agent

全长 30 分钟 | 建议先收藏

这一讲：深度研究 agent

上一讲片尾

下一讲：深度研究 agent

→

这一讲

训练一个会搜索的 agent

GRPO

检索增强生成
查一次资料再作答

问题 → 查一次 → 作答

信息需求
越来越复杂

③–⑦

评测

基准、细则和引用支撑

⑧–⑫

建模

学会搜索、推理和综合

奖励从哪来?

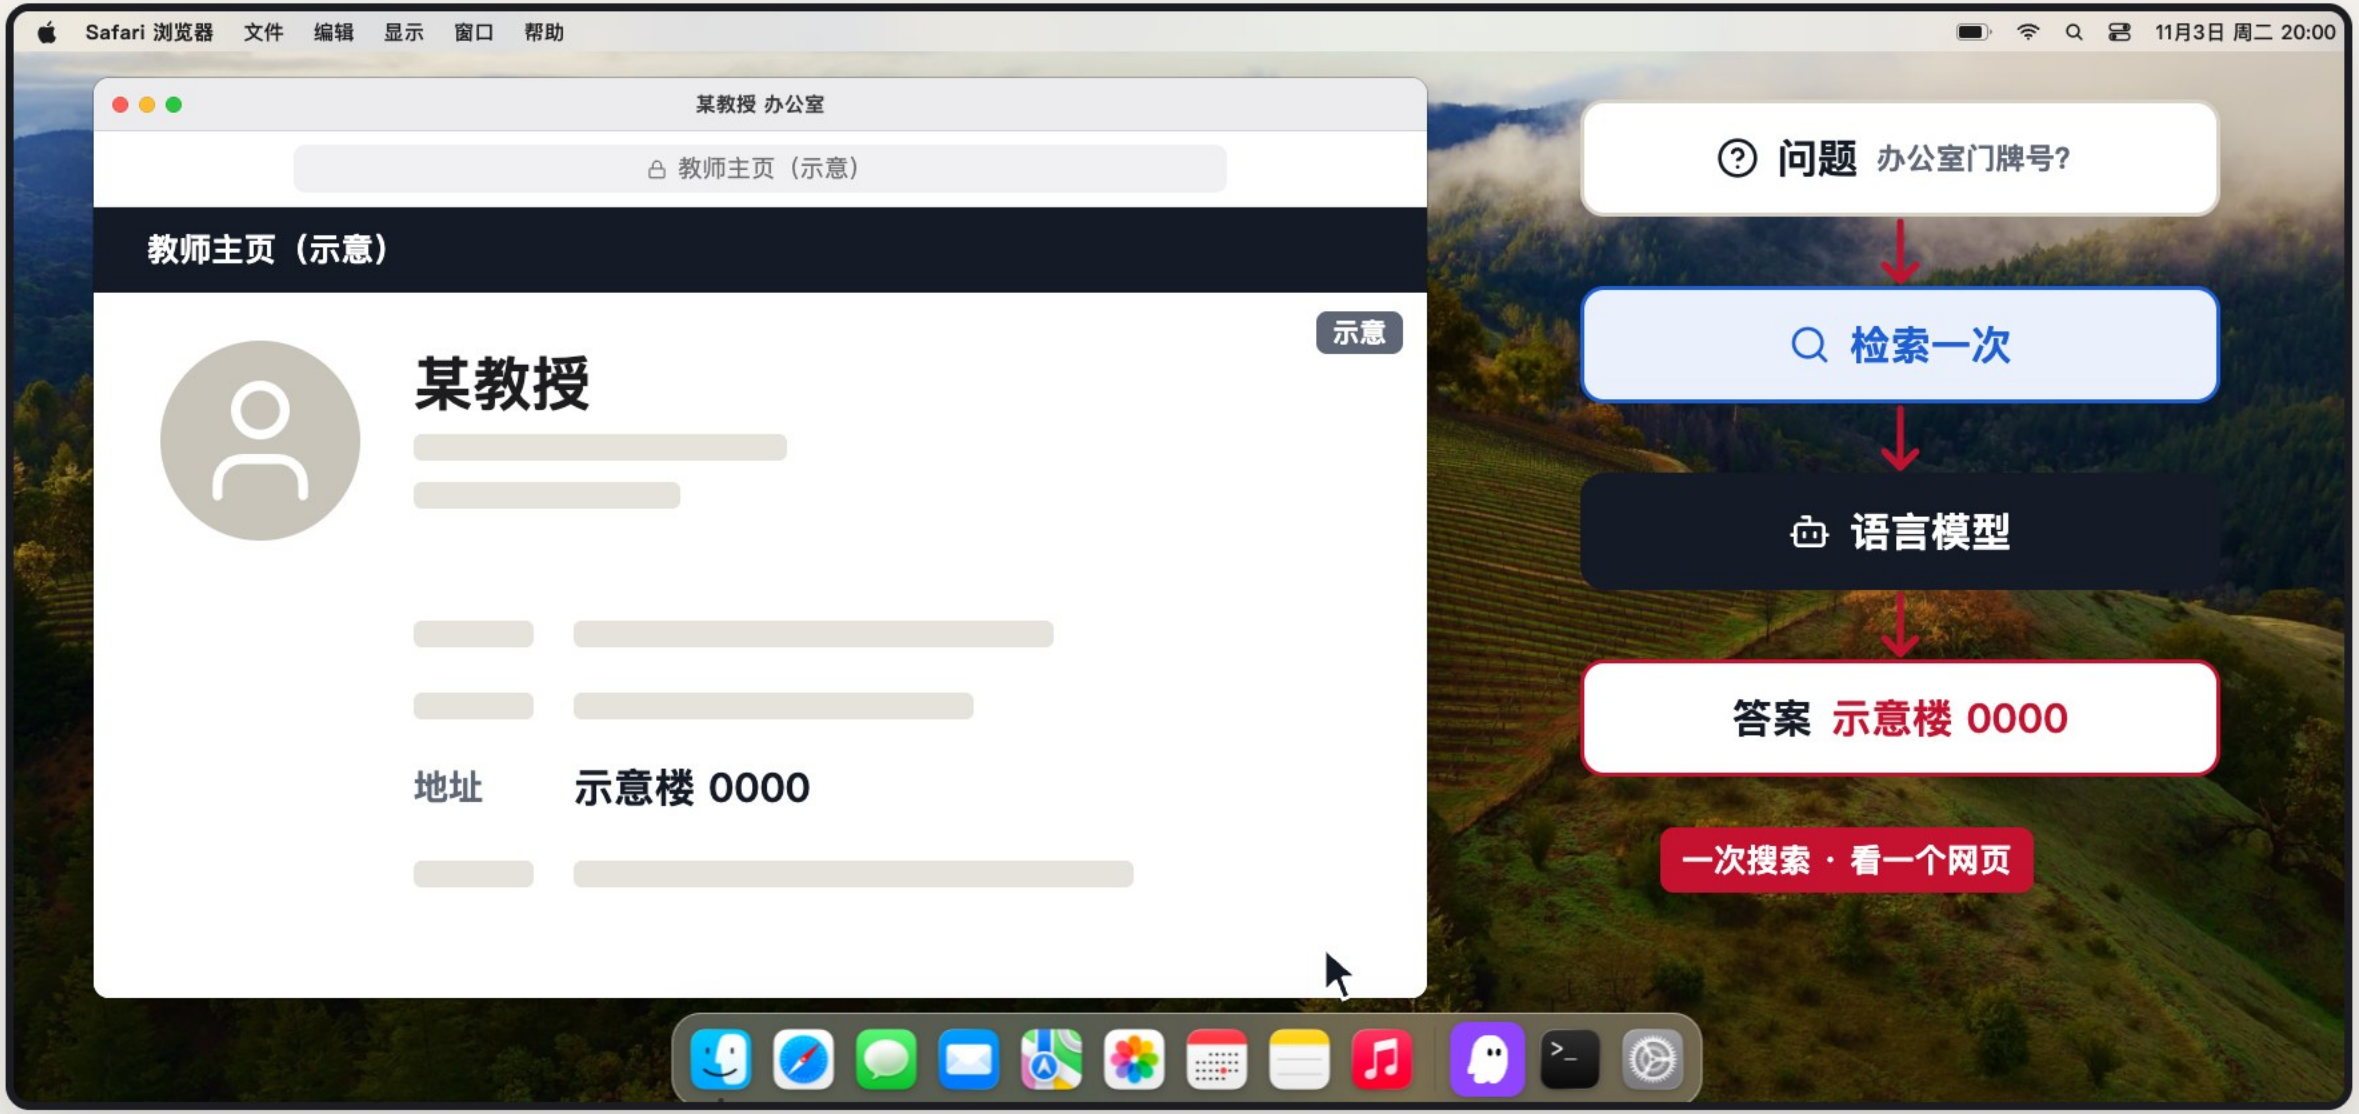
⑬–⑭

检索

为 agent 的下一步找到证据



课件 p.12

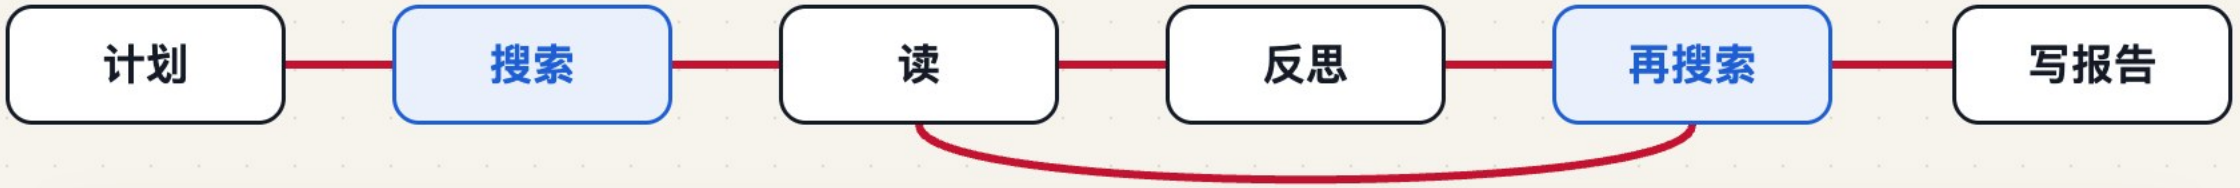

Safari 浏览器 文件 编辑 显示 窗口 帮助
11月3日 周二 20:00
某教授 办公室
教师主页（示意）
教师主页（示意）
示意
某教授
地址
示意楼 0000
问题 办公室门牌号?
检索一次
语言模型
答案 示意楼 0000
一次搜索 · 看一个网页



课件 p.3（示意）

研究问题：反复计划、搜索、反思

AI agent 能不能像人类专家一样综合科学文献?



最终答案 · 带引用

在测过的任务上有希望；更广泛地和专家持平，还没有被证明

在评测过的文献综合问题上，专家更喜欢 OpenScholar 的答案。[1]

DR Tulu 在四个长篇研究基准上成绩很好；但和其他 AI 比得好，不等于和人类专家持平。[2]

[1] OpenScholar，Nature 2026 [2] DR Tulu，ICML 2026



课件 p.11（中文重绘）

一道 Natural Questions 的题

Google 收集真实搜索查询做成

问题

`who wrote the score for the force awakens`

《星球大战：原力觉醒》的配乐是谁写的?

维基百科 · 来源文档

Star Wars: The Force Awakens – Original Motion Picture Soundtrack is the film score to the 2015 film of the same name composed by John Williams, with Williams and William Ross conducting ...

答案

John Williams

简单查找
靠一个网页就能答

通用领域
多建在英文维基百科上，多是体育、娱乐

证据用没用不清楚
说不清是哪份证据支撑了它

短答案
往往就是一个实体

Natural Questions 官方例题 · 按 2018 年的维基百科标注



课件 p.18（中文重绘）

翻过来，就是四个维度

1 / 搜索复杂度

搜索复杂度

简单查找

2 / 领域专长

领域专长

通用领域

3 / 答案质量

答案质量

短答案

4 / 证据支撑

证据支撑

证据用没用不清楚



课件 p.19（中文重绘）

BrowseComp：从答案倒着出题

1,266 道人写的题　OpenAI · 现在用得最多的深度研究基准之一

出题

1 从答案出发

一个已知的人、事件或作品

2 写一道复杂的题

把名字藏起来，把几条事实线索拼在一起

验证难度

语言模型 + 搜索

模型应该答不出；
5 次 Google 搜索应该不够

人工检查

10 分钟后还是很难吗？
只在一部分题上检查过



课件 p.21（中文重绘）

一道由五条线索拼成的题

找一个虚构角色，他…… 原题按阅读顺序拆成五条

- **行为** 偶尔打破第四面墙，直接和观众说话
- **背景故事** 受无私的苦行者帮助
- **性格** 以幽默出名
- **电视剧** 1960–1980 年代之间播出
- **集数** 少于 50 集

题目已经不像自然的问题了

Plastic Man

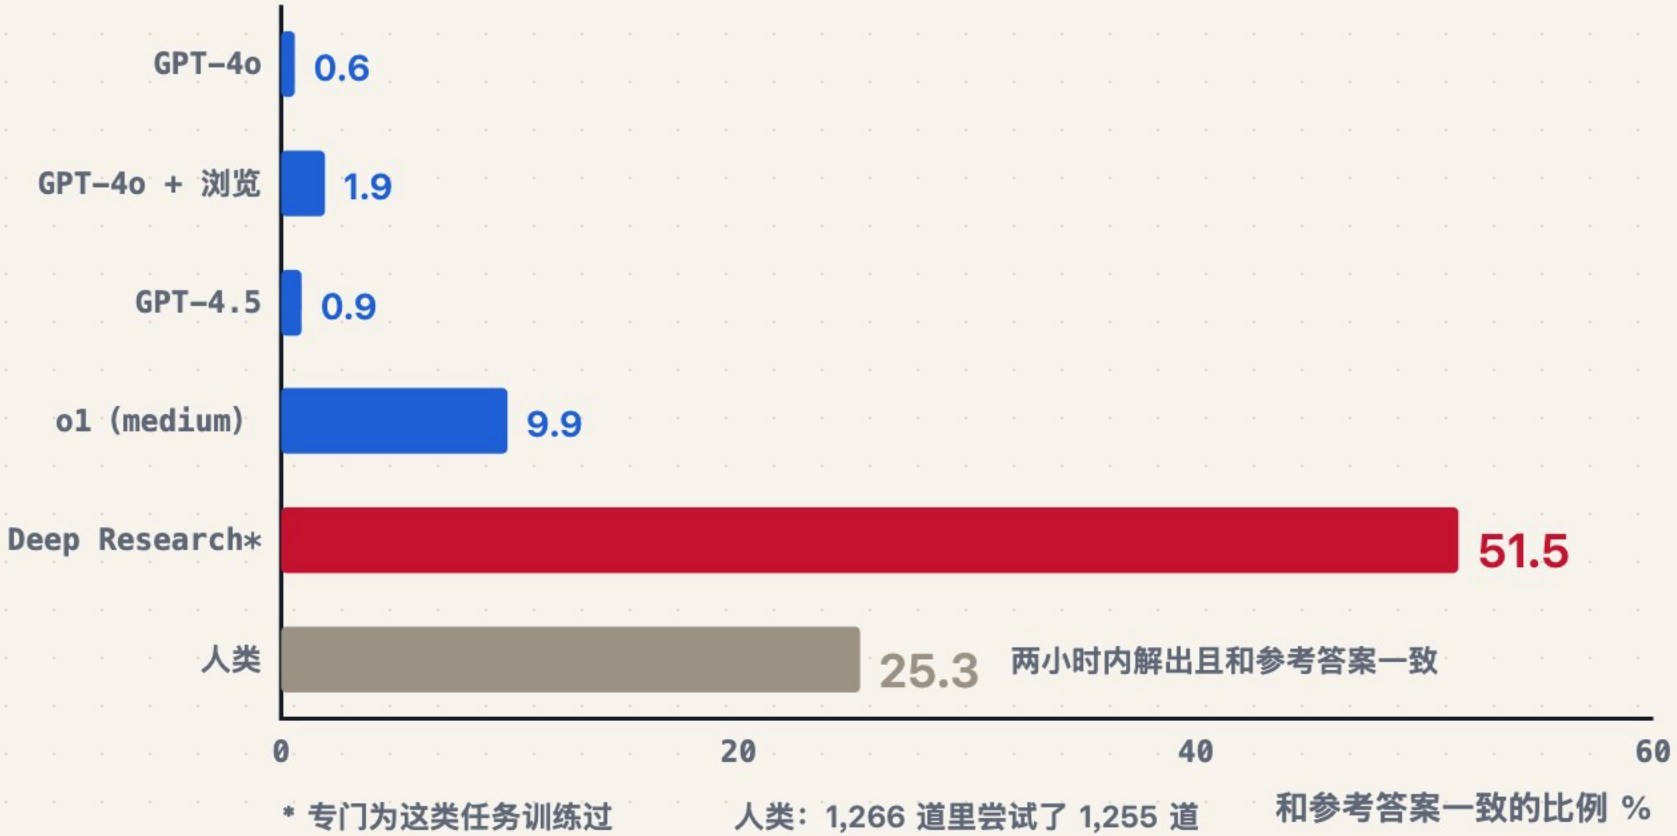
塑胶人

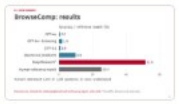
✓ 答案短，好验证



课件 p.23（中文重绘）

专门训练过的系统，超过两小时的人类训练员

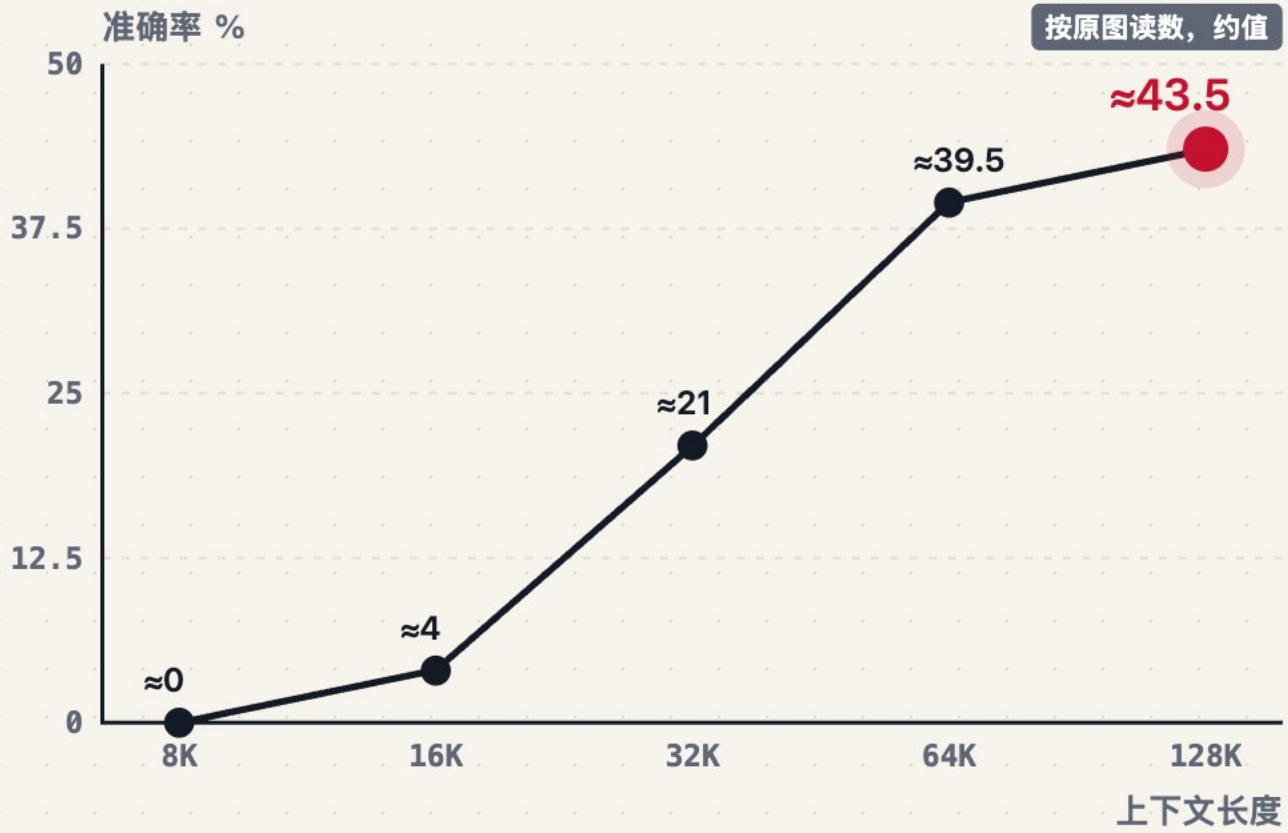




课件 p.25（中文重绘）

上下文越长，准确率越高

Tongyi DeepResearch · 在 BrowseComp 上的消融



评测

128 次工具调用

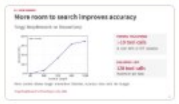
每道题最多允许

训练

10 次以上工具调用

超过两成的监督微调样本

一道题就要上百次搜索



课件 p.26（中文重绘）

BrowseComp-Plus：把语料库固定下来

BrowseComp 题目对

问题 + 已知答案

从原题和答案出发

→

1 / 收集证据

用 o3 找证据页面



→

2 / 人工核实

- ✓ 标出支撑片段
- ✓ 检查每条线索
- ✓ 标出答案文档

↓

加入困难负例

相关，但缺了某条线索



→

固定的基准

1,005 道里，830 道通过人工核实

🔒 冻结

830 道题 / 100,195 篇文档



课件 p.28（中文重绘）

第一格换掉

1 / 搜索复杂度

BrowseComp / BrowseComp-Plus

答案难找；语料库固定，方便受控比较

2 / 领域专长

通用领域

宽泛的网络问题，考不到专家知识

3 / 答案质量

短答案

答案匹配，评不了多份文档的综合

4 / 证据支撑

证据用没用不清楚

答对了，也不代表用了证据，更不代表可靠



课件 p.29（中文重绘）

领域专长：专家出题、专家核

1 · 搜索复杂度
BrowseComp / BrowseComp-Plus
答案难找；语料库固定，方便受控比较
娱乐 人物

2 领域专长
问题：通用领域

3 答案质量
问题：短答案

4 证据支撑
问题：证据用没用不清楚

~~只会答娱乐题~~ 用在专业、风险更高的领域

FinSearchComp 金融版的 BrowseComp **635 道题** **70 位金融专业人士**

1 专家出题
从工作场景或核实过的财务报表出发

→

2 确定答案
取可靠数据；计算并交叉核对

→

3 独立复核
其他专家来解；分歧要解决掉

例题（原题改写）

2022 到 2024 年间，强生公司海外营收的占比，每年比上一年变化了多少?

2022–2024 | 强生 | 海外营收占比 | 每年变化多少

计算器工具
+ 大量金融知识



课件 p.31

领域专长：专家出题、专家核

1 · 搜索复杂度
BrowseComp / BrowseComp-Plus
答案难找；语料库固定，方便受控比较
娱乐 人物

2 领域专长
问题：通用领域

3 答案质量
问题：短答案

4 证据支撑
问题：证据用没用不清楚

MedBrowseComp 医学

FinSearchComp 金融

ScholarSearch 论文检索

AutoResearchBench 论文检索
找出同时满足好几个条件的那篇论文

专业领域的基准：请专家来标注和核实答案



课件 p.32

领域专长：专家出题、专家核

这一段记住一句

专业领域的题，
得靠专家出、专家核。

1 · 搜索复杂度

BrowseComp / BrowseComp-Plus

答案难找；语料库固定，方便受控比较

娱乐 人物

2 · 领域专长

MedBrowseComp / FinSearchComp

用专家知识引导医学和金融搜索

答案仍然很短

3

答案质量

问题：短答案

4

证据支撑

问题：证据用没用不清楚



课件 p.33–34

答案质量：正确答案不止一种

1 · 搜索复杂度
BrowseComp / BrowseComp-Plus
答案难找；语料库固定，方便受控比较
娱乐 人物

2 · 领域专长
MedBrowseComp / FinSearchComp
用专家知识引导医学和金融搜索
答案仍然很短

3
答案质量
问题：短答案

4
证据支撑
问题：证据用没用不清楚

问题 AI agent 能不能像人类专家一样综合文献?

参考摘要

在一项研究里，专家更喜欢 OpenScholar。各领域都持平还没被证明。

另一份同样正确的摘要

一项研究支持 OpenScholar；它没有证明各领域都等同。

✓ 正确答案不止一种

相似，但错误

在一项研究里，专家更喜欢 OpenScholar。各领域都持平已经被证明。

× 和标准答案相似还不够

OpenScholar：用检索来综合科学文献的语言模型

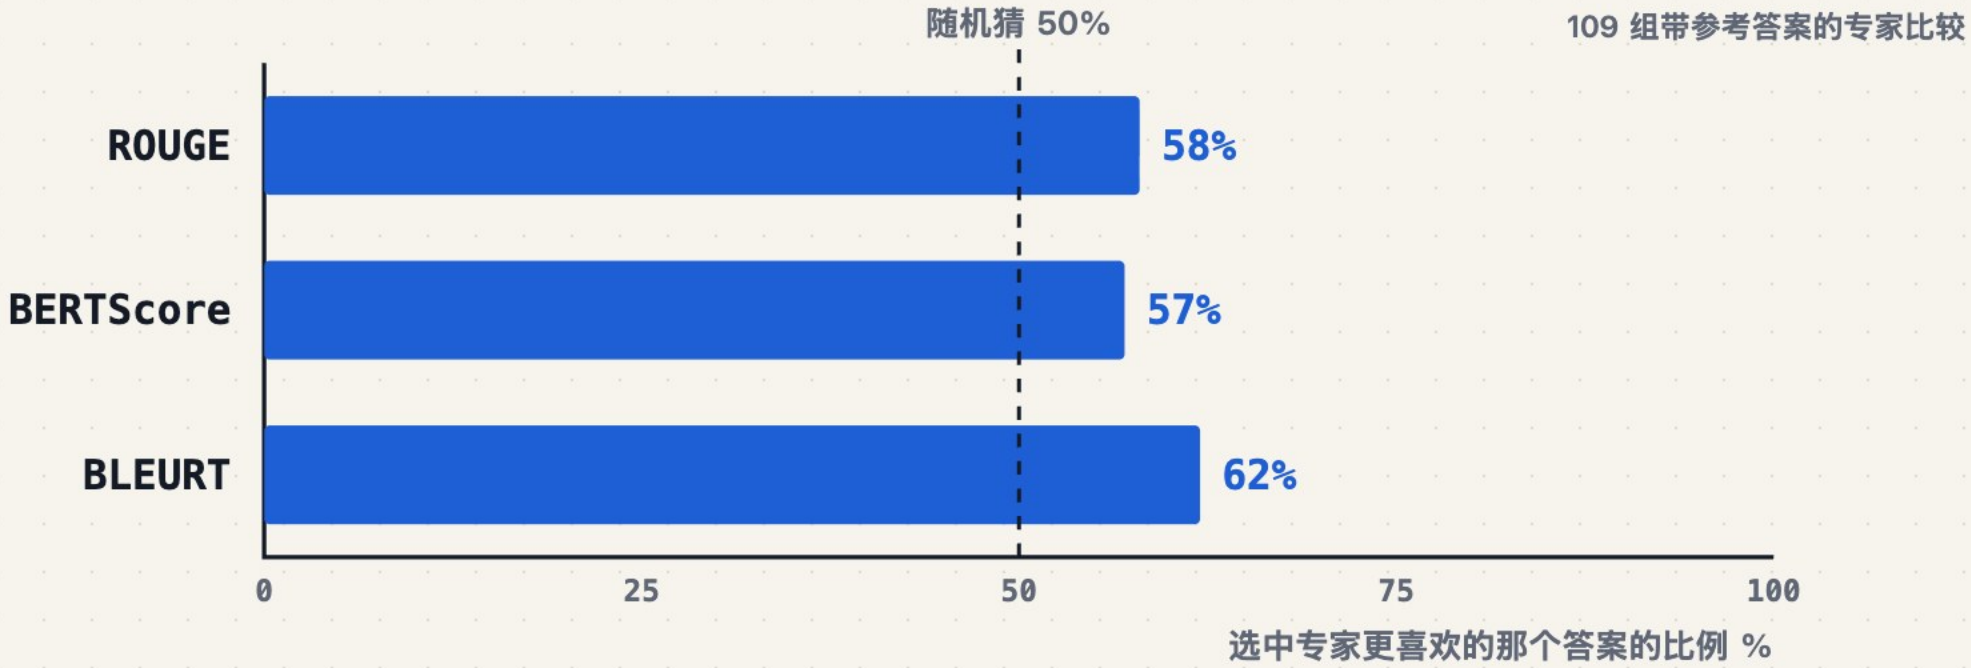
参考答案标不全

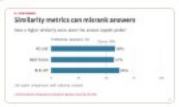


课件 p.35–37

相似度高，不等于专家更喜欢

开放式的研究场景：不能直接用基于参考答案的指标





课件 p.38

ScholarQABench：用专家细则来评

题目

AI agent 能不能像人类专家一样综合文献?

候选答案

OpenScholar 在 70% 的专家比较中胜出[1]。这一点在所有领域都成立。

一句描述 + 权重 → 语言模型逐条判断 → 按权重加权平均

专家细则	权重	判断
报告了和人类专家的直接比较	2	✓ 1
按任务和领域给结论加了限定	1	× 0

$$S = \Sigma\, w_i b_i \,/\, \Sigma\, w_i = (2\times1 + 1\times0) \,/\, 3 = 0.67$$

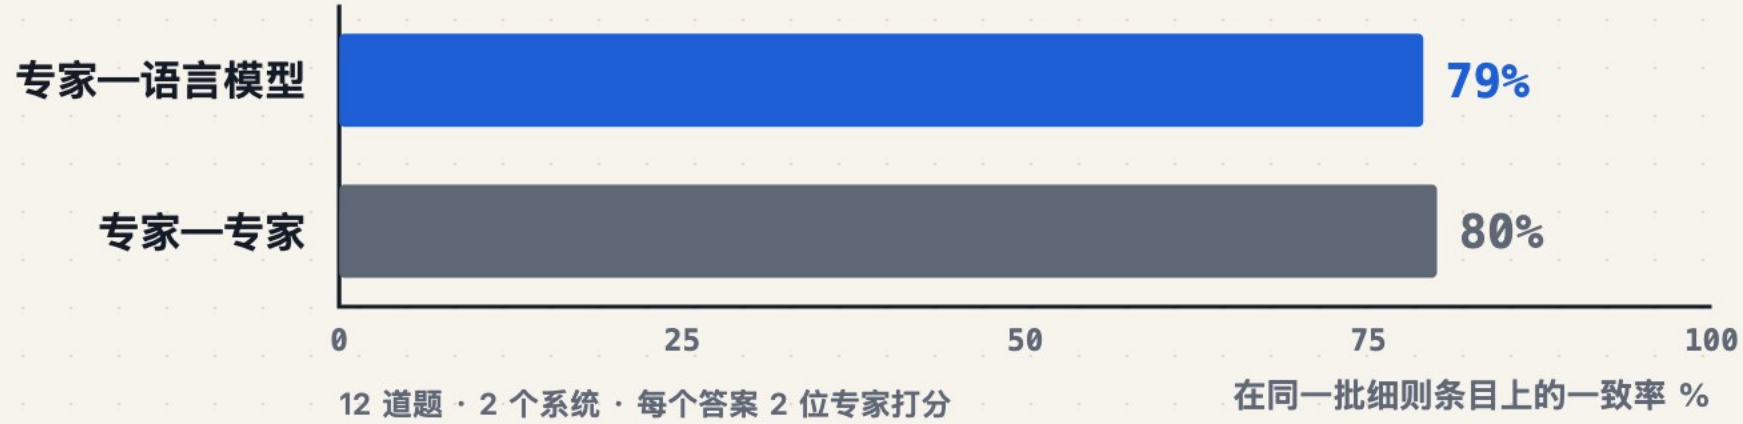
0.67



课件 p.41

细则判断：和专家一致吗

课件数据



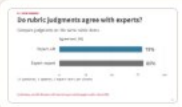
细则写得好 → 交给语言模型大规模地评

写一份参考答案 ≈ 1 小时

博士级的专家来标，非常费时间

难扩大规模





课件 p.42

ResearchQA：模型写细则

1 · 搜索复杂度
BrowseComp / BrowseComp-Plus
答案难找；语料库固定，方便受控比较
娱乐 人物

2 · 领域专长
MedBrowseComp / FinSearchComp
用专家知识引导医学和金融搜索
答案仍然很短

3
答案质量
问题：短答案

4
证据支撑
问题：证据用没用不清楚

综述论文的一节 → 语言模型 → 研究问题 / 细则

21K 道题

75 个领域

160K 条细则

例：从一篇讲上下文学习的综述里挖出的问题

预训练数据里一个词出现的频率，怎样影响少样本下的数值推理?



课件 p.43

生成的细则会把目标写错

1 · 搜索复杂度
BrowseComp / BrowseComp-Plus
答案难找；语料库固定，方便受控比较
娱乐 人物

2 · 领域专长
MedBrowseComp / FinSearchComp
用专家知识引导医学和金融搜索
答案仍然很短

3
答案质量
问题：短答案

4
证据支撑
问题：证据用没用不清楚

ResearchQA · 专家审查

15%

只靠模型自身知识生成的参数化细则：空洞、错误或说不清

会怎么错?

- ✕ 引用了不存在的论文
- ✕ 只是把问题复述一遍
- ✕ 含糊到看起来合理的错误也能过关

先评细则本身：建立在来源上，再审相关性和可核实性

DeepResearch Bench II 专家写报告 → 人工修订 → 专家复审



课件 p.44

答案质量：第三格换成细则评测

这一段记住一句

相似度评不了长篇回答，细则可以，但细则本身也得先审。

1 · 搜索复杂度

BrowseComp / BrowseComp-Plus

答案难找；语料库固定，方便受控比较

娱乐 人物

2 · 领域专长

MedBrowseComp / FinSearchComp

用专家知识引导医学和金融搜索

答案仍然很短

3 · 答案质量

ScholarQABench / ResearchQA

用细则评回答的质量

4

证据支撑

问题：证据用没用不清楚



课件 p.45–46

DeepResearch Bench 的 FACT：被引页面支不支持论断

1 · 抽出论断 + 网址

OpenScholar 和人类的答案比较过 [1]

OpenScholar 在每个领域都和专家持平 [1]

2 · 读被引页面

[1] OpenScholar 论文

在一部分研究问题上做了专家比较

没有测每个领域

3 · 判断支不支持

✓ 支持

✕ 不支持

引用准确率

1/2 = 50%

有效引用

1 条

还不检查

被引来源本身靠不靠谱 · 开放问题



课件 p.47–49

深度研究基准总览：四格填满

1 · 搜索复杂度

BrowseComp / BrowseComp-Plus

答案难找；固定语料库，方便做对照比较

2 · 领域专长

MedBrowseComp / FinSearchComp

专家知识引导医疗和金融搜索

3 · 答案质量

ScholarQABench / ResearchQA

用细则评回答质量

4 · 证据支撑

DeepResearch Bench

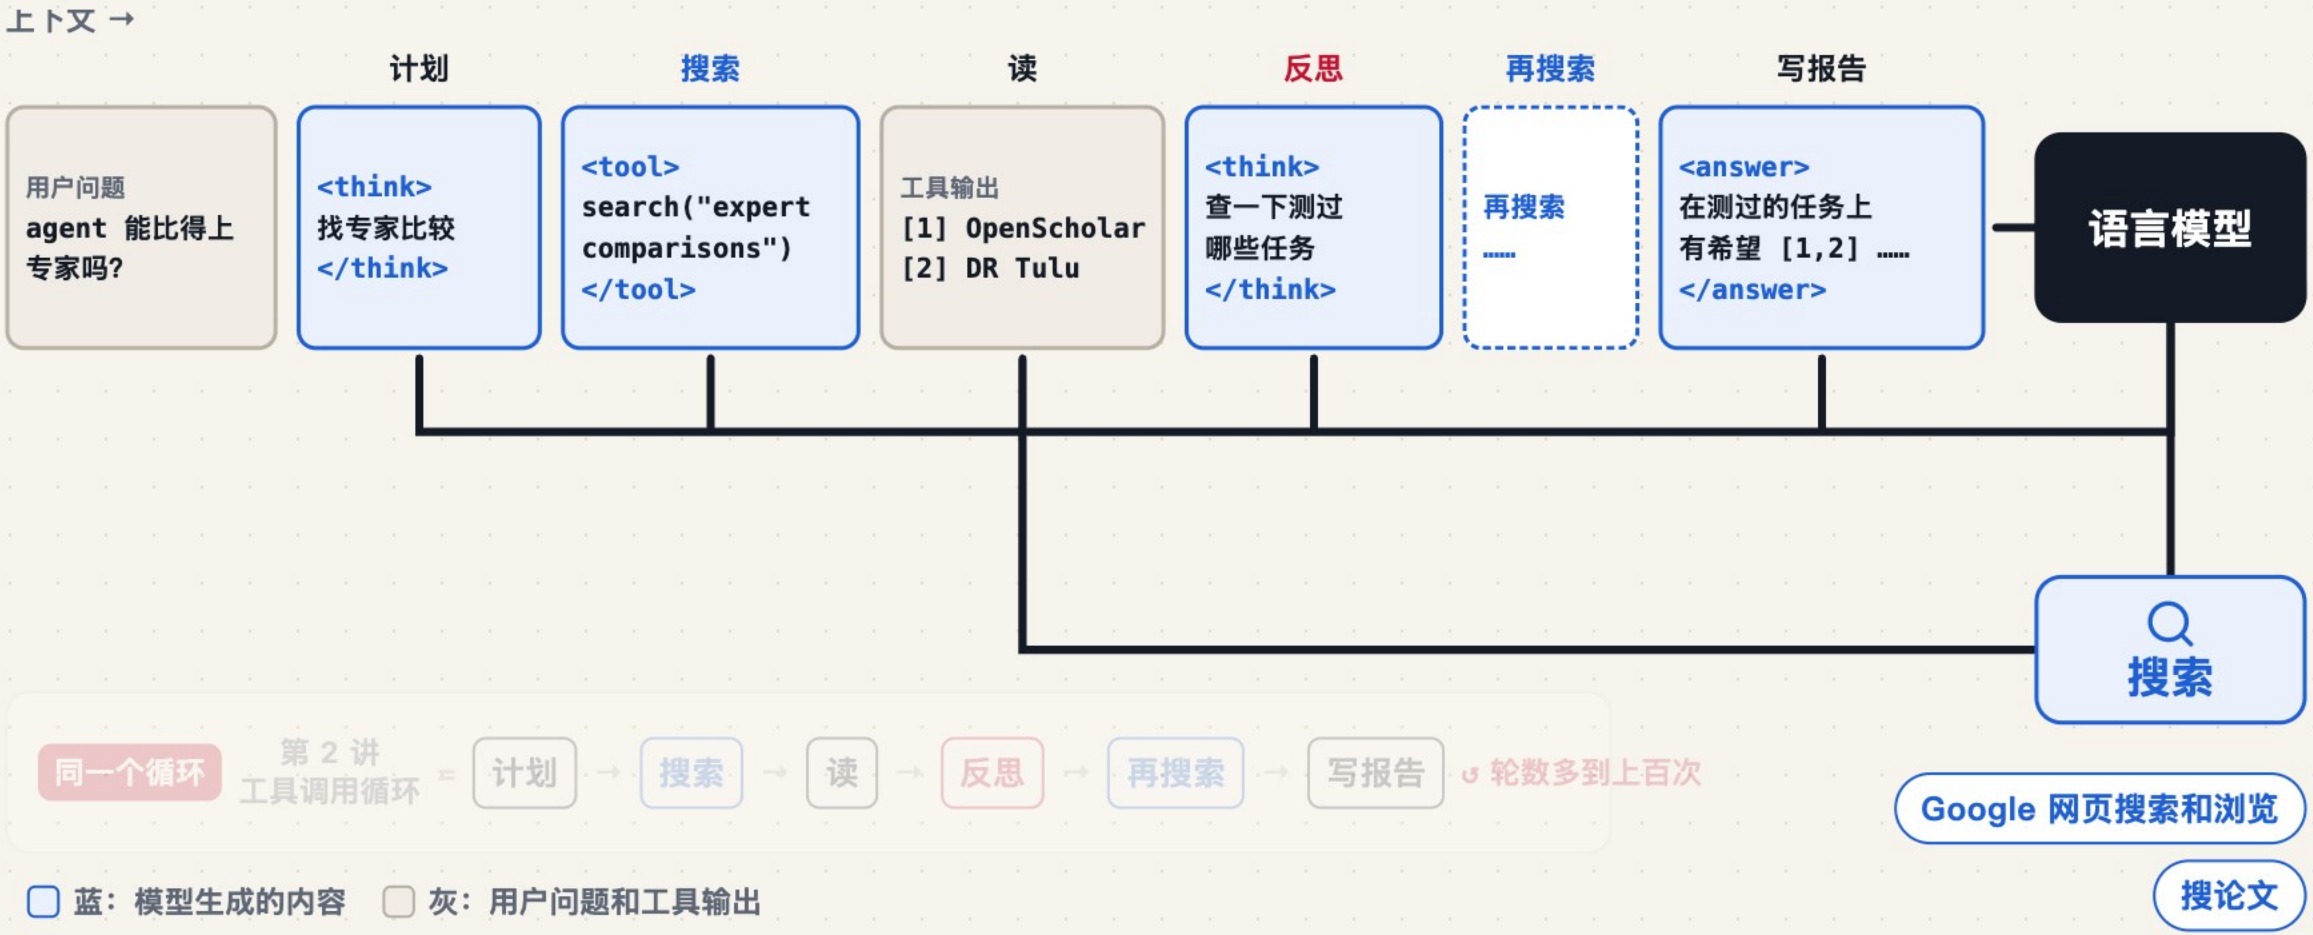
检查被引来源撑不撑得住报告的论断

每格：维度 · 基准 · 做什么



课件 p.50

推理时，上下文里一步步发生了什么





课件 p.51–57

Tongyi DeepResearch 的三阶段配方

中训练 → **监督微调** (第 8 讲) → **强化学习** (第 9 讲)

大规模地接触 agent 的行为

模仿老师的成功轨迹

从自己尝试得到的反馈里学

中训练	监督微调	强化学习
训练数据	训练数据	训练数据
输入 + 答案	输入 + 答案	输入 + 答案
老师的轨迹	老师的轨迹	策略自己的 rollout

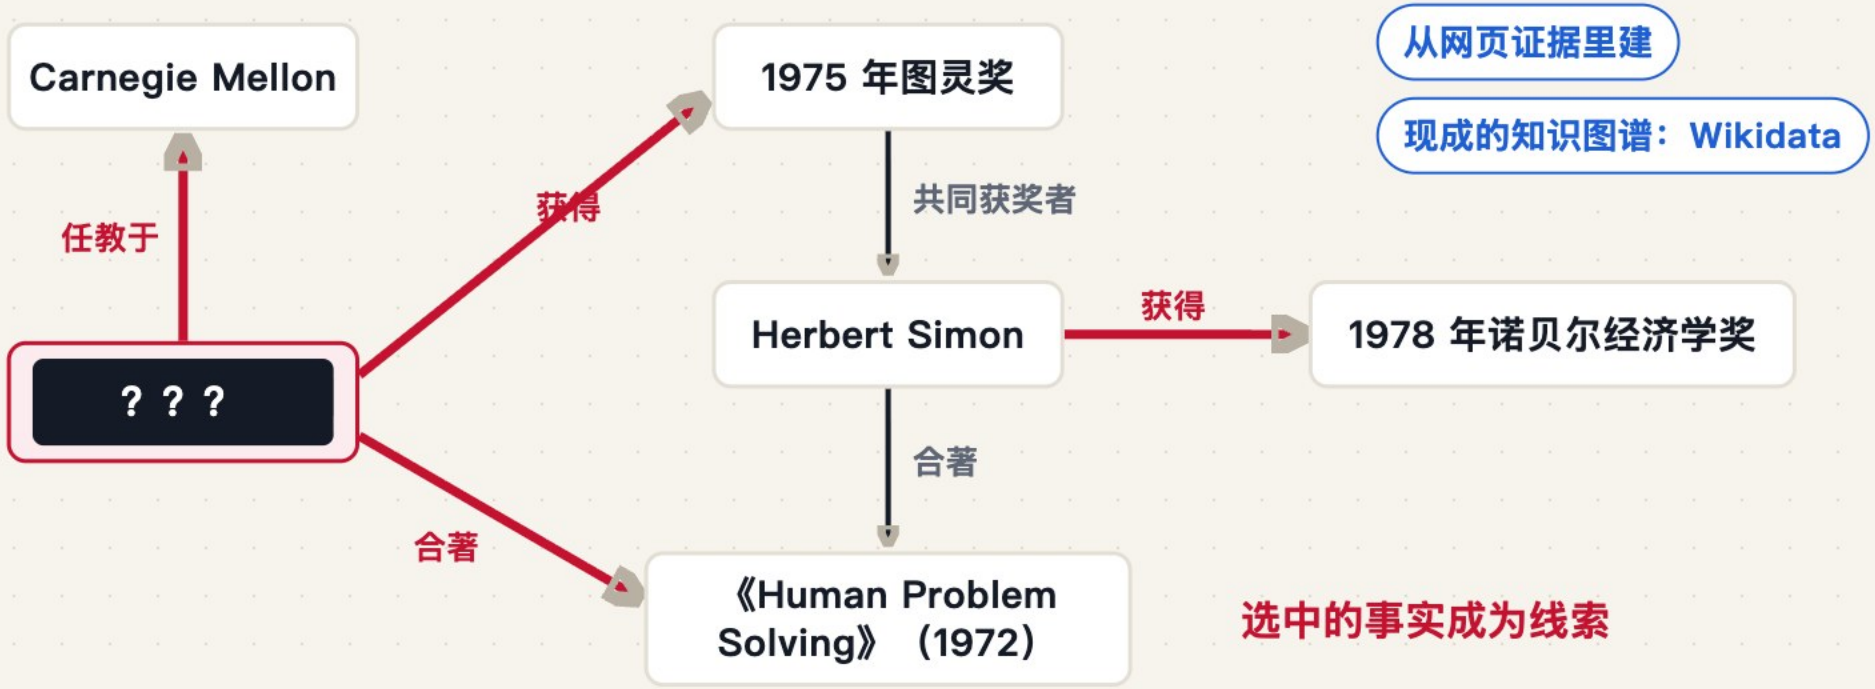
不是每个系统都三个都用

任务和轨迹从哪来?

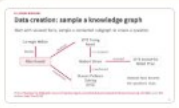


课件 p.58–60

知识图谱：节点是实体，带标签的箭头是关系



节点 = 实体　　带标签的箭头 = 关系



课件 p.63–64

把名字藏起来，关系变成线索

答案必须满足的事实

- [redacted]：在 CMU 任教
- [redacted] + Simon：合著《Human Problem Solving》（1972）
- [redacted] + Simon：共同获得 1975 年图灵奖
- Simon：1978 年诺贝尔经济学奖

→

哪位卡耐基梅隆大学的研究者，和一位后来获得诺贝尔经济学奖的人合著了一本关于人类问题求解的书，并且在那位同事获奖三年前，和他一起获得了图灵奖?

已知答案

Allen Newell

⇅ 同一种出题法

BrowseComp 的题（第 ④ 部分）

五条线索要同时满足

答案：Plastic Man

把目标基准反向工程了一遍

能不能迁移到各种基准：开放问题

能规模化



课件 p.65–67

收集老师轨迹，过滤，再模仿

老师的轨迹



第 9 讲 ReST　生成 → 按奖励筛选 → 再监督微调



课件 p.68–70

同样的监督微调数据，起点不同

agent 轨迹

普通的预训练数据

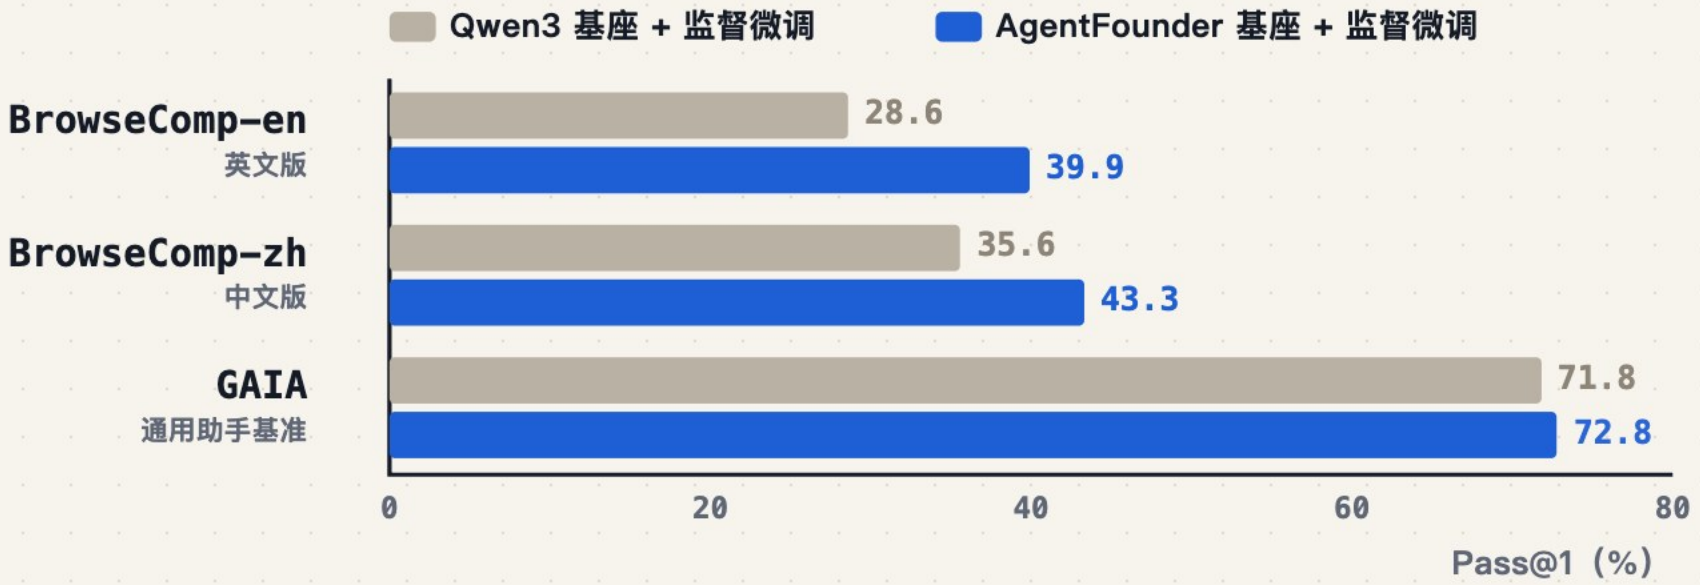
继续预训练

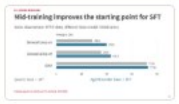
还是预测下一个 token

agent 就绪

基座模型

Tongyi DeepResearch 也建立在它上面





课件 p.73

RLVR：从答案对不对里学

RLVR 可验证奖励的强化学习

短答案能直接判对错 → 当奖励

DeepSeek-R1 这类模型都用过

Search-R1 · 用 GRPO

验证最终答案

$r_i = \mathrm{EM}(a_i, a_{gold})$

精确匹配 · 有时也用语言模型当评判

奖励：0, 1, 1

已知答案

Allen Newell

奖励 r_i → 更新策略

问题 x

卡耐基梅隆大学那道题

策略 π_θ

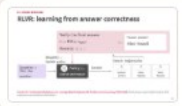
搜索并推理

采样

y_1	y_2	y_3
Herbert Simon	Allen Newell	Allen Newell
奖励 0	奖励 1	奖励 1

例子和奖励为示意

和监督微调的区别：训练用的轨迹来自策略自己



课件 p.76

GRPO 复习：和组内平均比

同一道题 x，采一组尝试 $y_1 \dots y_G$

回指第 9 讲：当时略掉的比值、截断和 KL

Herbert Simon	Allen Newell	Allen Newell
奖励 0	奖励 1	奖励 1
低于组内平均 ↓	高于组内平均 ↑	高于组内平均 ↑
降低概率	提高概率	提高概率

$$\mathcal{J}(\theta) = \mathbb{E}\left[\min\left(\rho \hat{A},\ \mathrm{clip}(\rho,\ 1-\varepsilon,\ 1+\varepsilon)\, \hat{A} \right) - \beta\, D_{KL} \right]$$

相对奖励

在组内比较

截断

限制一步更新的大小

KL 惩罚

别离参考模型太远

轨迹长、数据规模大的时候，这些约束很重要



课件 p.79

异步 rollout：到了答案先打分，凑够一批再更新



- 缓存工具结果
- 稳健地处理接口调用
- 离线维基百科的模拟环境
- 在后台整理任务数据

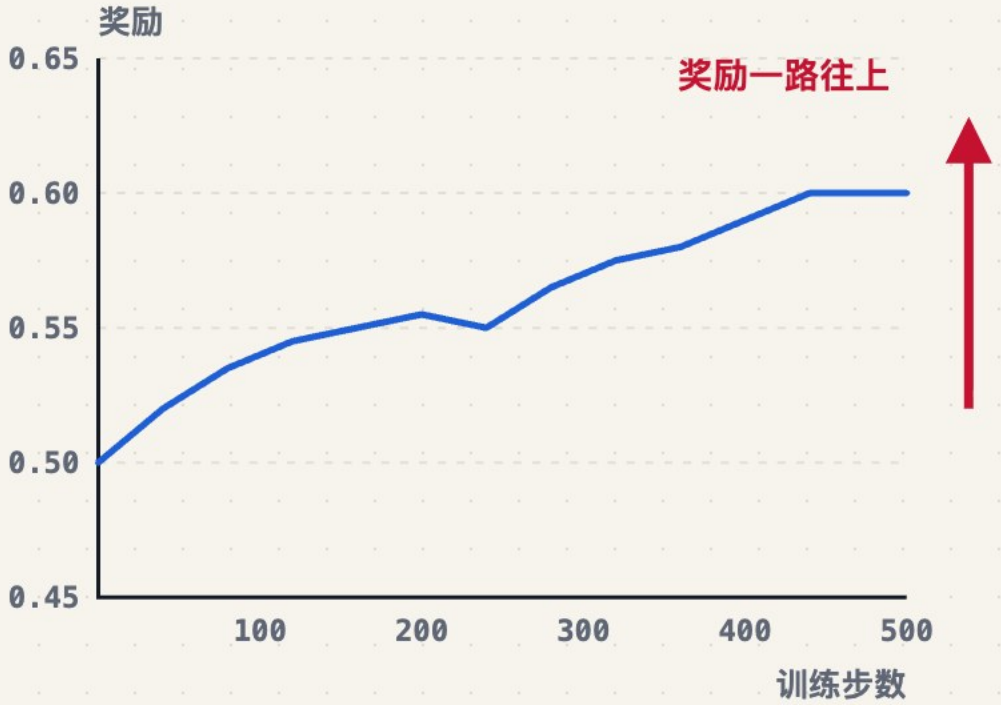
调度和训练效率 → 第 12 讲 · 强化学习系统

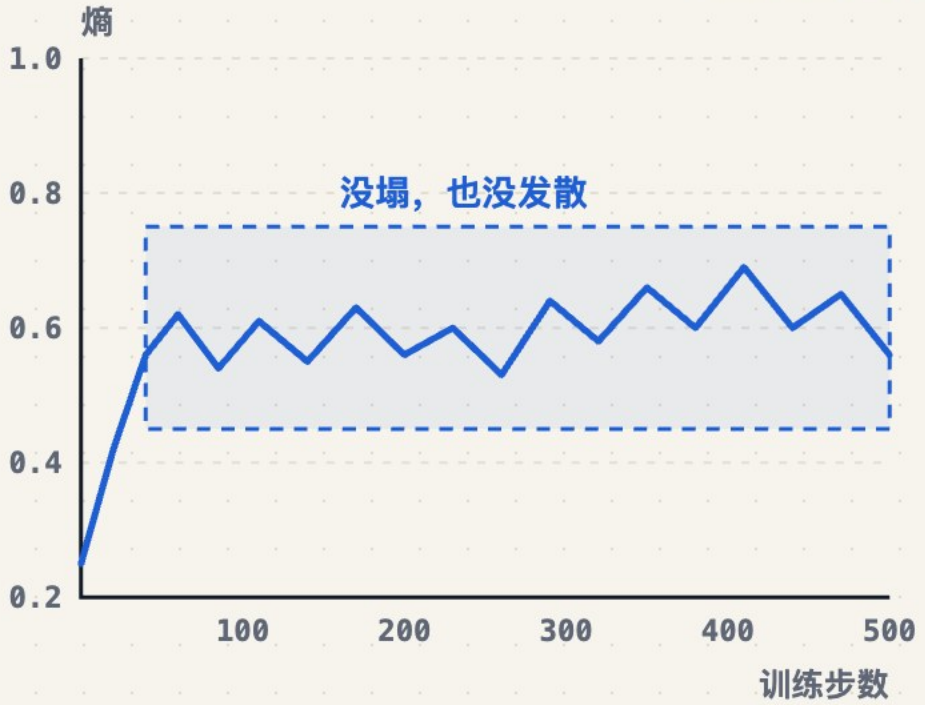


课件 p.82

通义的强化学习：奖励往上，熵稳定

按原图读数，约值







课件 p.83

开放式报告：奖励该衡量什么？

可验证的短答案

Allen Newell

✓ 答案对不对

精确匹配就够了

研究报告：
一个对错分数装不下

开放式综合

研究报告 没有标准答案

- 覆盖面
- 相关性
- 事实性
- 有引用支撑的论断

DR Tulu 开源的 8B 深度研究模型

配方：用演化细则做强化学习



课件 p.85

细则当奖励：逐条判，加权平均

问题 x
文献综合

策略 π_θ
搜索并推理

采样

y_1 · 报告 A

y_2 · 报告 B

y_3 · 报告 C

奖励 r_i → 更新策略

按细则评判

报告 A

细则从哪来？

- 细则 A w_1 ✓
- 细则 B w_2 ✓
- 细则 C w_3 ✗
- 细则 D w_4 ✓

$$r_i = \frac{\sum_k w_k \, \mathrm{Judge}(c_k, y_i)}{\sum_k w_k}$$

按权重加权平均

报告 A 的奖励

判定结果为示意

请专家写 太贵

只靠模型自己生成 容易出错 ResearchQA 已经看到了



课件 p.88

DR Tulu：细则和策略一起演化



每道题跑 8 份报告
拿来对比，写新细则

辅助奖励：格式 · 搜索 · 引用
除了细则，还有三个

权重：统一的分数 / 稍有不同的分数
专家之间也常对哪条最重要有分歧

图上只画了细则奖励，辅助奖励省略



课件 p.93

论文里的例子：从 rollout 里长出新细则

用户问题

怎么改造 T 细胞，改变它和巨噬细胞之间的细胞因子信号，用来治炎症性肠病？

三份 rollout

y_1 ……T 细胞通过 STAT3 激活抑制巨噬细胞 TNF-α……

y_2 ……全身 IL-6 没有升高……

y_3 ……一个抗炎信号增加了一个促炎信号，反而让整体炎症减轻……

新细则

正向细则

r_1 回答写到 STAT3 激活

正向细则

r_2 回答写到全身 IL-6 没有升高

负向细则

r_3 回答里含有错误的论断

现有细则里都没有 → 新的正向细则

这是错的 → 负向细则



课件 p.93

DR Tulu：分数追平，成本约千分之一



按原图读数，约值

DR Tulu-8B

约 66

略高于 OpenAI 的深度研究系统

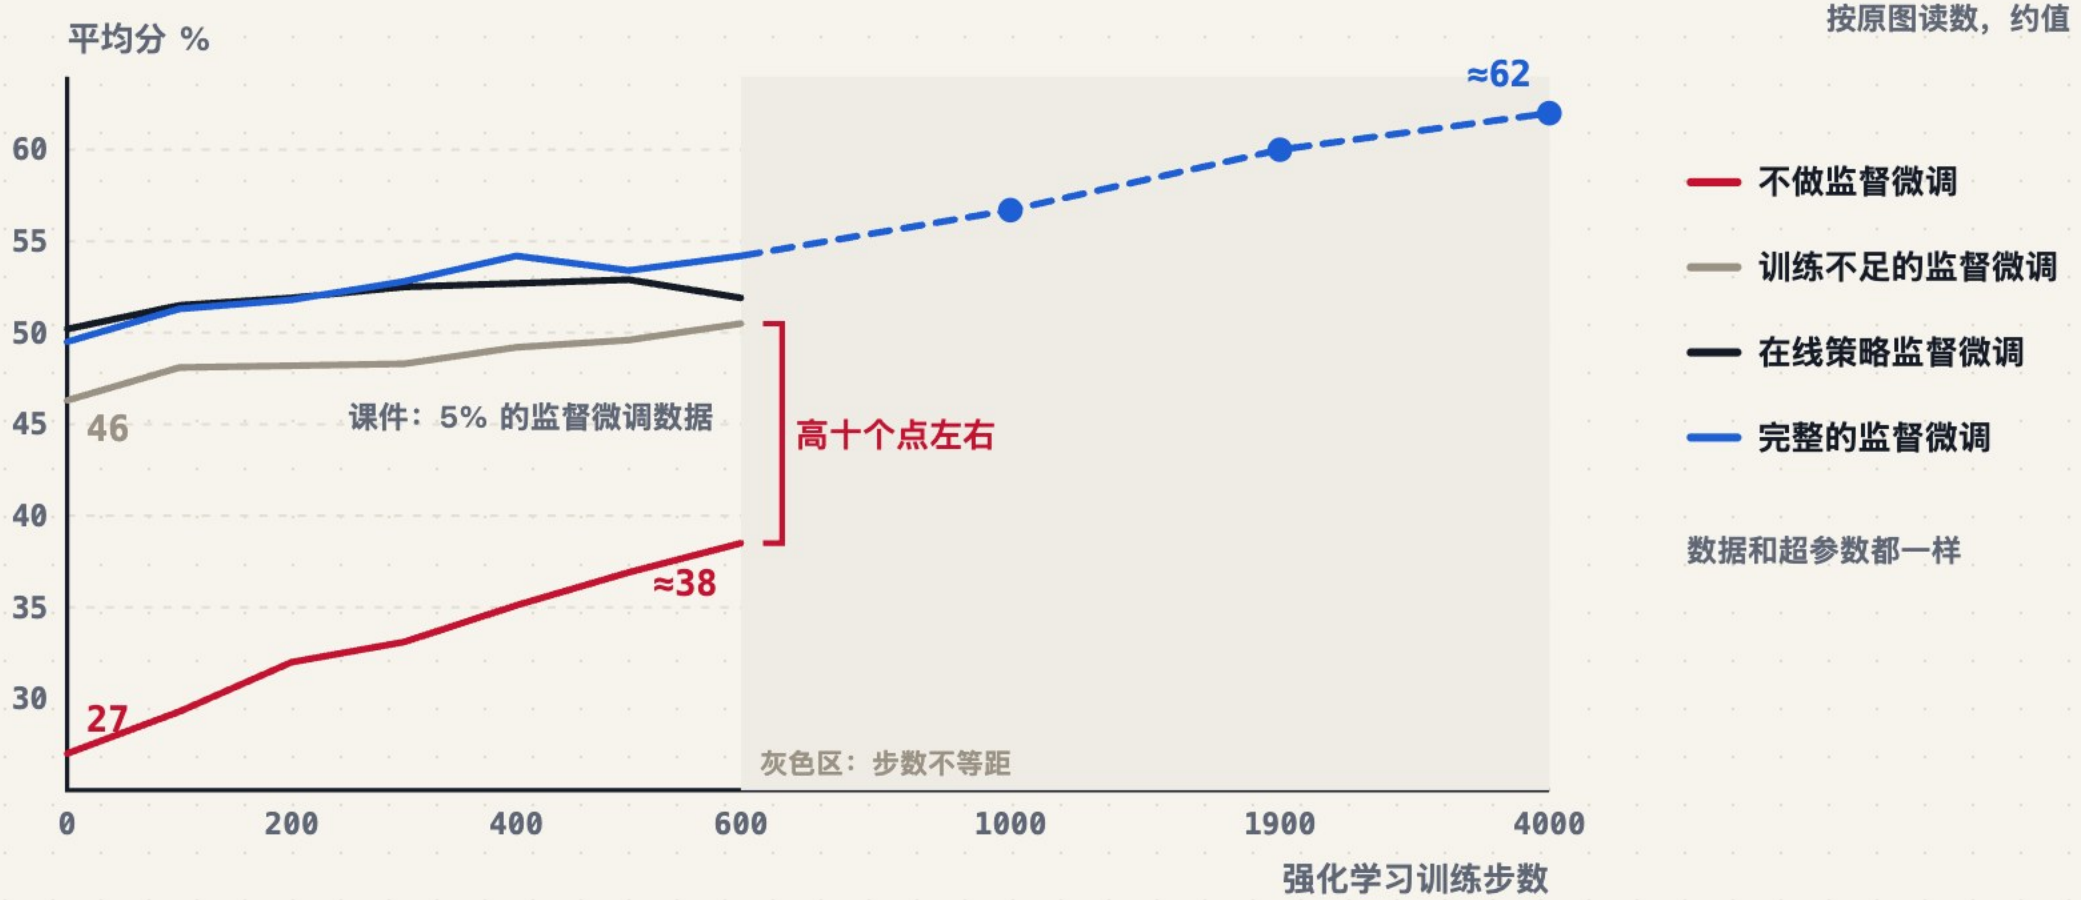
比 Tongyi DR 高 15.6 分

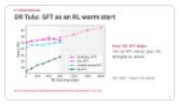
一个 8B 的小模型，在专门的任务上，**也能追平大得多的系统**



课件 p.94

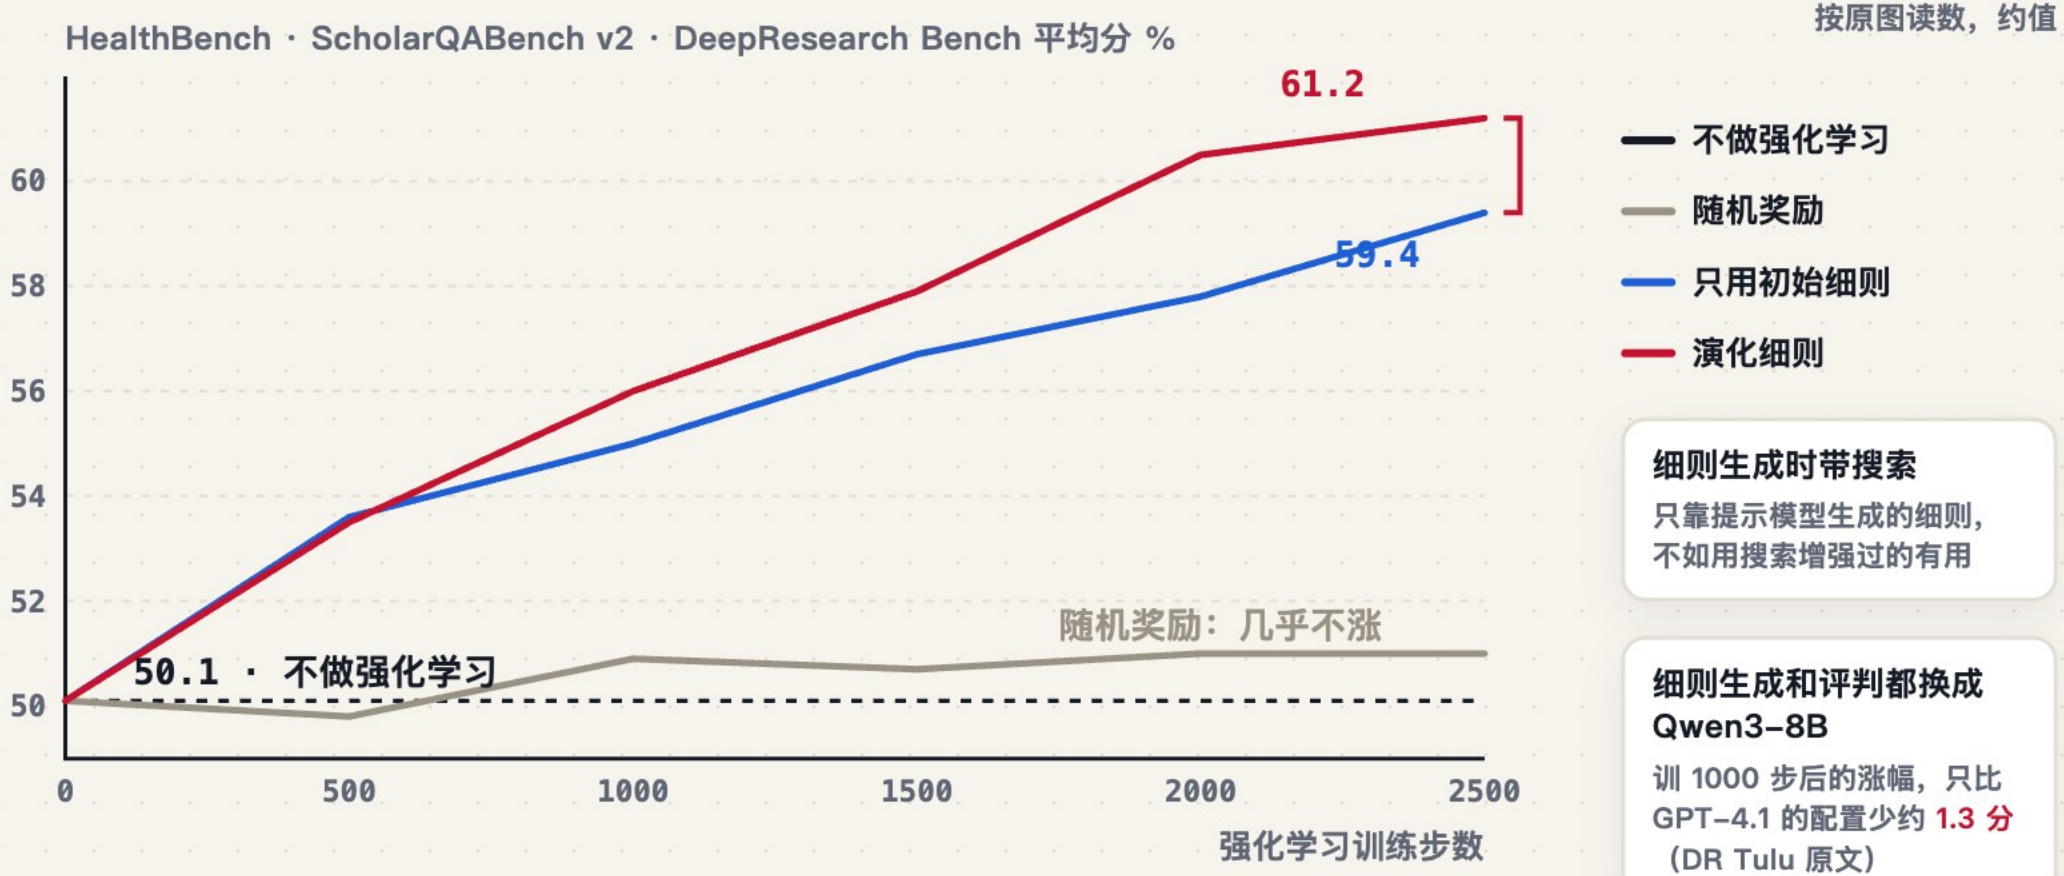
哪怕少量监督微调也有帮助





课件 p.95

演化细则：训得越久，差距越大

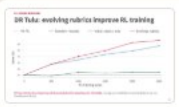


细则生成时带搜索

只靠提示模型生成的细则，不如用搜索增强过的有用

细则生成和评判都换成 Qwen3-8B

训 1000 步后的涨幅，只比 GPT-4.1 的配置少约 1.3 分（DR Tulu 原文）



课件 p.98

搜索工具

知道该从哪批文档里找

本地搜索

按词匹配
比如 BM25

嵌入模型
看向量相似度

Search-R1：嵌入检索 + 2018 年维基百科

题目更开放

黑盒接口

网页搜索
`web_search`

网页浏览
`browse`

通义、DR Tulu 还接了论文搜索

金融这类领域：自己建文档库，或者接更专门的接口



课件 p.100–104

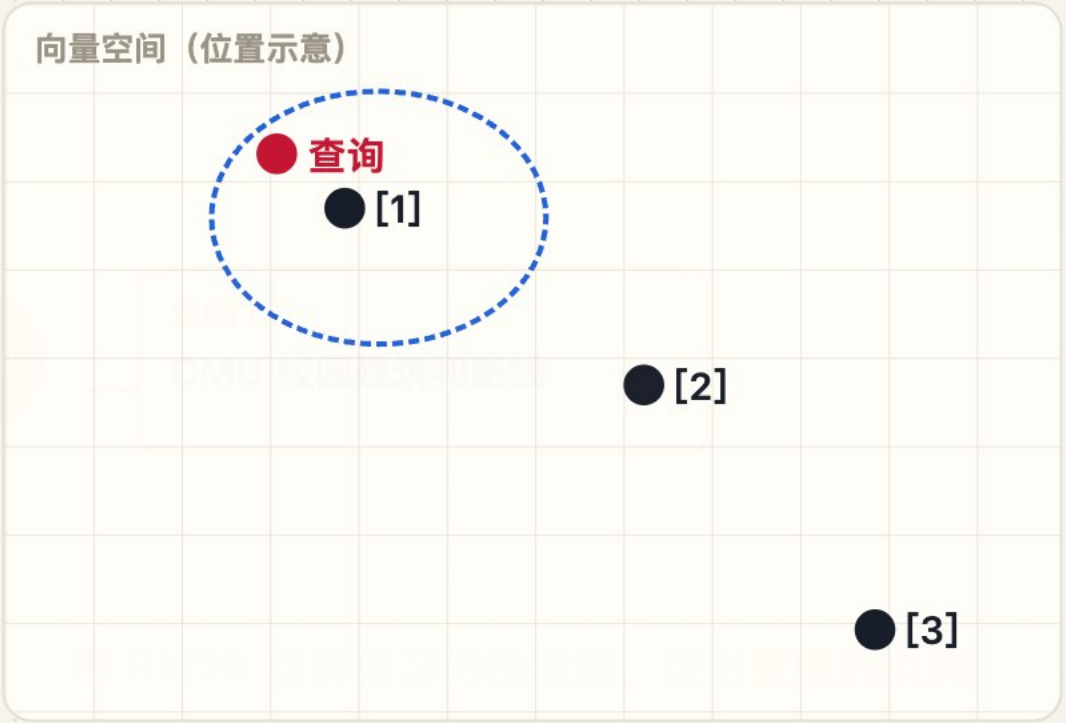
[1] Newell 和 Simon：1975 年图灵奖

[2] Simon：1978 年诺贝尔经济学奖

[3] CMU 校园建筑和路线

查询 谁和 Simon 一起获得了图灵奖?

→ 编码器



$$s(q, d) = E_Q(q) \cdot E_D(d)$$

点积越大越相关 · 取分数最高的几篇



课件 p.100–104

对比学习：拉近正例，推远负例

这一段记住一句

检索分本地和黑盒两类；嵌入检索靠向量距离，训练时拉近正例、推远负例。

负例从哪来 · 一

同一批里别的问题的正例：批内负例（DPR）

负例从哪来 · 二

用 BM25 这种更弱的检索器，挖出更难的负例



课件 p.100–104

原始任务

之前的推理

之前的查询

之前的证据

当前推理

最新查询

AgentIR

→ 排好序的文档

1 · 检索器的输入

当前推理 + 查询

2 · 检索器的训练

学会哪些文档对这一步推理有用

光是拼在一起就有提升，再专门训练，提升更多



课件 p.105–106

普通的检索训练

一个查询 → 标签已知

一个正例　若干负例

深度研究轨迹

中间那些搜索没有标签

第 1 轮 ?　第 2 轮 ?　第 3 轮 ?　… 这一轮哪些文档有帮助?

第 t 轮

查询

让 agent 真的跑一遍

→

检索结果

Doc 1–50

检索器返回的前 50 篇

→

加进来

整道题的答案文档

→

大模型重排

看着整道题的问题和答案

GLM-4.6

→

标签

排第一 → 正例

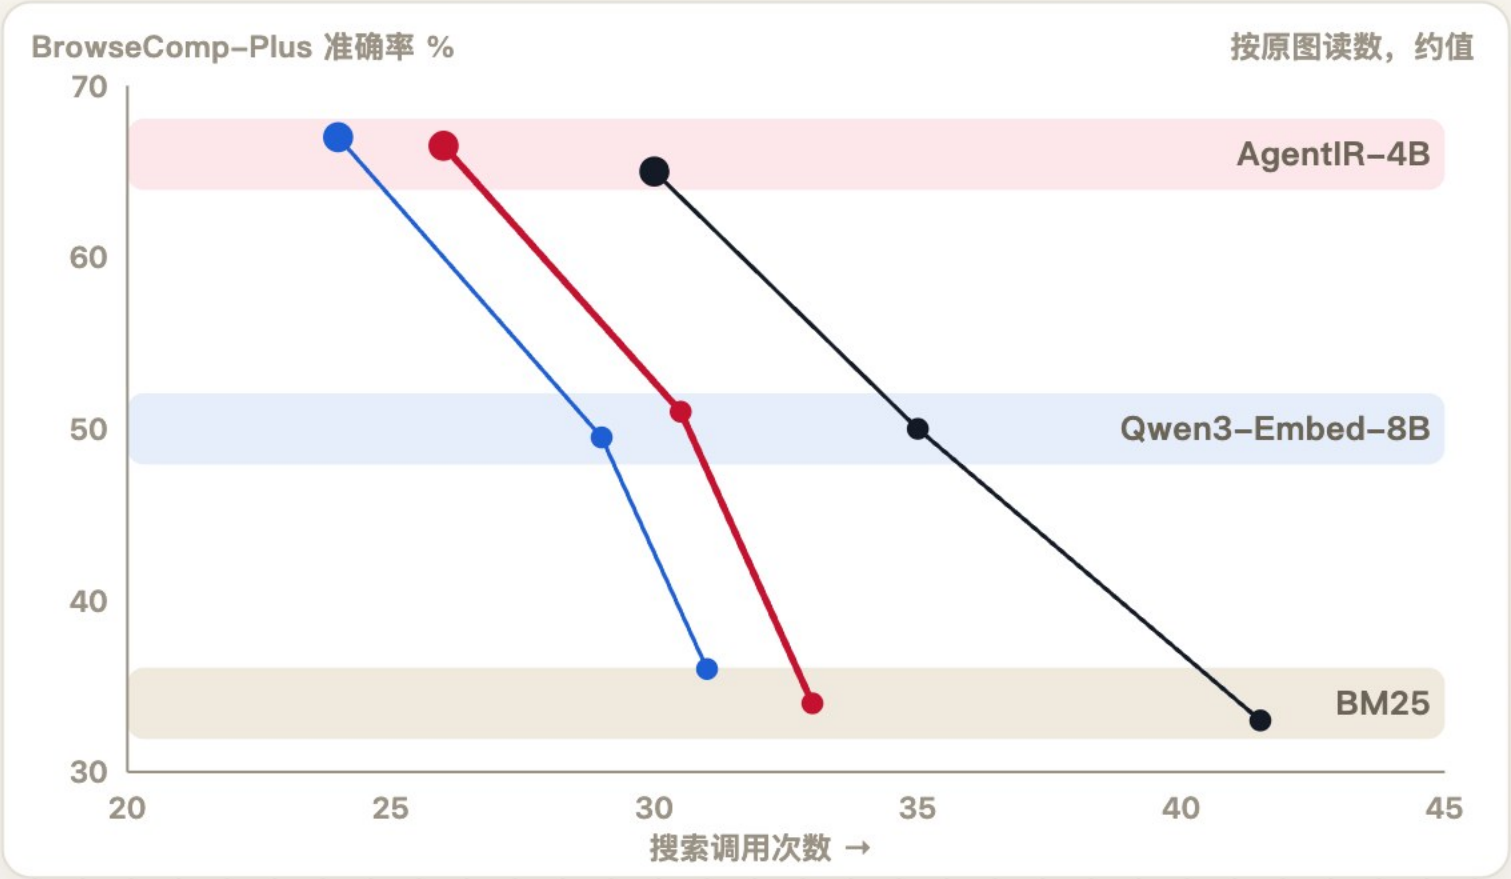
排最后 → 负例

DR-Synth：用来造这些中间标签



课件 p.107–111

准确率更高，搜得还更少



配通义 DeepResearch

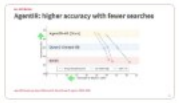
BM25 约 34% → Qwen3 8B 约 51% → AgentIR 约 66%

另外两个开源 agent

gpt-oss、GLM-4.7 同样走向

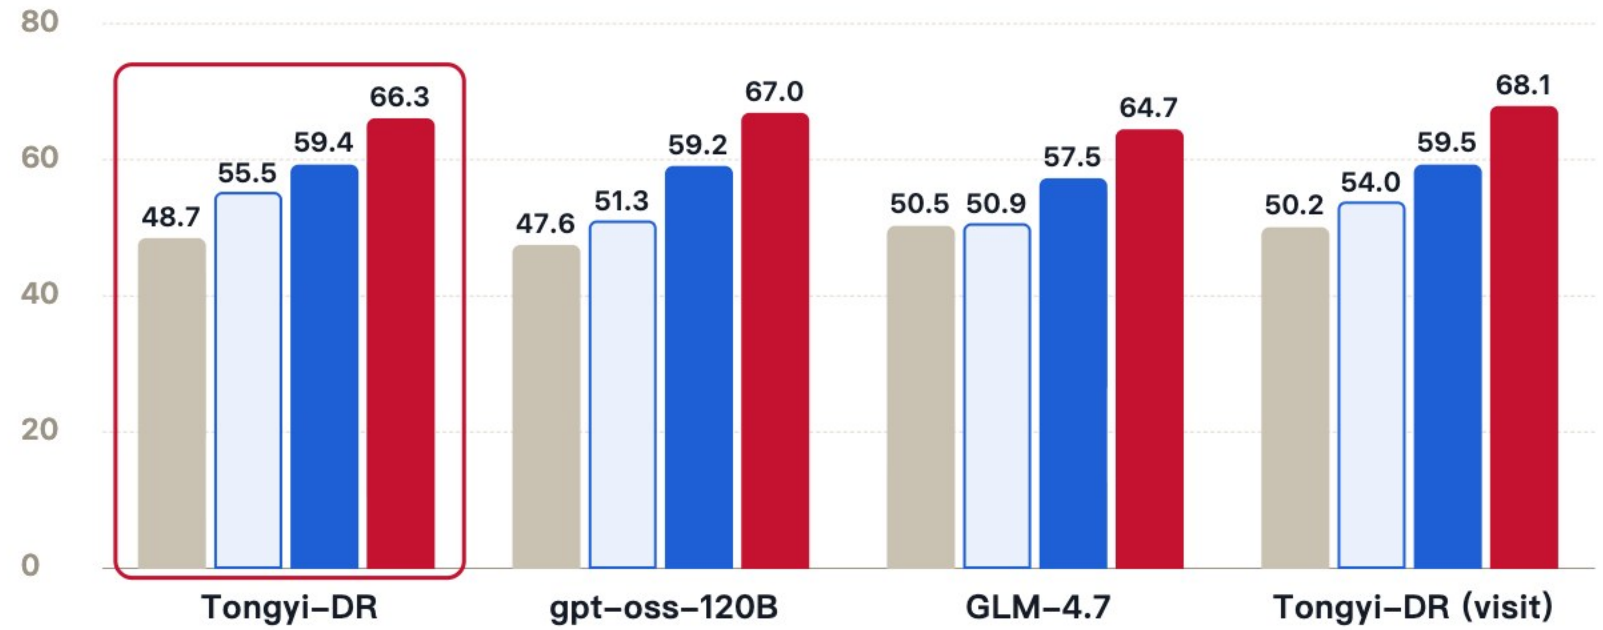
模型大小

AgentIR 4B · Qwen3 嵌入 8B，小一半



课件 p.112–114

两个部分都有帮助，合起来最高



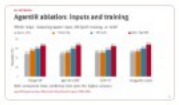
通义 DeepResearch 上

48.7 → 55.5 → 59.4 → 66.3

训练数据

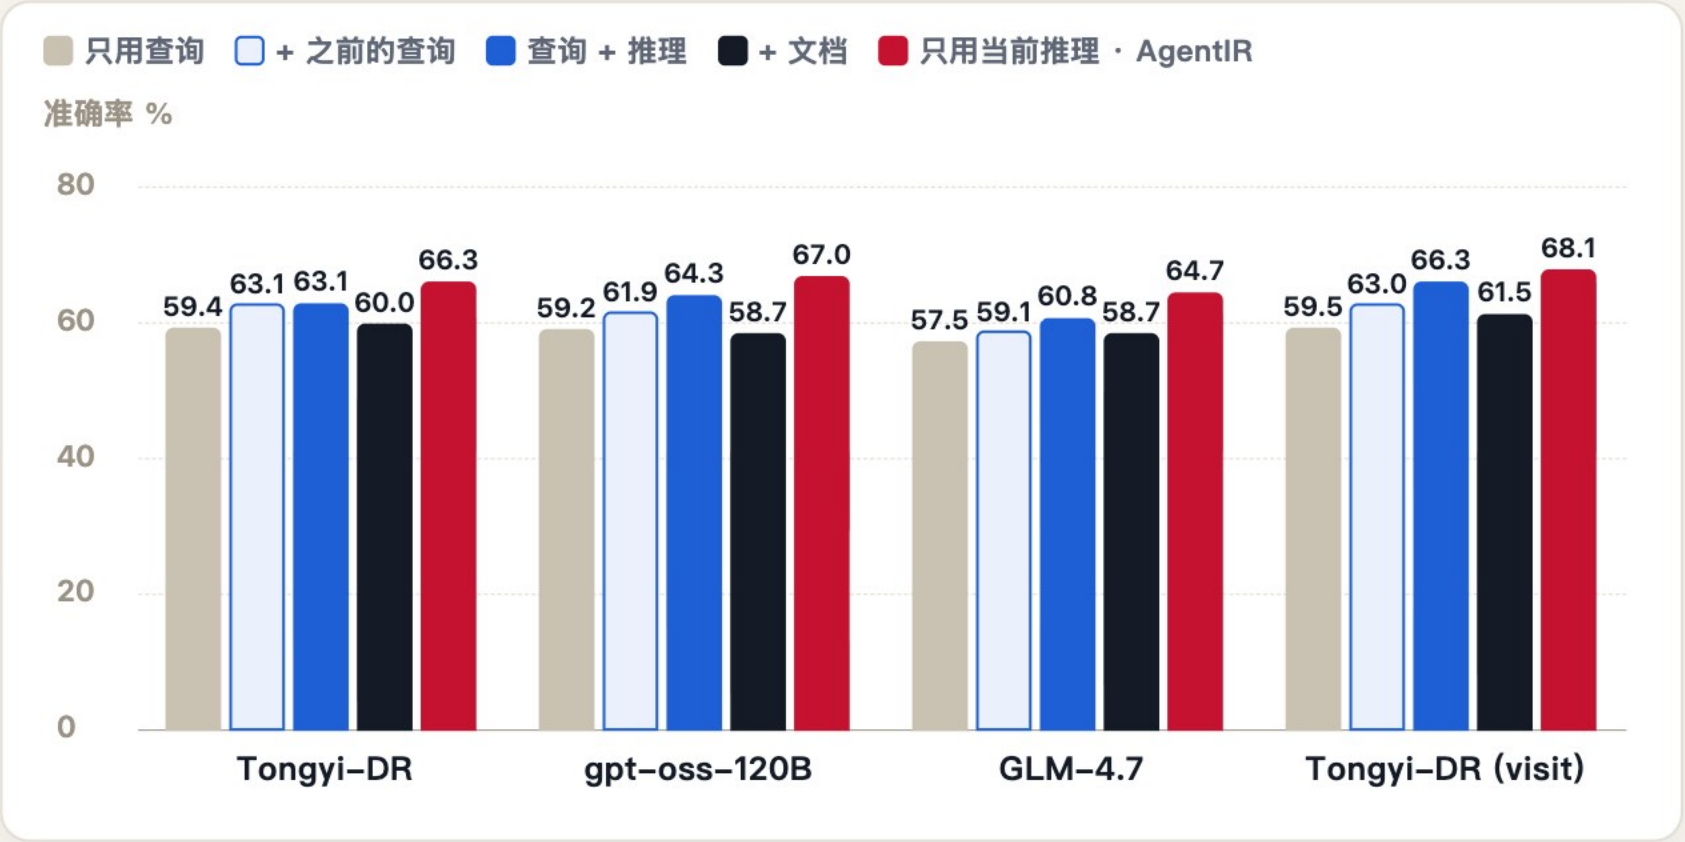
只用 WebShaper 的 500 道题，轨迹只来自通义

却能推广到别的 agent 和基准



课件 p.115–118

当前推理给出最强的信号



所有检索器都用 DR-Synth 训练

只改输入

整条轨迹都放进去

通义上 63.1 → 60.0，上下文太长

遗忘也是一种特性

当前推理已经总结好了，猜错的候选被略掉



课件 p.119–123

Q1 专门训练的 8B 小模型，和前沿大模型差在哪？

课上提问

BrowseComp 这类长程任务

前沿模型好得多

管长上下文 | 做计划 | 推理

差距大



开放式长篇基准

没看到大差距

HealthBench | ScholarQABench | DeepResearch Bench

也可能是评得还不够好



先想清楚目标基准和任务



课堂提问

Q2 深度研究 agent 现在最大的瓶颈是什么？

课上的回答：评测

短答案基准

BrowseComp 这类

知道目标就知道怎么优化，分数已经很高

开放式深度研究

做得少

连评它的好基准都没有



评测也是训练的基础

会评，才能

- 造大规模数据
- 拒绝采样
- 当奖励做强化学习

细则评测的偏差：偏向更长的回答

现在只评最终报告 → 还没测：帮人把事做成了多少？



课堂提问

Q3 评测时，怎么保证模型不是把答案背下来了？

课上提问

数据污染

最新的模型，背没背下答案不好说

数据污染?

不给搜索：课上的印象是还不到两成

还有一个坑

直接搜到原始数据集

搜索 → 原始数据集网站 → 答案

如 Hugging Face 上放的数据集

屏蔽名单：挡掉放数据集的网站

评搜索 agent，先把放数据集的网站屏蔽掉



课堂提问

深度研究 agent：四句话

01

任务

深度研究 = 很多次搜索 + 综合证据

搜索 × 很多次 → 综合

02

评测

既评回答质量，也评引用有没有支撑；细则本身也要审查

搜索 | 领域 | 细则 | 引用

03

训练

先从示范里学，再通过任务反馈改进

中训练
监督微调
强化学习

04

检索

把 agent 的信息需求交给检索器，并为它训练检索器

推理 + 查询 ↓ 检索器

开放问题：细则怎么做得更好 · 检索怎么为 agent 设计



课件 p.124

CMU 11–768 · AI AGENTS

第 10 讲 · 深度研究 agent

下一讲：第 11 讲 · 强化学习进阶算法

离策略数据 · 重要性加权 · 截断和 KL

每晚 20:00 更新



课件 p.124