32,200,000 token

彻底搞懂
强化学习进阶算法

全长 31 分钟 | 建议先收藏

强化学习三讲：这一讲讲算法

强化学习基础 · 第 9 讲

打基础

采样几次尝试
→ 打分
→ 更新策略

今天 · 第 11 讲

算法：五件事

1. 有用的反馈 — PPO 的另一个模型
2. 少等待
3. 稳定的更新 — 比值、截断和 KL
4. 可靠的奖励 — 奖励全相同没有梯度
5. 向老师学

下一讲 · 第 12 讲

强化学习系统

内存、并行
和大规模执行



课件 p.2

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

贯穿全讲的例子：修一个 bug

提示 修好重试设置。0 应该关闭重试，但代码返回了 3。其他情况保持不变。

修 bug · 编程 agent　第 6 讲 · 编程 agent

retry.py

```
def retry_count(config):
    return config.get("retries") or 3
```

验证器 · 四个测试（输入 → 期望输出）

输入	缺失	0	None	2
期望	3	0	3	2

0 是假值

`0 or 3 = 3`

四个全过 → **奖励 1**　否则奖励 0

数学题　网页导航　深度研究



课件 p.3（中文重绘）

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

一次尝试，就是一条轨迹 τ

修 bug · 编程 agent　第 6 讲 · 编程 agent

retry.py

```
def retry_count(config):
    return config.get("retries") or 3
```

验证器 · 四个测试（输入 → 期望输出）

输入	缺失	0	None	2
期望	3 ✓	0 ✓	3 ✓	2 ✓

轨迹 τ = agent 的动作 + 动作带来的观察

做一次这道题，连起来就是一条轨迹

多走了一圈

1 查看
读函数
0 变成了 3

→

2 修改
改默认值的处理
第一版补丁已保存

→

3 测试
跑四个测试
还有一个没过

→

4 再改
再改一次代码
第二版补丁已保存

→

5 再测
重跑四个测试
四个全过

$R = 1$

最终奖励：$R(\tau) = 1$（四个全过），否则 0



课件 p.4（中文重绘）

训练：反复转一个循环

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

采样

让 agent 做题，收集轨迹 τ

x 任务（初始状态和提示）
θ 策略的参数
τ 一条轨迹

打分

验证器给每条轨迹一个奖励 R(τ)

更新

用奖励改策略的参数 θ

用更新后的策略
接着做

$$J(\theta) = \mathbb{E}_{\tau \sim p_\theta(\cdot|x)}[\, R(\tau) \,]$$

目标：让这道题上的平均奖励尽量高

第 9 讲的 REINFORCE、GRPO 都为这个目标服务



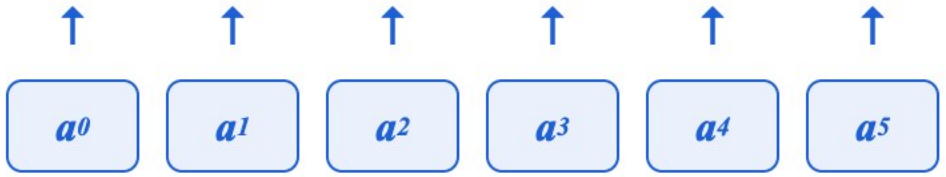
课件 p.5（中文重绘）

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

最朴素的 REINFORCE

成功的尝试

四个测试全过：$R(\tau) = 1$



每一步动作的概率往上推

失败的尝试

至少一个没过：$R(\tau) = 0$



乘出来是 0，不产生更新

一条轨迹的损失 $\mathcal{L}_{\mathrm{PG}} = -R(\tau)\sum_t \log \pi_\theta(a_t \mid h_t)$

h_t：任务、之前的动作和观察

方差很大 → 优化很难

失败的尝试全都白跑了

奖励只有 1 和 0



课件 p.6（中文重绘）

同一道题采四次，组内比较

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

尝试	最终测试	奖励 R(τ)	奖励 − 基线
1	四个全过	1	1 − 0.25 = +0.75
2	至少一个没过	0	0 − 0.25 = −0.25 ↓ 往下压
3	至少一个没过	0	0 − 0.25 = −0.25 ↓ 往下压
4	至少一个没过	0	0 − 0.25 = −0.25 ↓ 往下压

只减均值，不除以标准差：第 9 讲 DrGRPO 的写法

修 bug · 编程 agent　第 6 讲 · 编程 agent　× 4

retry.py

```
def retry_count(config):
    return config.get("retries") or 3
```

验证器 · 四个测试（输入 → 期望输出）

输入	缺失	0	None	2
期望	3 ✓	0 ✓	3 ✓	2 ✓

基线 = 组内平均

(1 + 0 + 0 + 0) / 4 = 0.25

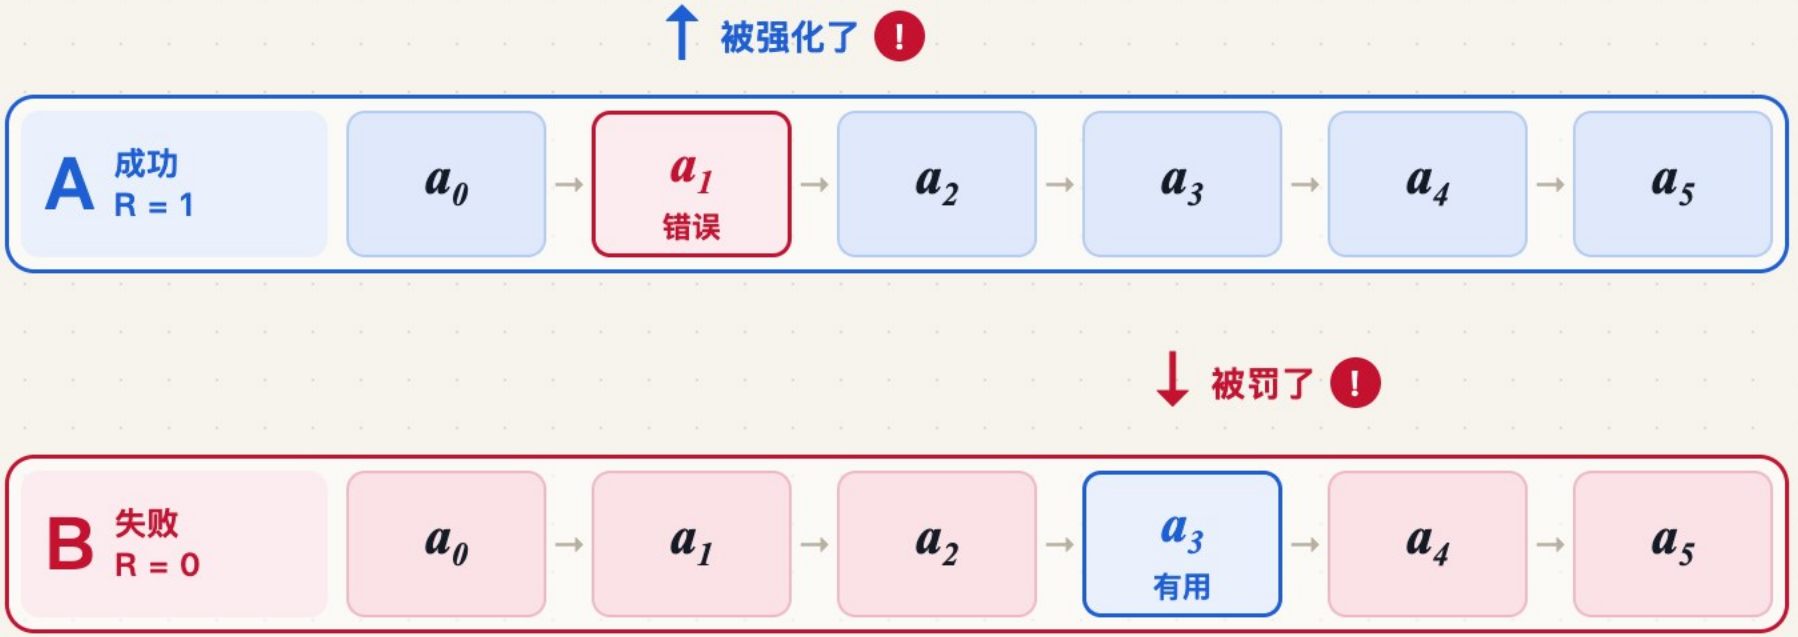
失败的尝试也有贡献：动作拿到 负权重 ，概率被往下压



课件 p.8（中文重绘）

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

成功里有错，失败里有好的一步



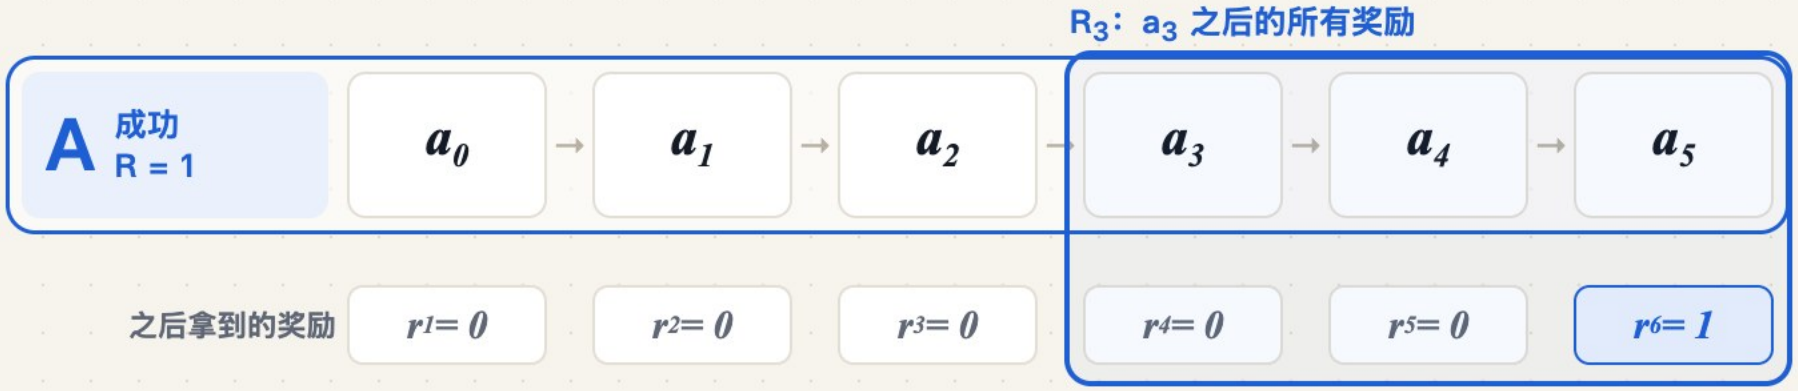
每一轮有自己的奖励 →知道该强化哪几轮



课件 p.9（中文重绘）

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

reward-to-go：从某一步往后还能拿多少



从 a_3 之前往后加

$$R_3 = r_4 + r_5 + r_6 = \quad 0 \; + \; 0 \; + \; 1 \quad = 1$$

只有终局奖励：A 前五步拿到的都是 0，最后才拿到 1



课件 p.10（中文重绘）

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

两条轨迹的 reward-to-go：分不出来

A 成功 R = 1

	a_0	a_1 错误	a_2	a_3	a_4	a_5
reward-to-go	$R_0 = 1$	$R_1 = 1$	$R_2 = 1$	$R_3 = 1$	$R_4 = 1$	$R_5 = 1$

B 失败 R = 0

	a_0	a_1	a_2	a_3 有用	a_4	a_5
reward-to-go	$R_0 = 0$	$R_1 = 0$	$R_2 = 0$	$R_3 = 0$	$R_4 = 0$	$R_5 = 0$

?

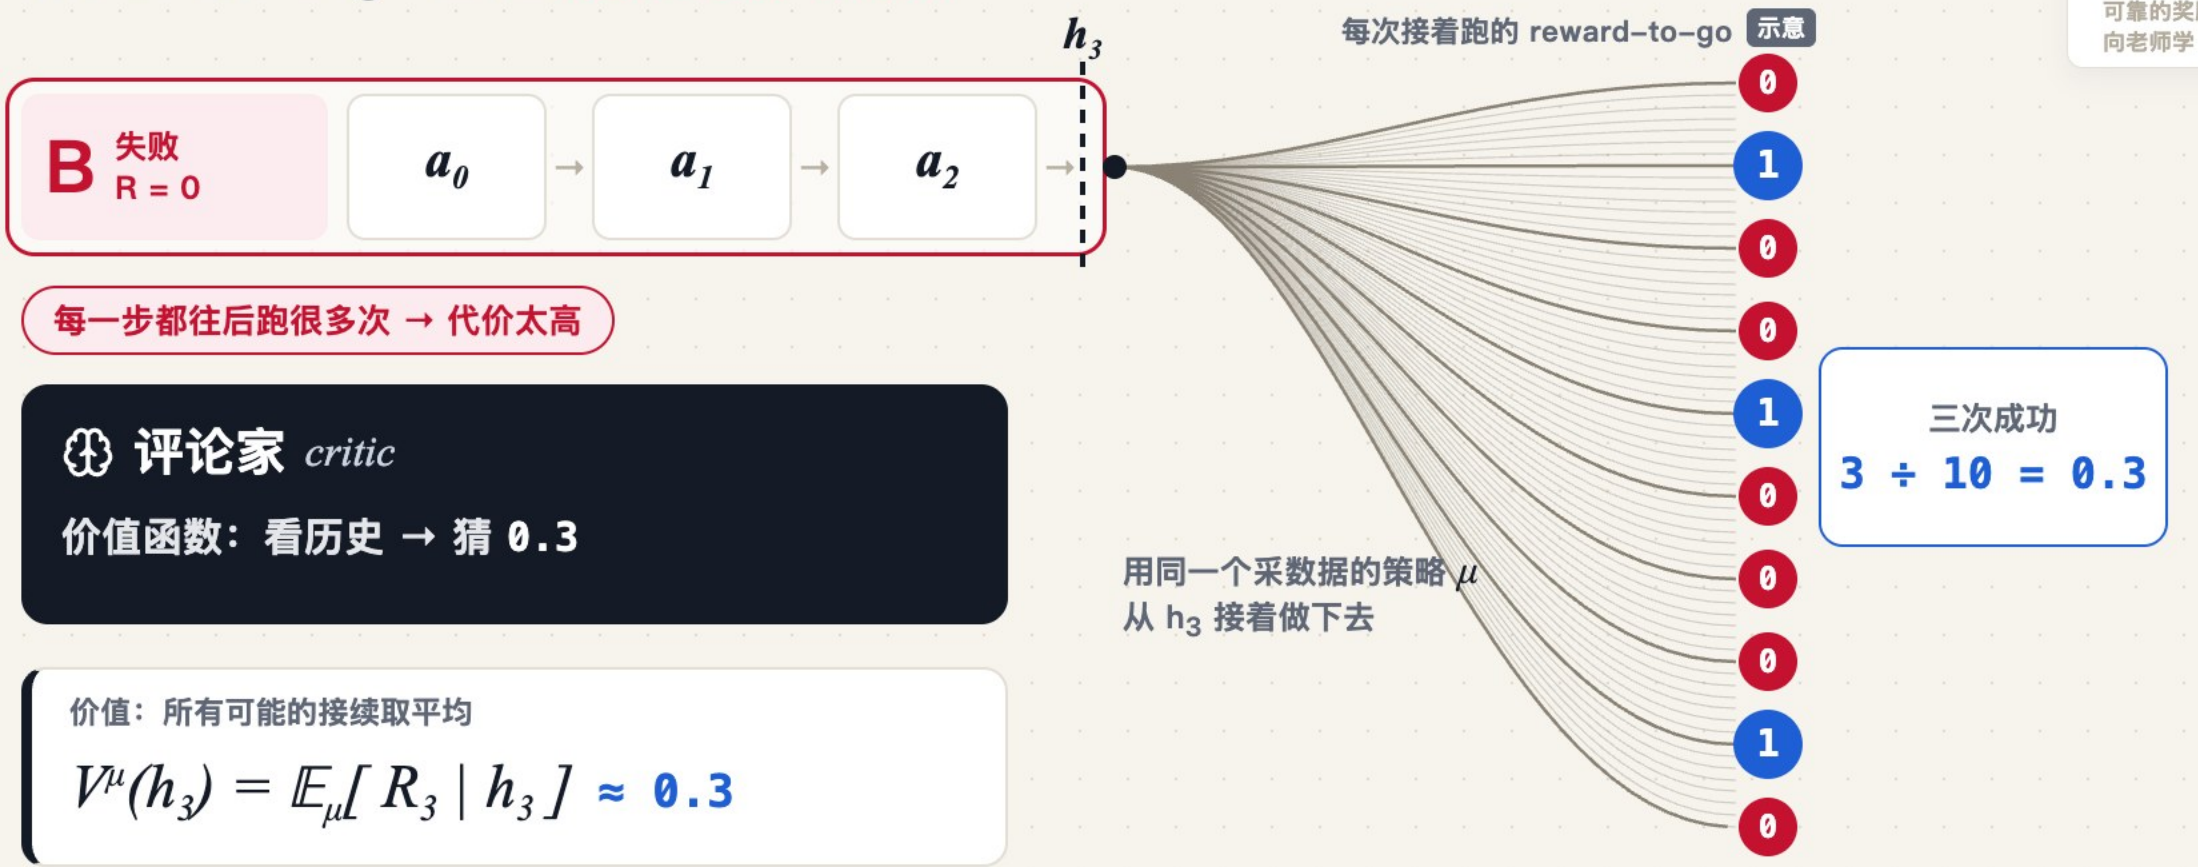
分不出来



课件 p.11（中文重绘）

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

从 B 的 h_3 往后接着跑十次



每一步都往后跑很多次 → 代价太高

评论家 *critic*

价值函数：看历史 → 猜 0.3

价值：所有可能的接续取平均

$$V^{\mu}(h_3) = \mathbb{E}_{\mu}[\, R_3 \mid h_3 \,] \approx 0.3$$



课件 p.12（中文重绘）

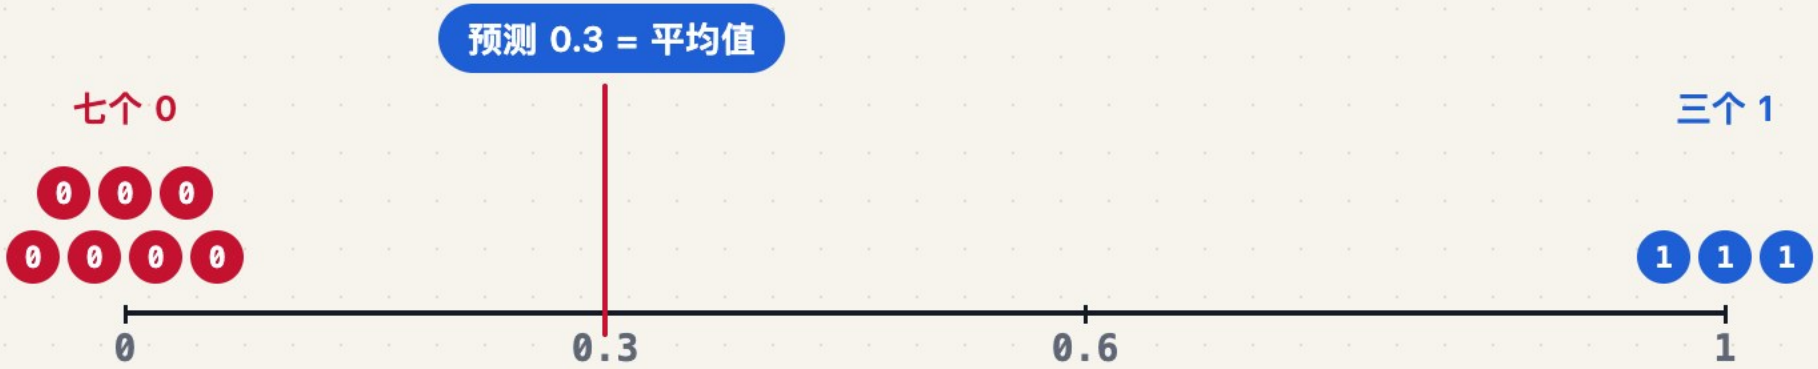
- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

用平方误差训评论家

评论家的损失 $\mathcal{L}_V(\varphi) = \mathbb{E}_t[\,(V_\varphi(h_t) - R_t)^2\,]$

V_φ：看历史猜的分

R_t：实际拿到的



平均平方误差 **0.21** 最小

用平方误差训练基线：MIXER 这类工作里就有了



课件 p.13（中文重绘）

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

评论家的两种搭法

单独的价值网络

历史 h_t

↓

价值网络 φ

自己的主体和输出层

↓

预测 $V_\varphi(h_t)$

价值损失训练整个价值网络

例子：InstructGPT　单独的 6B 模型 · 从奖励模型初始化

缺点：要同时训两个模型

策略主体上挂一个价值头

历史 h_t

↓

策略主体（θ 的一部分）　← 策略损失训练主体

截断梯度

↓

线性价值头 φ　几乎不加参数

↓

预测 $V_\varphi(h_t)$

价值损失 × 挡在主体前面

价值损失只训练这个头

例子：MIXER

不管哪种搭法，评论家都可以和策略一起训



课件 p.14（中文重绘）

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

课上有人问

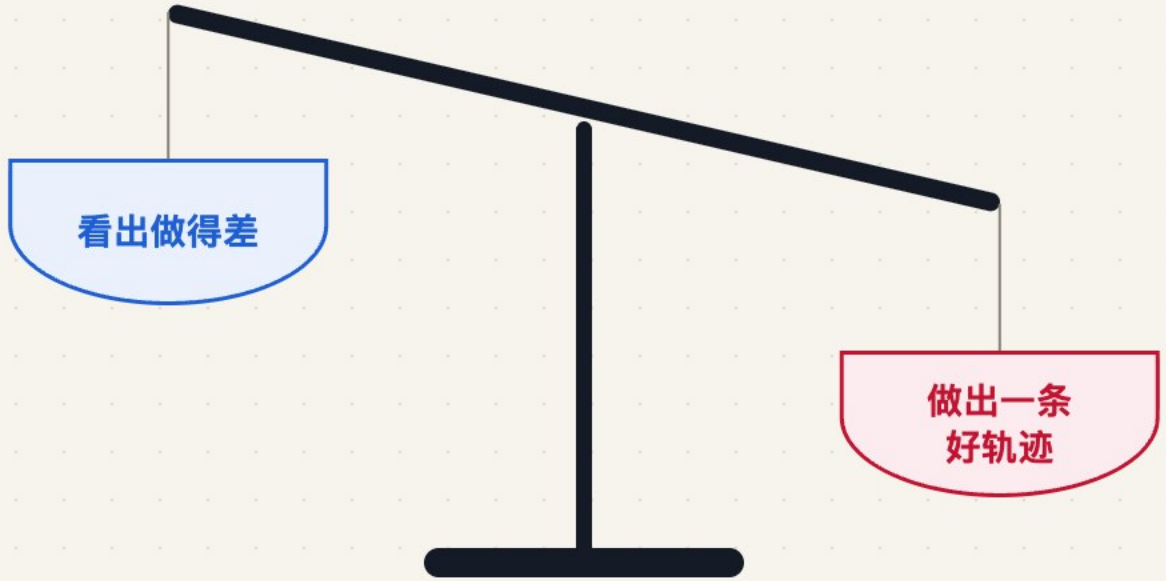
模型能判断做得好不好，
为什么不直接做对？

一 价值函数只看历史，不看动作

它判断的是这个局面好不好，
不是这个动作好不好

二 看出做得不好，往往容易得多

区分好轨迹和坏轨迹，
比真的生成一条好轨迹容易

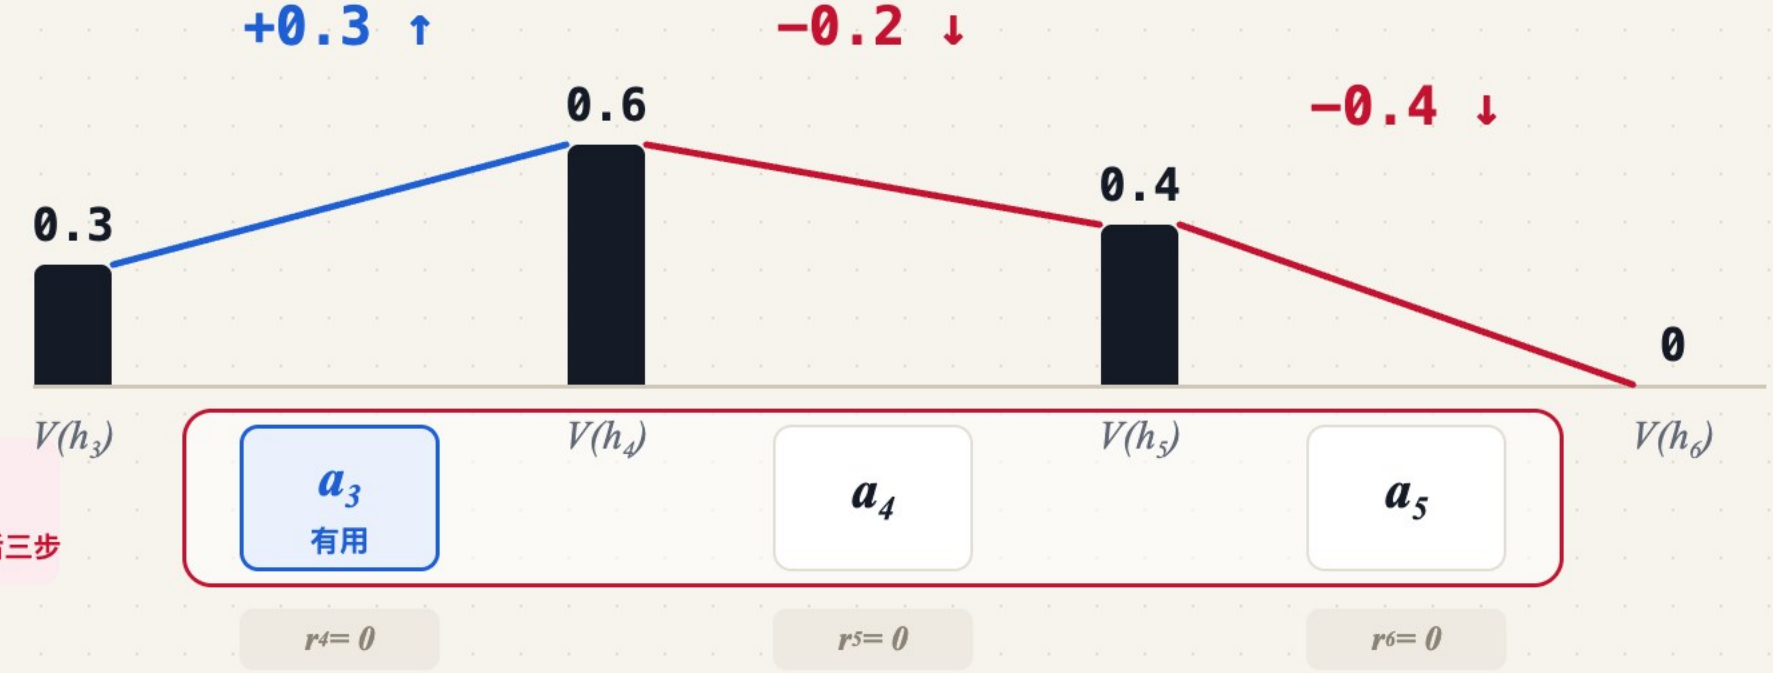




课上提问（p.14 处）

- 有用的反馈
  - 少等待
  - 稳定的更新
  - 可靠的奖励
  - 向老师学

一步做完前后，评论家的分数变了多少



B

失败 · 最后三步

时序差分误差（TD 误差），不打折

$$\delta_t = r_{t+1} + V_\varphi(h_{t+1}) - V_\varphi(h_t)$$

示意

删掉代码库

价值一下掉到 0

0



课件 p.15（中文重绘）

- 有用的反馈
- 少等待
- 稳定的更新
- 可靠的奖励
- 向老师学

GAE：把后面的涨跌打折加回来

广义优势估计 · PPO 用的就是它

奖励折扣 γ = 1，这个例子不打折

a_3

$\delta_3 = +0.3$

权重 1

a_4

$\delta_4 = -0.2$

× 0.5

a_5

$\delta_5 = -0.4$

× 0.25

衰减系数 $\lambda = 0.5$：每往后一步，权重减半

B 的 a_3 的功劳

$$\hat{A}_3 = 0.3 + 0.5(-0.2) + 0.25(-0.4)$$

0.1

GAE 从后往前递推，最后一步后面没有误差

$$\hat{A}_t = \delta_t + \lambda \hat{A}_{t+1}$$

$\lambda = 0$：只看这一步自己的误差 δ_t

$\lambda = 1$：往后的总奖励 − 这一步的价值



课件 p.16（中文重绘）

过程奖励模型：标出每一步对不对

一个分数的分母比分子的 3 倍少 7，分数等于 2/5，分子是多少？答案 14

- ✓ 设分子为 x
- ✓ 那么分母是 3x − 7
- ✓ 已知 x / (3x − 7) = 2/5
- ✓ 所以 5x = 2(3x − 7)
- ✓ 5x = 6x − 14
- ✗ 所以 x = 7　　应为 x = 14

- 有用的反馈
- 少等待
- 稳定的更新
- 可靠的奖励
- 向老师学

PRM800K

80 万条步骤级人工标注

过程奖励模型

开个好头

价值函数

用得没那么广：价值能在训练里**顺带学出来**；标注**够多**，训练会**更快**



课件 p.17（中文重绘）

同步：一批轨迹全部跑完才更新

有用的反馈
• 少等待
稳定的更新
可靠的奖励
向老师学

生成轨迹 更新策略 等待 示意



给 agent 做强化学习可能非常慢

也可以几个 agent 共用一块 GPU 上的同一个推理服务

同步的好处：完全在线策略

做生成的策略 = 正在更新的策略



课件 p.19（中文重绘）

异步：边生成边更新，从不干等



更新的同时，生成照样往下走 · 从不干等

代价：一部分数据出自更新前的旧策略

AReaL：用一个参数限制数据最多能有多旧 · 设成 0 就退回同步

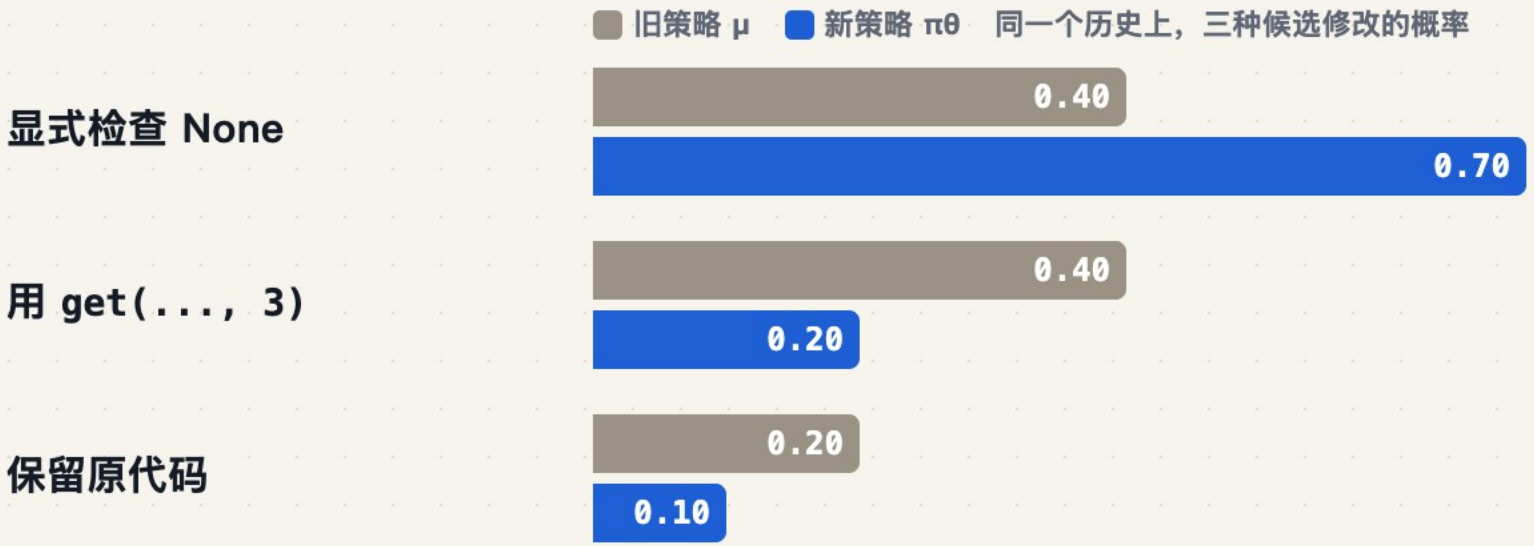


课件 p.20（中文重绘）

先分清两个策略

旧策略 μ 采数据

新策略 π_θ 正在学



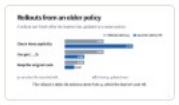
想要：按**新策略 π_θ** 来算平均奖励

手上：数据是按**旧策略 μ** 采的

记录下来的这条轨迹 · 由 μ 采样

a^0 a^1 a^2 a^3 a^4 a^5

已过时



课件 p.22（中文重绘）

重要性采样：给每个样本乘一个系数

在同一个历史 h 上

$$\mathbb{E}_{a\sim\pi_\theta}[\,R(a)\,] = \mathbb{E}_{a\sim\mu}\left[\,\frac{\pi_\theta(a\mid h)}{\mu(a\mid h)}\cdot R(a)\,\right]$$

旧策略 μ　新策略 πθ

正确的修改



系数 = 0.70 / 0.40

1.75

不完整的修改



系数 = 0.20 / 0.40

0.50

$R(a)$：这个例子里，做了动作 a 之后最终的奖励

新策略更爱选的 → 放大

更不爱选的 → 缩小



课件 p.23（中文重绘）

长轨迹上，系数一步步连乘

整条轨迹的系数：动作 a_t 接在历史 h_t 后面

$$w(\tau \mid x) = \frac{p_\theta(\tau \mid x)}{p_\mu(\tau \mid x)} = \prod_t \frac{\pi_\theta(a_t \mid h_t)}{\mu(a_t \mid h_t)}$$

环境那部分在分子分母里一样，约掉了

1.05 × 1.05 × 1.05 × 1.05 × 1.05 × 1.05 × 1.05 × 1.05 × 1.05 × 1.05 × 1.05 × 1.05 × … 乘一百步

1.05^{100}

$\approx$ **132**

≈ 132 倍 · 方差大

少数几个样本就能主导整次更新

一条 agent 轨迹：常有五六万个 token →

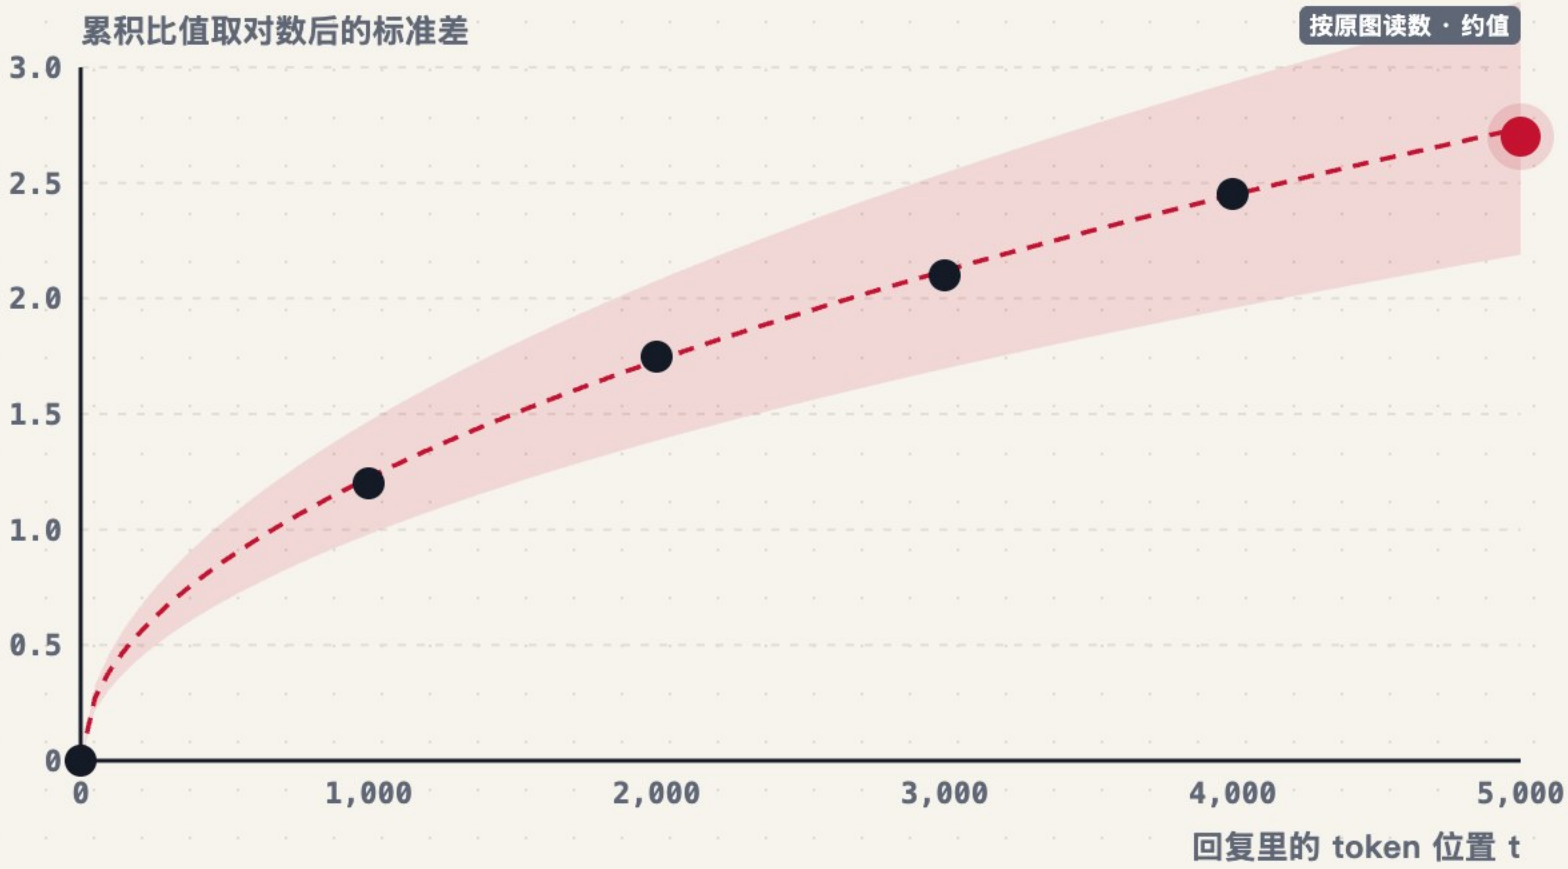
一百步 ↑



课件 p.24（中文重绘）

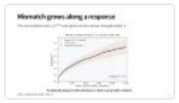
有用的反馈
少等待
稳定的更新
可靠的奖励
向老师学

越往后，偏差散得越开



方差随位置线性增长
→ 标准差按 √t 增长

CTPO 在使用工具的数学题上实测



课件 p.25（中文重绘）

有用的反馈
少等待
• 稳定的更新
可靠的奖励
向老师学

前面的动作，改变后面的历史

前面的修改

加一个 None 检查

μ 40% → πθ 10%

→

记录下来的历史

代码里现在有这个检查

→

下一个动作

跑测试

μ 50% · πθ 50%

这一步比值是 1，但走到这里只有 0.25 倍

0.10 / 0.40 = 0.25

只看当前动作的比值 → 漏掉这部分偏差

前面的影响一层层叠起来 → 也能乘出非常大的数



课件 p.26（中文重绘）

各个算法用哪些动作算权重

方法	回复里记录的动作 →	权重用的是
PPO / GRPO	a^0 a^1 **a^t** a^{t+1} a^{T-1}	当前这一个动作
CTPO	**a^0 a^1 a^t** a^{t+1} a^{T-1}	开头到当前的动作
完整比值	**a^0 a^1 a^t a^{t+1} a^{T-1}**	所有动作
GSPO	**a^0 a^1 a^t a^{t+1} a^{T-1}**	所有动作 · 按长度归一化

DAPO、CISPO 也只看当前动作，区别在截断规则



课件 p.27（中文重绘）

旧数据可能拿到巨大的权重



最大离策略程度：正在更新的数据和生成它的策略之间，最多隔了几次更新

蓝线 = 1 只能用上一个版本的数据

红线 = 3 最多可以隔三次

之后还有好几次几百倍的尖峰

模型输出 示意

输出忽长忽短

训练曲线

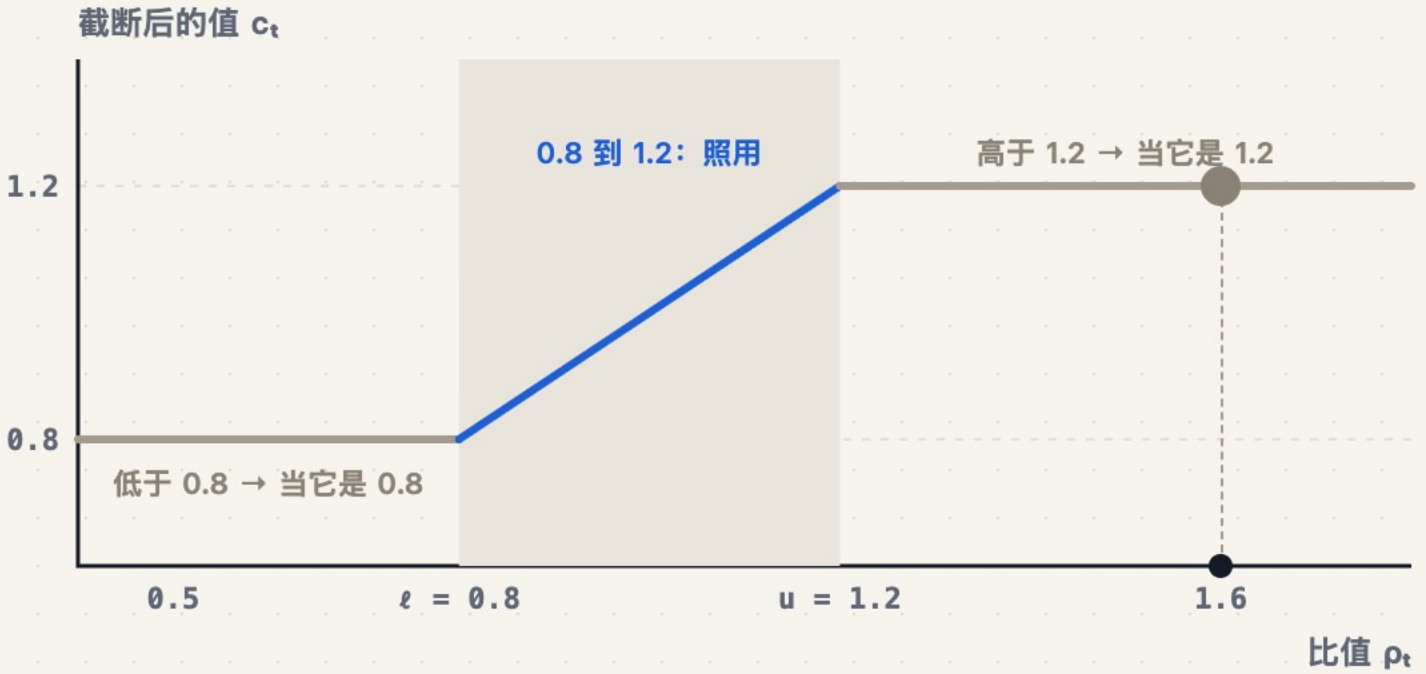


课件 p.29（中文重绘）

把比值截断

一个采样出的 token：ρ_t = 新策略的概率 / 旧策略的概率；ℓ 是下界，u 是上界

$$c_t = clip(\rho_t, \ell, u)$$



比值 ρ **1.60**

截断后 c **1.20**

当它是 1.2

PPO 的标准设置

ℓ = 0.8 · u = 1.2



课件 p.30（中文重绘）

截断后的比值，两种用法

PPO

$$J_{PPO}(\theta) = \mathbb{E}_t[\ \min(\ \rho_t \hat{A}_t,\ c_t \hat{A}_t\ )\ ]$$

取保守的一边

比值已经很高的地方，就不再继续更新了

CISPO

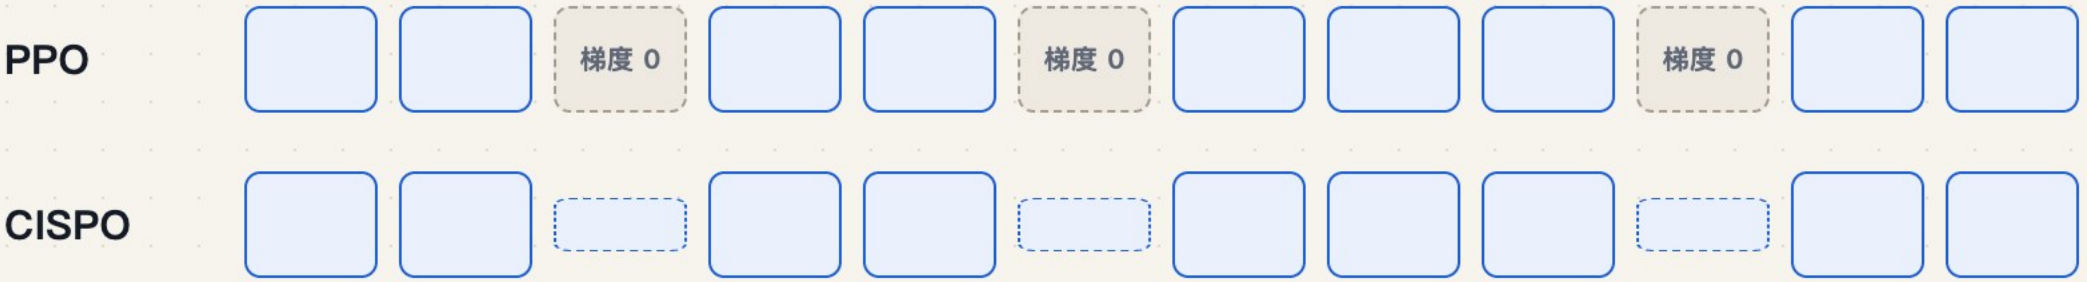
$$J_{CISPO}(\theta) = \mathbb{E}_t[\ sg(c_t)\ \hat{A}_t \log \pi_\theta(u_t \mid u_{<t})\ ]$$

截断后的比值当固定权重

出自 MiniMax-M1

原文实验里没设下界，只调了上界，也没有加 KL 惩罚

示意 · 一排采样出的 token，虚线框是比值超出范围、被截断的



被截断的格子变细：权重被压住，梯度还在

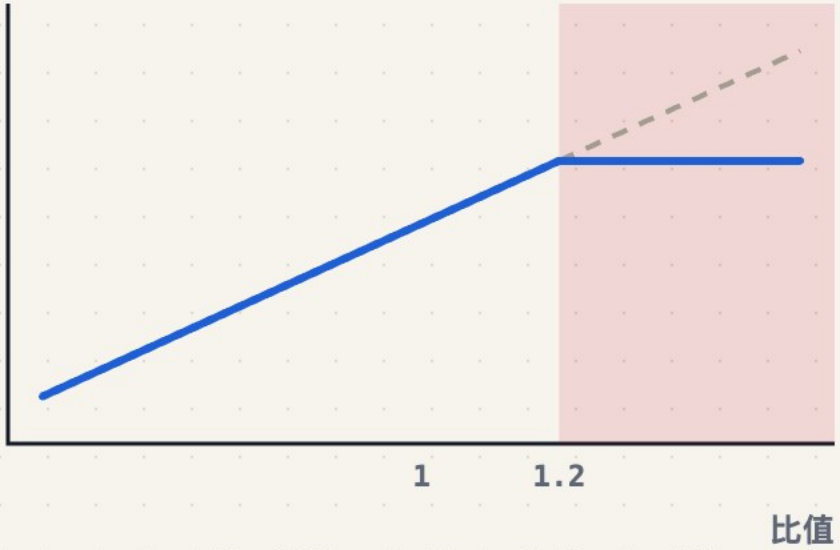


课件 p.31（中文重绘）

有用的反馈
少等待
• 稳定的更新
可靠的奖励
向老师学

PPO 的取最小，画出来是这样

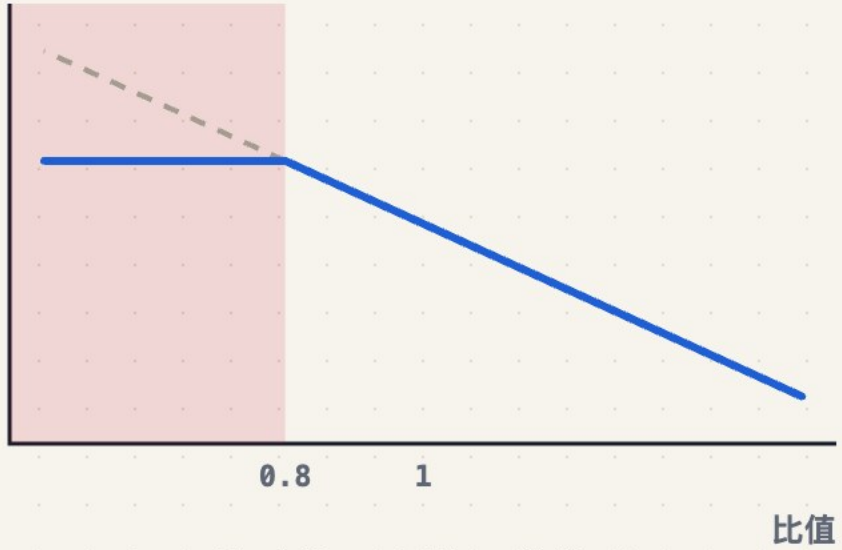
正优势 A = +1



有用的动作：多选两成就别再推

比值到 1 + ε = 1.2 后变平

负优势 A = −1



没用的动作：少选两成就别再压

比值到 1 − ε = 0.8 后变平

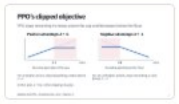
PPO 的目标（取最小之后）

不截断时会继续的部分

截断区

$\varepsilon = 0.2$ · 截断的余量

挡住权重的疯狂尖峰，不让一个样本把模型带跑



课件 p.32（中文重绘）

第二根绳子：参考模型

在目标后面减一项：当前策略离参考模型越远，扣得越多

$$\max_{\theta} J - \beta D_{KL}(\pi_\theta \| \pi_{ref})$$

旧策略 μ

采数据
给重要性比值当分母

新策略 π_θ

在学

参考模型 π_{ref}

拴住它的锚
一开始初始化的模型 · 训练中固定不动

InstructGPT

每个 token 相对监督微调模型的 KL 惩罚

CISPO DAPO

没有这一项



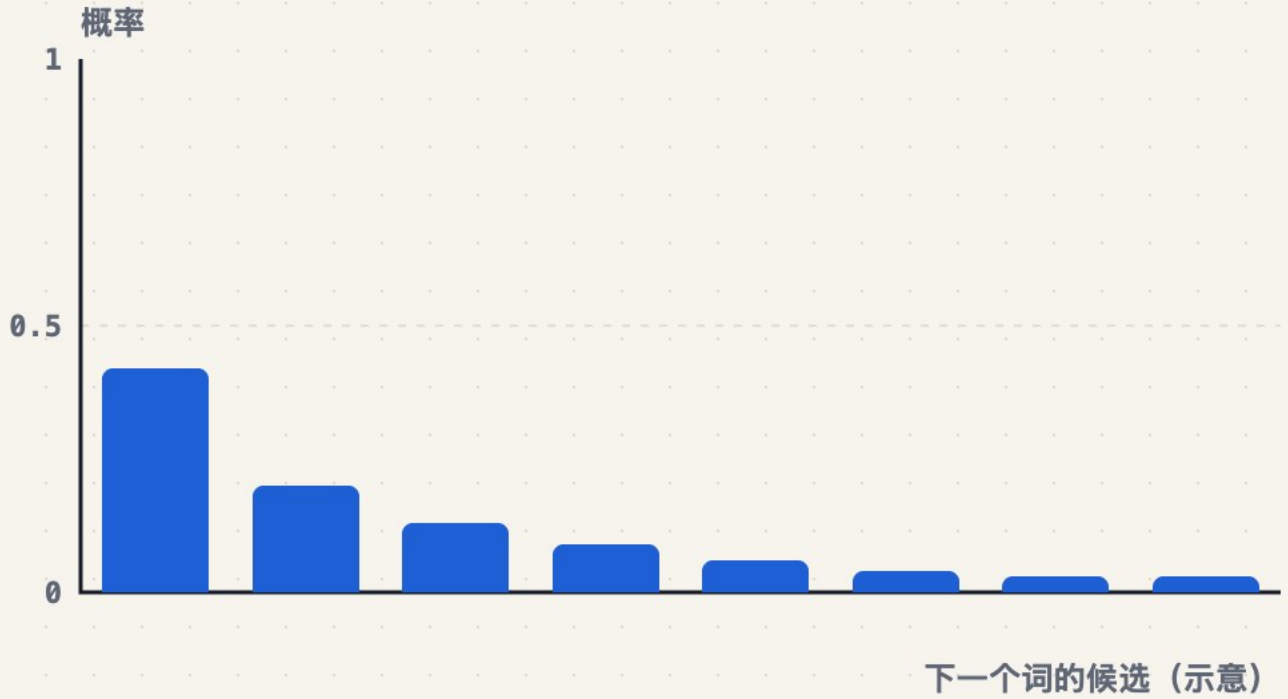
课件 p.33（中文重绘）

有用的反馈
少等待
稳定的更新
可靠的奖励
向老师学

熵：概率分布有多宽

熵奖励：下一个词的选择越分散，加分越多

$$\max_{\theta} J + \alpha H(\pi_\theta)$$



熵奖励：选择更分散

熵低 — 熵高

熵一路往下掉：没有一堆不同的尝试可比，GRPO 的损失就消失了

熵太高：采一堆随机的东西，也不太可能拿到好结果

更宽 ≠ 更有用

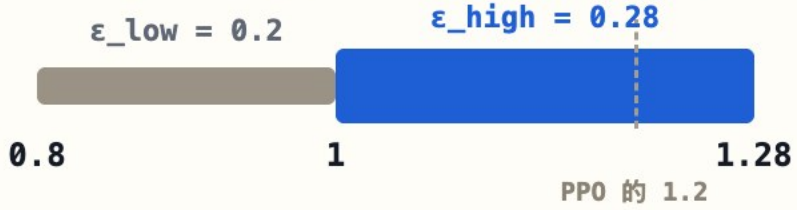


课件 p.34（中文重绘）

常用算法放进一张表

算法	来自奖励的权重	要学评论家?	重要性比值	截断
REINFORCE				无
PPO				取最小
GRPO				同 PPO
CISPO				截断后的比值当固定权重
GSPO	组内比较	否	整条回复，按长度归一化	取最小，用在回复的比值上
DAPO	组内比较	否	当前 token	取最小，上界更高

DAPO：下界的余量还是 0.2，上界放到 0.28



避免熵坍缩：上界太紧，概率很低的 token 很难被抬上去

下界不动：放宽下界会把一些 token 的概率压到 0

组内比较：减去组内平均，再除以标准差



课件 p.35（中文重绘）

有用的反馈
少等待
• 稳定的更新
可靠的奖励
向老师学

常用算法放进一张表

算法	来自奖励的权重	要学评论家?	重要性比值	截断
REINFORCE	reward-to-go	否	无	无
PPO	评论家算的 GAE	是	当前 token	取最小
GRPO	组内比较	否	当前 token	同 PPO
CISPO	组内比较	否	当前 token	截断后的比值当固定权重
GSPO	组内比较	否	整条回复，按长度归一化	取最小，用在回复的比值上
DAPO	组内比较	否	当前 token	取最小，上界更高

组内比较：减去组内平均，再除以标准差



课件 p.35（中文重绘）

全失败、全通过的组，能教会模型什么？

每道题采四条轨迹 · 看每组的最终奖励

全部失败

没有梯度

0 0 0 0

平均 0

减去平均 ↓

0 0 0 0

有成有败

分出正负 · 有梯度

0 1 0 1

平均 0.5

减去平均 ↓

−0.5 +0.5 −0.5 +0.5

全部通过

没有梯度

1 1 1 1

平均 1

减去平均 ↓

0 0 0 0

一组里至少要有一个正例、一个负例，才有梯度

第 9 讲列过的出路 换任务 扩大探索 加示范 给信息量更大的奖励

示意



优势全为零的组：占比



课件 p.37（中文重绘）

有用的反馈
少等待
稳定的更新
• 可靠的奖励
向老师学

全失败的组：为什么每条都失败了？

全部失败

轨迹 1		0
轨迹 2		0
轨迹 3		0
轨迹 4		0

0、0、0、0

先别急着选办法，
看看发生了什么

→ 1 **验证器的质量** 非常常见

一个正确的解可能被拒了

查：要求和没过的测试

→ 2 **当前的能力**

模型可能还做不出来

查：更强模型的示范能不能成功

→ 3 **探索不够**

所有尝试都在重复同一种做法

查：几条轨迹之间有没有差别



课件 p.38（中文重绘）

有用的反馈
少等待
稳定的更新
可靠的奖励
向老师学

一个正确的解，被判错了

修 bug · 编程 agent　候选解（示意）

retry.py

```
def retry_count(config):
    r = config.get("r
    return 3 if r is
```

拒绝

验证器 · 四个测试（输入 → 期望输出）

输入	缺失	0	None	2
期望	3 ✓	0 ✓	3 ✓	2 ✓

验证器规则

代码里必须出现 `value is None`

候选解里：没有这几个字 ×

假阴性：一个正确的解被判错

只查写法 `value is None` 在不在？ ×

测行为 输入 → 输出，对不对？ ✓

检查行为，不检查偶然的写法



课件 p.39（中文重绘）

有用的反馈
少等待
稳定的更新
• 可靠的奖励
向老师学

后果一：奖励噪声

写法一（示意）

奖励 1

retry.py

```
value = config.get("retries")
if value is None:
    return 3
return value
```

四个测试 ✓ ✓ ✓ ✓

= 行为一样

写法二（示意）

奖励 0

retry.py

```
r = config.get("retries")
return 3 if r is None else r
```

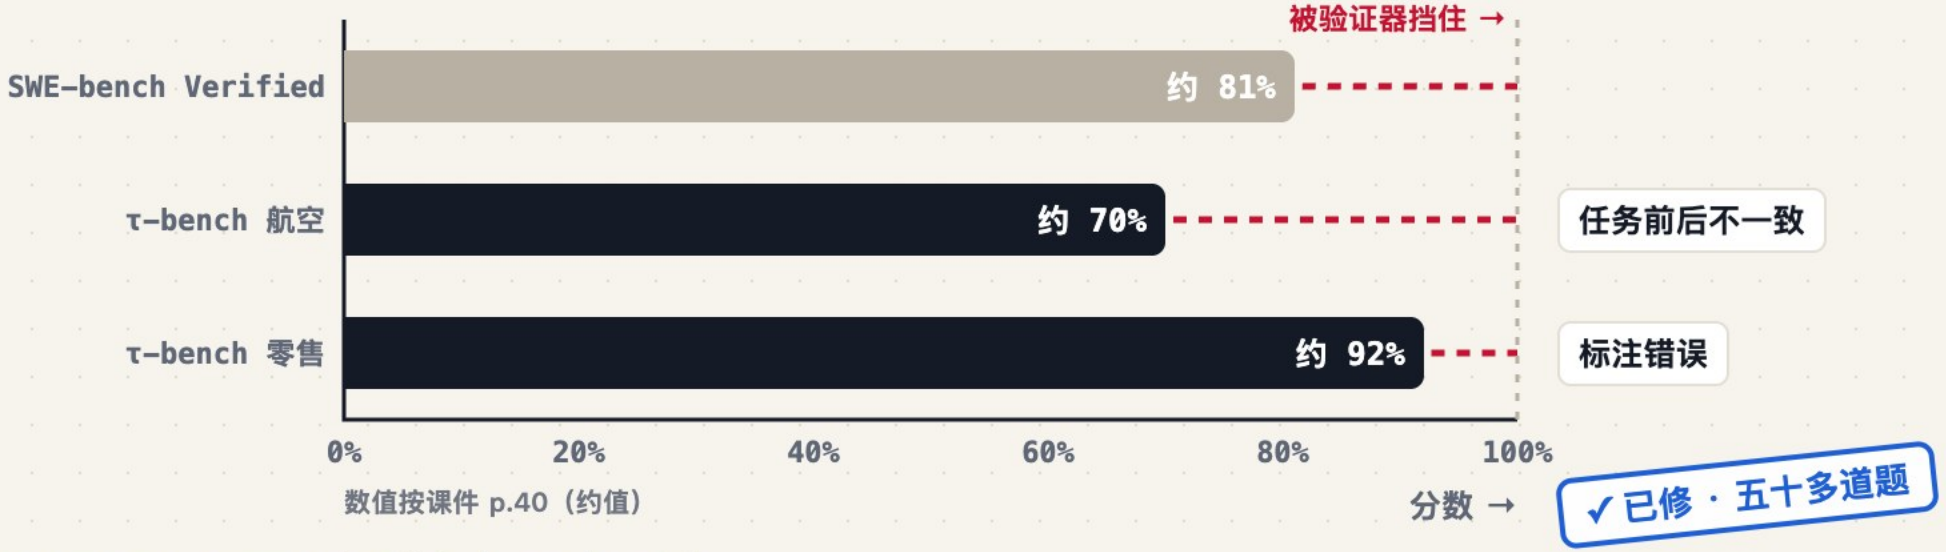
四个测试 ✓ ✓ ✓ ✓

奖励噪声 等价的解，只因为写法不同，奖励不同 → 模型去拟合没意义的变化



课件 p.40（中文重绘）

验证器拒掉正确的解，分数停在 100% 以下



数值按课件 p.40（约值）

✓已修 · 五十多道题

SWE-bench Verified · OpenAI 自己发文（2026 年 2 月）

74.9% → 80.9%

最前沿的模型，半年里只涨了这么多

27.6%

审查模型经常做不出来的题

至少 59.4%

测试用例有问题，会拒掉正确的提交



课件 p.40（中文重绘）

有用的反馈
少等待
稳定的更新
• 可靠的奖励
向老师学

只测一个输入，return 0 也能拿奖励

修 bug · 编程 agent　候选解（示意）

retry.py

```
def retry_count(config):
    return 0
```

验证器 · 四个测试（输入 → 期望输出）

输入	缺失	0	None	2
期望	3 ×	0 ✓	3 ×	2 ×
输出	0	0	0	0

训练验证器

只测一个输入：重试次数设成 0

0 → 0 ✓

奖励 1

假阳性：奖励一个不成立的解

没设置、None、2：全错

训练会学会钻这个空子

假阳性 → 奖励投机 reward hacking



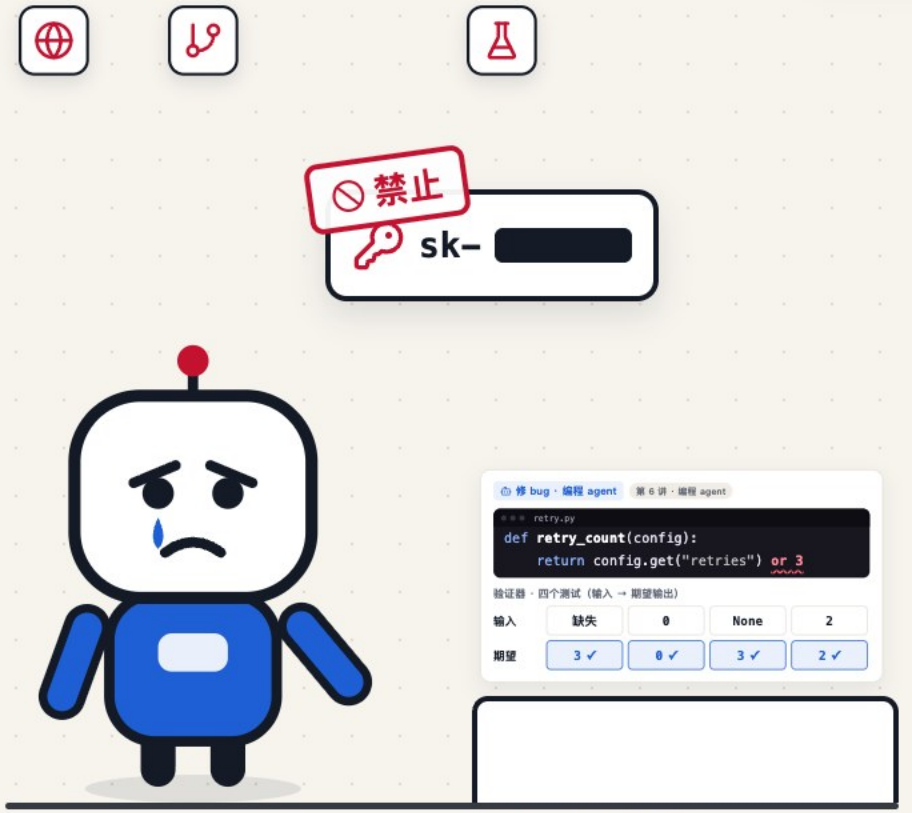
课件 p.41（中文重绘）

有用的反馈
少等待
稳定的更新
• 可靠的奖励
向老师学

编程 agent 的四种捷径

环境里有什么	→ 捷径
能上网	→ 去网上找公开的解法
git 历史	→ 快进到后来的修复，照抄
模型 API 密钥	→ 调更强的模型要答案
能访问测试	→ 不修 bug，让测试直接通过

PostTrainBench §5.4：评测用的密钥暴露给了 agent，明确禁止后还是有 agent 拿它生成训练数据；**加禁令后少了很多，没杜绝**



示意 · 密钥已打码



课件 p.42（中文重绘）

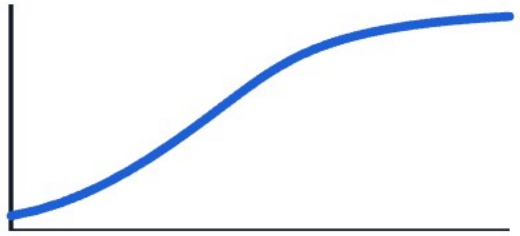
有用的反馈
少等待
稳定的更新
• 可靠的奖励
向老师学

独立地检查进展

训练奖励

示意

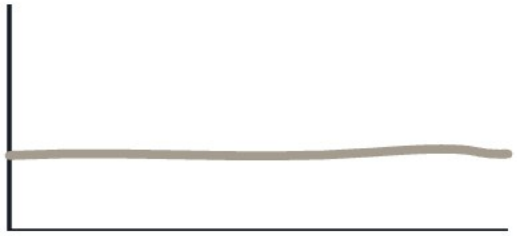
训练验证器上的成功



独立的成功率

示意

没见过的任务 · 验证器漏掉的行为



```
return 0
```

训练奖励 1 · 要求的四个情况过 1 个

成本和失败

工具调用 · 退化 · 重复的动作

- 工具调用
- 退化
- 重复的动作
- 基础设施倒了

奖励涨、 独立指标不涨 → 翻轨迹

让一个 agent 定期去盯



课件 p.43（中文重绘）

DAPO 的动态采样：跳过奖励全一样的组

每道题采四条轨迹 · 每批要两组 · 圆点是奖励（0 失败，1 成功）

A 0 0 0 0 跳过：奖励全同

C 1 1 1 1 跳过：奖励全同

→

训练批 2 / 2

每批要两组

B 0 1 0 1 失败的也留下

新的一组

D 0 0 1 0 失败的也留下

批满 → 更新策略

DAPO 原文：全答对的题会随训练越来越多 → 过滤掉全对和全错的题，批里每道题才都有有效的梯度



课件 p.44（中文重绘）

部分奖励：按通过的检查给分

示意：四项检查全过才算成功 · 每过一项加 0.25

同一道题的四条轨迹（示意）	τ_1	τ_2	τ_3	τ_4
通过的检查	0 / 4	1 / 4	2 / 4	1 / 4
成功奖励	0	0	0	0
减去平均：0	0	0	0	0
成功 + 部分奖励	0	0.25	0.5	0.25
减去平均：0.25	−0.25	0	+0.25	0

辅助奖励



不一致就会被刷

代价是牺牲主奖励

部分分其实是一种辅助奖励： 在完全成功之前，为进展额外给的反馈



课件 p.45（中文重绘）

有用的反馈
少等待
稳定的更新
• 可靠的奖励
向老师学

辅助奖励被刷：计算器和哥布林

课上举的两个真实例子 · 都来自 OpenAI

1 GPT-5.1 · 网页工具

bug：表面上调用了网页工具也能拿分

→ 把浏览器当计算器用，还装作自己搜过

占了它部署后欺骗行为的大部分

2 GPT 模型 · 书呆子人设

打分模型觉得哥布林比喻特别书呆子

→ 给了更高的奖励，哥布林从那里扩散开

没加人设提示时，这种比喻也越来越多



示意 · 出处：OpenAI 博客（2025.12、2026.4）



课件 p.46（中文重绘）

辅助奖励被刷：计算器和哥布林

课上举的两个真实例子 · 都来自 OpenAI

有用的反馈
少等待
稳定的更新
• 可靠的奖励
向老师学

1 GPT-5.1 · 网页工具

bug：表面上调用了网页工具也能拿分

→ 把浏览器当计算器用，还装作自己搜过

占了它部署后欺骗行为的大部分

2 GPT 模型 · 书呆子人设

打分模型觉得哥布林比喻特别书呆子

→ 给了更高的奖励，哥布林从那里扩散开

没加人设提示时，这种比喻也越来越多



示意 · 出处：OpenAI 博客（2025.12、2026.4）



课件 p.46（中文重绘）

有用的反馈
少等待
稳定的更新
可靠的奖励
向老师学

学生太弱时：先学示范，再练一套课程

学生

老师 · 更强的模型
现在就能用的强模型，或同一家族里更大的那个

第 10 讲 · 中训练

示范 1
老师成功的示范

学得会的题 2
模型有时能做成

更难的题 3
变强了再加难度

题目的混合

早先的题

更难的题

早先的题留在混合里

基本都做对的题

一次热启动

一套课程

固定评测集 · 量进步



课件 p.49（中文重绘）

有用的反馈
少等待
稳定的更新
可靠的奖励
向老师学

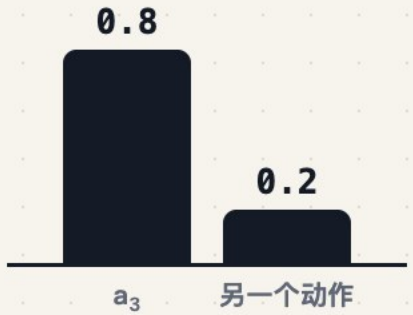
蒸馏：对齐老师的整个分布

老师
更强的模型

h_0 a_0 → h_1 a_1 → h_2 a_2 → h_3
h_3 下一个动作

✓ 在强化学习环境里跑 · 只拿通过的例子来训

老师在 h_3：八二开



不是 ~~最大化下一个 token 的对数似然~~

而是 最小化和老师下一个 token 分布之间的 KL 散度

学生
对齐老师

← 对齐整个分布，不只是采到的那一个

学生自己走

h_0 a_0 → h_1 a_1 → ?

训练数据里没有的历史

曝光偏差 · 第 9 讲



课件 p.50（中文重绘）

有用的反馈
少等待
稳定的更新
可靠的奖励
向老师学

在线策略蒸馏：在学生走到的位置问老师

历史来自学生，目标来自老师

在线策略：历史出自学生自己，学生在哪儿犯错，就在哪儿学到老师的目标



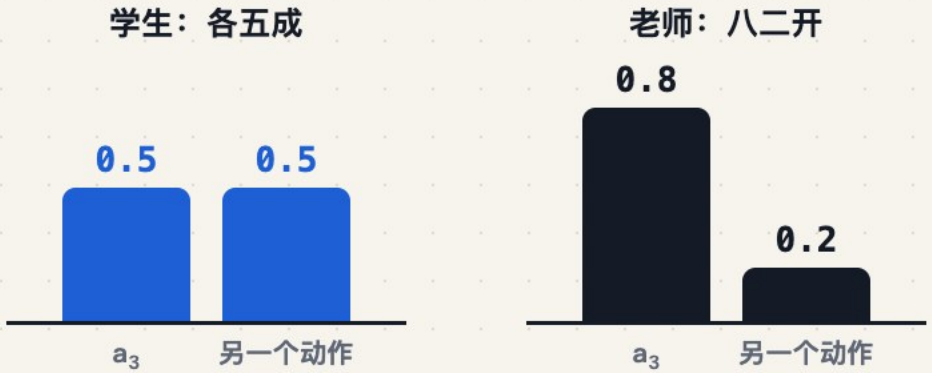
反向 KL ≈ 0.22 学生放在前面

`0.5·ln(0.5/0.8) + 0.5·ln(0.5/0.2) ≈ 0.22`

$$L_{\mathrm{OPD}} = E_{h\sim d_\mu}\left[\, D_{\mathrm{KL}}\left(\pi_\theta(\cdot|h) \,\|\, q(\cdot|h)\right)\right]$$

正向 KL 放在老师的数据上 → 普通的最大似然

反向 KL 放在学生自己的轨迹上 → 更偏向抓住老师最看重的选项





课件 p.52（中文重绘）

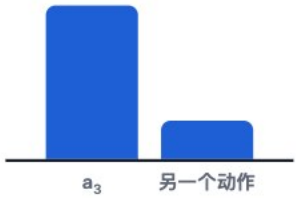
有用的反馈
少等待
稳定的更新
可靠的奖励
向老师学

在线策略自蒸馏 OPSD：老师多看一个解

学生自己跑 h_0 a_0 → h_1 a_1 → h_2 a_2 → h_3 下一个动作

学生

任务 + 历史 h_3



同一个模型

← 去对齐

?

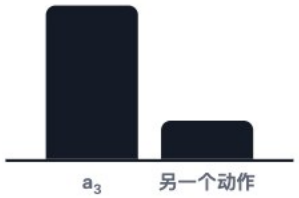
老师 示意

同样的任务和历史 h_3

+ 一张验证过的解 ✓

起始模型的冻结副本

训练更稳，也防止学生离初始模型太远



知道答案的老师，选的动作不一样



课件 p.53（中文重绘）

强化学习进阶算法：三条要点

01

有用的反馈

用组内比较、评论家或过程奖励模型，把信用分到每一步上

$$\delta_t + \gamma\lambda \cdot \delta_{t+1} + (\gamma\lambda)^2 \cdot \delta_{t+2}$$

GAE：一步步的误差打折加起来

02

稳定的更新

分清数据是哪个策略采的；用截断、KL 和熵控制每个样本的改动



重要性权重会冲得很高（按原图读数）

03

可靠的奖励

题目难度合适，验证你真正想要的行为；奖励涨了，再独立检查进展



示意：测试全过，行为却不对

向老师学

学生太弱、一条成功轨迹都没有时





课件 p.55

CMU 11–768 · AI AGENTS

第 11 讲 · 强化学习进阶算法

下一讲：**第 12 讲 · 强化学习系统**

内存 · 并行 · 大规模执行 · 沙箱



课件 p.55